

人工智能导论期末复习

网络空间安全学院 信息安全 陆皓喆 2211044

人工智能导论期末复习

第一章 绪论

知识点

- 定义
- 人工智能的不同研究方法
- 形式化系统的有效性
- 人工智能三次低谷
- 智能计算方法

习题

第二章 逻辑与推理

知识点

- 命题
- 逻辑
- 推理规则
- 范式
- 谓词逻辑
- 量词
- 自然语言的形式化**
- 知识图谱推理**
- 因果推理**
- D-分离**

习题

第三章 搜索求解

知识点

- 一些名词
- 搜索算法**
- 启发式搜索**
- 对抗搜索**
 - minimax*搜索
 - Alpha - Beta*剪枝搜索
 - 蒙特卡洛树搜索

习题

第四章 监督学习

知识点

- 机器学习基本概念
- 生成模型与判别模型
- 回归分析
 - 一元线性回归
 - 多元线性回归
 - 逻辑斯蒂回归
- 决策树
- 线性区别分析(LDA)
- Ada Boosting
- 支持向量机
- 生成学习模型

习题

第五章 无监督学习

知识点

- K均值聚类(K-Means)
 - 算法原理
 - K-means聚类算法步骤
 - 聚类算法的缺点
- 主成分分析(PCA)
 - 方差
 - 协方差
- 特征人脸方法

期望最大化算法(EM)	
习题	
第六章 深度学习	
知识点	
前馈神经网络	
神经元	
常用的激活函数	
Sigmoid函数	
tanh函数	
relu函数	
softmax函数	
损失函数	
均方误差损失函数	
交叉熵损失函数	
感知机	
单层感知机	
多层感知机	
参数优化与学习	
卷积神经网络	
主要结构	
池化操作	
神经网络正则化	
循环神经网络	
习题	
第七章 强化学习	
知识点	
强化学习问题定义	
基于价值的强化学习	
习题	
第八章 博弈	
知识点	
博弈相关概念	
遗憾最小化算法	
若干定义	
策略选择	
习题	

分值分配：课上随堂测试考核(10%)、研讨内容(10%)、实验内容考核(40%)和期末考试(40%)

期末考试：30道选择题（每小题2分）4道简答题（每小题5分）2道解答题（每小题10分）

第一章 绪论

知识点

定义

人工智能的定义：**是以机器为载体所实现的人类智能或生物智能**

人工智能的不同研究方法

- **符号逻辑：**以推理为核心
- **联结主义：**以统计机器学习为手段
- **行为学派：**从环境交互过程中进行策略学习

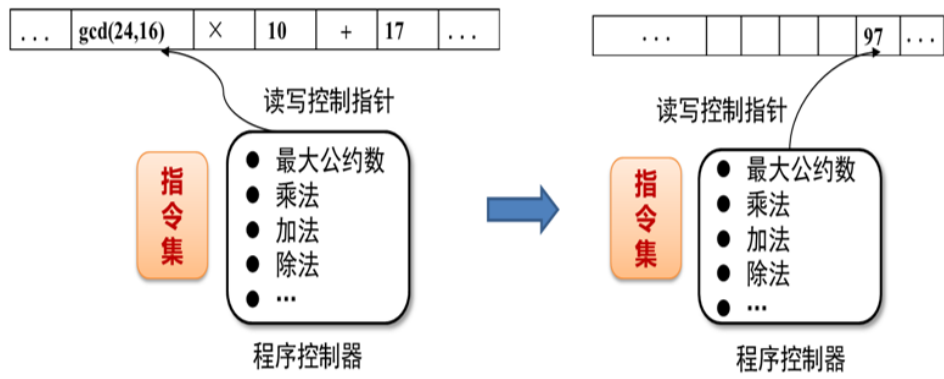
形式化系统的有效性

- **完备性**：所有能够从某形式化系统推出来的知识，都可以从这个形式化系统推导出来
- **一致性**：推导出来的知识不会推导出自己的否定，整个形式化系统是自洽的、非矛盾的
- **可判定性**：对于推导出的知识，存在算法在有限步内判定其真假

其中，哥德尔不完备定理指出，**一致性和完备性不可能同时具有**。

可计算的：就是可以用图灵机来计算，图灵机是一个机械计算装置，从左到右逐一计算，得出结果

图灵机模型：现代计算机的理论模型



人工智能三次低谷

- 第一次低谷：1973年英国发表*James Lighthill*报告
教训：AI尚属婴儿期，难以测算准确
- 第二次低谷：日本智能（第五代）计算机研制失败
教训：驱动AI的发展要靠软件、数据和知识，而非只依靠硬件
- 第三次低谷：知识词典日趋势微、网络百科兴起
教训：知识不能靠专家表达，要自动学习

智能计算方法

1.符号主义为核心的逻辑推理

就是将自然语言转为符号语言，从而使语言容易被计算机所识别

推理一般包括：

- **归纳推理**：从特殊到一般，从具体到抽象，从现象到本质
- **演绎推理**：从一般性前提出发，去推导演绎，得出具体陈述或者个别结论
- **因果推理**：判断事物之间存在的原因和结果这样的关系

推理方法	推理方式	说明
归纳推理	如果 A_i (i 为若干取值), 那么 B	从若干事实出发推理出一般性规律
演绎推理	如果 A , 那么 B	A 是 B 的前提, 但不是唯一前提, 因此 A 是 B 的充分条件
因果推理	因为 A , 所以 B	A 是 B 的唯一前提, 因此“如果没有 A , 那么没有 B ”也成立

2.问题求解为核心的探寻搜索

搜索 { 无信息搜索: *DFS; BFS*
 有信息搜索: *A**搜索; 贪婪最佳搜索
 对抗搜索: 最小最大搜索; *Alpha - Beta*剪枝搜索; 蒙特卡洛树搜索

3.数据驱动为核心的机器学习

机器学习 { 监督学习: 数据本身有*label*
 无监督学习: 无*label*
 半监督学习: 有些有*label*, 有些没有*label*

监督学习 { 回归分析
 提升算法(*boosting*)
 支持向量机
 决策树
 隐狄利克雷分布(*LDA*)
 隐马尔可夫链

无监督学习 { 聚类
 降维
 期望极大算法(*EM*)

4.行为主义为核心的强化学习

	监督学习	无监督学习	强化学习
学习依据	基于监督信息	基于对数据结构的假设	基于评价
数据来源	一次性给定(含标注信息)	一次性给定(无标注信息)	在序列交互中产生, 且只有在一个序列结束后才会反馈明确奖惩值
决策过程	根据标注信息做出单步静态决策	无	根据环境给出的滞后回报做出序列决策
学习目标	样本空间到高级语义空间的映射	同一类数据的分布模式	选择能够获取最大收益的状态到动作的映射

5.博弈对抗为核心的决策智能

博弈论——应用到计算机领域

习题

为保证形式化系统的有效性,下面哪个选项不是形式化系统需要具有的性质()

A 完备性 **B 可靠性** C 一致性 D 可判定性

*Deepmind*研制的*AlphaGo*算法没有使用哪个人工智能方法()

A 强化学习 B 深度学习 C 蒙特卡洛树搜索 **D 逻辑推理**

图灵奖获得者*Judea Pearl*将推理按照由易到难程度分成三个层次?

关联、干预、反事实

以下哪种搜索方法属于启发式搜索()

A 广度优先搜索 B 蒙特卡洛树搜索 C 深度优先搜索 **D A*搜索**

以下哪一种算法不属于监督学习算法()

A 隐马尔可夫链 B 支持向量机 **C 聚类** D 决策树

以下哪种学习方法的学习目标是学习同一类数据的分布模式()

A 监督学习 B 无监督学习 C 强化学习 D 博弈对抗

从人工智能的计算性和智能性角度可以将人工智能定义为：

以机器为载体所实现的人类智能或生物智能

从智能角度可以将人工智能分为三类，分别是

领域人工智能/专用人工智能;通用人工智能/跨领域人工智能;混合增强人工智能

人工智能的三种主流方法包括：

符号主义; 联结主义; 行为主义

推理一般包括哪三种主流方法？

归纳推理；演绎推理；因果推理

按照学习算法对数据的利用方式不同，机器学习算法可以分为：

监督学习；无监督学习；半监督学习

有信息搜索又称为？什么是其中比较有代表性的算法？

启发式搜索； A^* 搜索、贪婪最佳优先搜索

什么称为博弈搜索？代表性算法？

对抗搜索；最大最小搜索、 $\alpha - \beta$ 剪枝搜索、蒙特卡洛树搜索

第二章 逻辑与推理

知识点

命题

命题：**确定真值的陈述句**，无法判断正误的句子都不能作为命题

北京是中国的首都：是真命题

请出去：不是命题，是祈使句

您去开会吗？：不是命题，是疑问句

13能被6整除：是假命题

这座山真高啊！：不是命题，是感叹句

我正在说谎：不是命题，是悖论

原子命题：指的是不包含其他命题作为其组成部分的命题，又叫做简单命题

简单命题通过联结，形成复合命题

复合命题：指的是包含其他命题作为其组成部分的命题

五种常见的联结词：

命题连接符号	表示形式	意义
与(<i>and</i>)	$p \wedge q$	命题合取(<i>conjunction</i>), 即“ p 且 q ”
或(<i>or</i>)	$p \vee q$	命题析取(<i>disjunction</i>), 即“ p 或 q ”

命题连接符号	表示形式	意义
非 (<i>not</i>)	$\neg p$	命题否定(<i>negation</i>), 即“非 p ”
条件(<i>conditional</i>)	$p \rightarrow q$	命题蕴含(<i>implication</i>), 即“如果 p 则 q ”
双向条件 (<i>bi – conditional</i>)	$p \leftrightarrow q$	命题双向蕴含(<i>bi – implication</i>), 即“ p 当且仅当 q ”

对应的真值表：

真值表						
p	q	$\neg p$	$p \wedge q$	$p \vee q$	$p \rightarrow q$	$p \leftrightarrow q$
<i>False</i>	<i>False</i>	<i>True</i>	<i>False</i>	<i>False</i>	<i>True</i>	<i>True</i>
<i>False</i>	<i>True</i>	<i>True</i>	<i>False</i>	<i>True</i>	<i>True</i>	<i>False</i>
<i>True</i>	<i>False</i>	<i>False</i>	<i>False</i>	<i>True</i>	<i>False</i>	<i>False</i>
<i>True</i>	<i>True</i>	<i>False</i>	<i>True</i>	<i>True</i>	<i>True</i>	<i>True</i>

注意：当 $p \rightarrow q$ 时，代表的意思是，如果 p 是真的，那么 q 是真的，相当于就是说 p 是 q 的子集，所以如果 p 为假，那么 q 一定成立

逻辑

逻辑等价：如果 p 和 q 都具有相同的结果，那么这两个命题就等价

一些常见的逻辑等价	
$\alpha \wedge \beta \equiv \beta \wedge \alpha$ ($\wedge$ 的交互律)	$(\alpha \rightarrow \beta) \equiv \neg \alpha \vee \beta$ (蕴涵消除)
$\alpha \vee \beta \equiv \beta \vee \alpha$ ($\vee$ 的交互律)	$(\alpha \leftrightarrow \beta) \equiv (\alpha \rightarrow \beta) \wedge (\beta \rightarrow \alpha)$ (双向消除)
$(\alpha \wedge \beta) \wedge \gamma \equiv \alpha \wedge (\beta \wedge \gamma)$ ($\wedge$ 的结合律)	$\neg(\alpha \wedge \beta) \equiv (\neg \alpha \vee \neg \beta)$ (<i>De Morgan</i>)
$(\alpha \vee \beta) \vee \gamma \equiv \alpha \vee (\beta \vee \gamma)$ ($\vee$ 的结合律)	$\neg(\alpha \vee \beta) \equiv (\neg \alpha \wedge \neg \beta)$ (<i>De Morgan</i>)
$\neg(\neg \alpha) \equiv \alpha$ (双重否定)	$(\alpha \wedge (\beta \vee \gamma)) \equiv (\alpha \wedge \beta) \vee (\alpha \wedge \gamma)$ ($\wedge$ 对 $\vee$ 的分配律)
$(\alpha \rightarrow \beta) \equiv \neg \beta \rightarrow \neg \alpha$ (逆否命题)	$(\alpha \vee (\beta \wedge \gamma)) \equiv (\alpha \vee \beta) \wedge (\alpha \vee \gamma)$ ($\vee$ 对 $\wedge$ 的分配律)

蕴涵消除： α 为假、则命题恒为真； α 为真、则 β 须为真，所以 $(\alpha \rightarrow \beta) \equiv \neg \alpha \vee \beta$

推理规则

命题逻辑中常用的推理规则：

假言推理 (Modus Ponens)	
与消解 (And-Elimination)	$(\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n) \Rightarrow (\alpha_i (1 \leq i \leq n))$
与导入 (And-Introduction)	$(\alpha_1, \alpha_2, \dots, \alpha_n) \Rightarrow (\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n)$
双重否定 (Double-Negation Elimination)	$(\neg \neg \alpha) \Rightarrow \alpha$
单项消解或单项归结 (Unit Resolution)	$(\alpha \vee \beta, \neg \beta) \Rightarrow \alpha$

假言推理 (Modus Ponens)	$(\alpha \rightarrow \beta, \alpha) \Rightarrow \beta$
消解或归结 (Resolution)	$(\alpha \vee \beta, \neg\beta \vee \gamma) \Rightarrow \alpha \vee \gamma$

e.g

已知 $\alpha \vee \beta; \alpha \rightarrow \gamma; \beta \rightarrow \gamma$, 证明命题 γ 是成立的

证明:

通过蕴涵消除得到

$$\alpha \rightarrow \gamma \Rightarrow \neg\alpha \vee \gamma$$

$$\beta \rightarrow \gamma \Rightarrow \neg\beta \vee \gamma$$

通过消解与归结得到

$$\alpha \vee \gamma$$

$$\beta \vee \gamma$$

再和前面的做归结运算得到命题正确

重点看一下书本上的例题2.3, 例题2.4和例题2.5

范式

范式:

- 析取范式: 有限个简单合取式构成的析取式
- 合取范式: 有限个简单析取式构成的合取式

假设 α_i 为简单的合取式, 则 $\alpha = \alpha_1 \vee \alpha_2 \vee \dots \vee \alpha_k$ 为析取范式

假设 α_i 为简单的析取式, 则 $\alpha = \alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_k$ 为合取范式

析取范式与合取范式统称为范式

一个析取范式是不成立的, 当且仅当它的每个简单合取式都不成立

一个合取范式是成立的, 当且仅当它的每个简单析取式都是成立的

任一命题公式都存在着与之等值的析取范式与合取范式, 且命题公式的析取范式和合取范式都不是唯一的

问题: 求 $\neg(\alpha \rightarrow \beta) \vee \neg\gamma$ 的析取范式与合取范式

$$\neg(\alpha \rightarrow \beta) \vee \neg\gamma$$

$$\iff \neg(\neg\alpha \vee \beta) \vee \neg\gamma$$

$$\iff (\alpha \wedge \neg\beta) \vee \neg\gamma \text{ (析取范式)}$$

$$\iff (\alpha \vee \neg\gamma) \wedge (\neg\beta \vee \neg\gamma) \text{ (合取范式)}$$

谓词逻辑

谓词逻辑: 引入更强大的逻辑表示方式, 分离其主语 (个体和群体) 和谓语 (关系), 这就是谓词逻辑

个体: 指的是在所研究的领域中可以独立存在的具体或者抽象的概念

谓词: 用来刻画个体属性或者描述个体之间的关系存在性的元素, 其值为真或者为假

函数与谓词的区别：

- 函数中，个体变量用个体变量代入后，还是个体
- 谓词中，个体变量用个体变量代入后，就变成了命题，结果是 $true$ 或者是 $false$

量词

量词：

- 全称量词：全称量词用符号 $\forall$ 表示，表示一切的、凡是、所有的、每一个等。 $\forall x$ 表示定义域中的所有个体， $\forall xP(x)$ 表示定义域中的所有个体具有性质 P
- 存在量词：存在量词用符号 $\exists$ 表示，表示存在、有一个、某些等。 $\exists x$ 表示定义域中存在一个或若干个个体， $\exists xP(x)$ 表示定义域中存在一个个体或若干个个体具有性质 P

全称量词&存在量词：

$$\forall x \neg P(x) \equiv \neg \exists x P(x)$$

$$\neg \forall x P(x) \equiv \exists x \neg P(x)$$

$$\forall x P(x) \equiv \neg \exists x \neg P(x)$$

$$\exists x P(x) \equiv \neg \forall x \neg P(x)$$

合式公式：

命题常项、命题变项、原子谓词都是合式公式

如果 A 和 B 是合式公式，那么 $\neg A, A \wedge B, A \vee B, A \rightarrow B, A \longleftrightarrow B$ 都是合式公式

如果 A 是合式公式， x 是个体变元，则 $\exists x A(x)$ 和 $\forall x A(x)$ 也是合式公式

谓词逻辑的推理：

- 全称量词消去： $(\forall x)A(x) \Rightarrow A(y)$
- 全称量词引入： $A(y) \Rightarrow (\forall x)A(x)$
- 存在量词消去： $(\exists x)A(x) \Rightarrow A(c)$
- 存在量词引入： $A(c) \Rightarrow (\exists x)A(x)$

已知：

$$(\forall x)(P(x) \rightarrow Q(x))$$

$$(\forall x)(Q(x) \rightarrow R(x))$$

$$\text{试证明：} (\forall x)(P(x) \rightarrow R(x))$$

使用全称量词的消去与引入就可以证明了

$$(\forall x)(P(x) \rightarrow Q(x))$$

$$P(x) \rightarrow Q(x) \text{ (消去全称量词)}$$

$$(\forall x)(Q(x) \rightarrow R(x))$$

$$Q(x) \rightarrow R(x) \text{ (消去全称量词)}$$

$$P(x) \rightarrow R(x) \text{ (假言三段论)}$$

$$(\forall x)(P(x) \rightarrow R(x)) \text{ (引入 } x \text{)}$$

看课本30页例题2.11和例题2.12

自然语言的形式化

就是将我们人类使用的自然语言，用谓词逻辑表示出来，就可以进行推理了

例题2.13和例题2.14

已知: $(\forall x)(plane(x) \rightarrow inground \vee onfly(x)), (\neg \forall x)(plane(x) \rightarrow onfly(x))$

请证明: $(\exists x)(plane(x) \wedge inground(x))$

$(\neg \forall x)(plane(x) \rightarrow onfly(x))$

$(\exists x)\neg(plane(x) \rightarrow onfly(x))$

$(\exists x)\neg(\neg plane(x) \vee onfly(x))$

$(\exists x)(plane(x) \wedge \neg onfly(x))$

$plane(a) \wedge \neg onfly(a)$

$plane(a) \neg onfly(a)$

$(\forall x)(plane(x) \rightarrow inground(x) \vee onfly(x))$

$plane(a) \rightarrow inground(a) \vee onfly(a)$

$inground(a) \vee onfly(a)$

$inground(a)$ (7, 10消解)


$plane(a) \wedge inground(a)$

$(\exists x)(plane(x) \wedge inground(x))$

知识图谱推理

知识图谱可视为包含多种关系的图

可将知识图谱中任意两个相连节点及其连接边表示成一个三元组 (triplet)



比如说 $(David, Father, Mike)$ 的意思就是，前者是后者的爸爸，中间的表示两者之间的关系，图中的红色的线需要通过推理才能得到

知识图谱推理就是通过机器学习等方法对知识图谱所蕴含关系进行挖掘

如何对知识图谱中的关系进行推理？一共是两种方法

1. 归纳逻辑程序设计 (inductive logic programming, ILP) 算法

作为 ILP 的代表性方法，FOIL (First Order Inductive Learner) 通过序贯覆盖实现规则推理。

推理手段：

$positive\ examples + negative\ examples + background\ knowledge\ examples \implies hypothesis$

$$(\forall x)(\forall y)(\forall z)(Mother(z, y) \wedge Couple(x, z) \rightarrow Father(x, y))$$



前提约束谓词
(学习得到)



目标谓词
(已知)

推理思路：从一般到特殊，逐步给目标谓词添加**前提约束谓词**，直到所构成的推理规则**不覆盖任何反例**

对目标谓词或前提约束谓词中的变量赋予具体值，如将

$(\forall x)(\forall y)(\forall z)(Mother(z, y) \wedge Couple(x, z) \rightarrow Father(x, y))$ 这一推理规则所包含的目标谓词 $Father(x, y)$ 中 x 和 y 分别赋值为 $David$ 和 Ann

那么我们需要添加哪些谓词呢？我们根据 $FOIL$ 中的**信息增益值**来判断

$$FOIL_Gain = \widehat{m_+} \cdot \left(\log_2 \frac{\widehat{m_+}}{\widehat{m_+} + \widehat{m_-}} - \log_2 \frac{m_+}{m_+ + m_-} \right)$$

其中， $\widehat{m_+}$ 和 $\widehat{m_-}$ 是增加前提约束谓词后所得新推理规则覆盖的正例和反例的数量， m_+ 和 m_- 是原推理规则所覆盖的正例和反例数量

我们依次将谓词加入到推理规则中作为前提约束谓词，并计算所得到新推理规则的 $FOIL$ 增益值。基于计算所得 $FOIL$ 增益值来选择最佳前提约束谓词。

背景知识样例集合	目标谓词训练样例集合
$Sibling(Ann, Mike)$ $Couple(David, James)$ $Mother(James, Ann)$ $Mother(James, Mike)$	$Father(David, Mike)$ $\neg Father(David, James)$ $\neg Father(James, Ann)$ $\neg Father(James, Mike)$ $\neg Father(Ann, Mike)$

然后就一个一个计算下来，算出增益值最大的那一个前提约束谓词

计算出第一轮加入 $Couple(x, z)$ 信息增益最大，然后将其加入前提约束中去，将训练样例中与该推理规则不符的样例去掉

这样一直进行运算，直到最后的推理规则不包含反例就可以了


具体见课本例题2.15

FOIL	FOIL算法
输入	目标谓词 P ， P 的训练样例（正例集合和反例集合），其他背景知识
输出	推导得到目标谓词 P 的推理规则
1	将目标谓词作为所学习推理规则的结论
2	将其他谓词逐一作为前提约束谓词加入推理规则，计算所得到推理规则的 $FOIL$ 信息增益值，选取最优前提约束谓词以生成新推理规则，并将训练样例集合中与该推理规则不符的样例去掉
3	重复2过程，直到所得到的推理规则不覆盖任意反例

2.路径排序算法

就是判断路径关联是否能支持表述两者之间的关系

Score(Father(David, Ann))



一个简单的家庭关系知识图谱

$$\text{score}(s, t) = \sum_{\pi_j \in p_l} \theta_j P(s \rightarrow t; \pi_j)$$

p_l 是链接节点 s 和节点 t 的所有路径集合

θ_j 是某一条路径 π_j 的权重

P 是路径 π_j 概率值大小

- 特征抽取：生成并选择路径特征集合。生成路径的方式有随机游走 (*randomwalk*)、广度优先搜索、深度优先搜索等。
- 特征计算：计算每个训练样例的特征值 $P(s \rightarrow t; \pi_j)$ 。该特征值可以表示从实体节点 s 出发，通过关系路径 π_j 到达实体节点 t 的概率；也可以表示为布尔值，表示实体 s 到实体 t 之间是否存在路径 π_j ；还可以是实体 s 和实体 t 之间路径出现频次、频率等。
- 分类器训练：根据训练样例的特征值，为目标关系训练分类器。当训练好分类器后，即可将该分类器用于推理两个实体之间是否存在目标关系。

具体示例看书本例题2.16

因果推理

Simpson's Paradox (辛普森悖论)：在总体样本中成立的某种关系在分组样本中恰好相反


有向无环图 (DAG)

对于任意的DAG，模型中 d 个变量的联合概率分布由每个节点与其父节点之间条件概率 $P(\text{child}|\text{parents})$ 的乘积给出：

$$P(x_1, x_2, \dots, x_d) = \prod_{j=1}^d P(x_j | x_{pa(j)})$$

其中， $x_{pa(j)}$ 表示节点 x_j 的父节点集合（所有指向 x_j 的节点）

(考点) 写出以下DAG的联合概率形式，并区分内生变量和外生变量






有向无环图DAG

联合分布为 $P(X_1, X_2, X_3, X_4, X_5, X_6, X_i, X_j) =$

$P(X_2) \times P(X_3) \times P(X_1 | X_2, X_3, X_i, X_j) \times P(X_4 | X_2) \times P(X_5 | X_3) \times P(X_6 | X_i, X_j) \times P(X_i | X_4) \times P(X_j | X_5, X_6)$

内生变量是里面的，被其他影响的；外生变量是不由其他元素决定的

D-分离

链结构(chain)	分连结构(fork)	汇连（或碰撞）结构(collider)
		
Z和X是相关的	X和Z是相关的	Z和X是相关的
Y和Z是相关的	Y和Z是相关的	Z和Y是相关的
Y和X很有可能是相关的	Y和X很有可能是相关的	Y和X是相互独立的
给定Z时，Y和X是条件独立的	给定Z时，Y和X是条件独立的	给定Z时，Y和X是相关的


D-分离：对于一个DAG图，如果 A 、 B 、 C 是三个集合（可以是单独的节点或者是节点的集合），为了判断 A 和 B 是否是 C 条件独立的，在DAG图中考虑所有 A 和 B 之间的路径(不管方向)。对于其中的一条路径，如果满足以下两个条件中的任意一条，则称这条路径是阻塞（block）的：路径中存在节点 X

- X 是**链结构**或**分连结构**节点, 且 $X \in C$
- X 是**汇连结构**节点，并且 X 或 X 后代不包含在 C 中

如果 A 和 B 之间所有路径都是阻塞的，那么 A 和 B 就是关于 C 条件独立的；否则 A 和 B 不是关于 C 条件独立

下面描述中正确的有

- ☐ A a和b是条件c下独立的
- ☐ B a和b是条件e下独立的
- ☒ C a和b是条件f下独立的



上图中 a 到 b 只有一条路径 $a \rightarrow e \rightarrow f \rightarrow b$ 。如果能找到该路径上的任意节点 X 对其进行阻塞，则 a 和 b 是条件独立的。否则不是。

条件为 c 时，只有当汇连节点 e 或者 e 的子节点不包含在条件 c 中的时候， e 才能阻塞。由于 c 是 e 的子节点，因此 e 不能阻塞。只有当分连接点 f 包含在条件 c 中的时候， f 才能阻塞。这里的 f 也不能阻塞。因此 a 和 b 在条件 c 下是不独立的。

同上。

条件为 f 时，对分连结构节点 f ， f 在条件集合 f 中，因此可以阻塞。独立成立。

推理总结

推理方法	推理方式	说明
归纳推理	如果 A_i (i 为若干取值), 那么 B	从若干事实出发推理出一般性规律
演绎推理	如果 A , 那么 B	A 是 B 的前提、但不是唯一前提, 因此 A 是 B 的充分条件。当然, 在特殊情况下 A 也可为 B 的充分必要条件
因果推理	因为 A , 所以 B	A 是 B 的唯一前提, 因此“如果没有 A , 那么没有 B ”也成立。

习题

1. 和均是原子命题,“如果那么”是由和组合得到的复合命题。下面对“如果那么”这一复合命题描述不正确的是()

A.“如果那么”定义的是一种蕴涵关系(即充分条件)

B.“如果那么”意味着命题包含着命题,即是子集

C.无法用真值表来判断“如果那么”的真假

D.当不成立时,“如果那么”恒为真

2.下面哪个逻辑等价关系是不成立的 ()

- A $\forall x \neg P(x) \equiv \neg \exists x P(x)$
- B $\neg \forall x P(x) \equiv \exists x \neg P(x)$
- C $\forall x P(x) \equiv \neg \exists x \neg P(x)$
- D $\exists x P(x) \equiv \neg \forall x P(x)$

3.下列句子中不是命题的是 ()

A. $x > 2$

B. 今天天气真好啊!

C. 天津大学是中国近代第一所大学

D. 所有实数的平方都大于或等于0

4.应用归结法证明以下命题集是不可满足的。

a) $\alpha \vee \beta$;

b) $\beta \rightarrow \gamma$;

c) $\neg \alpha \wedge \neg \gamma$;

解 应用归结法:

(1) $\alpha \vee \beta$ (已知);

(2) $\neg \beta \vee \gamma$ (b 进行蕴涵消除);

(3) $\alpha \vee \gamma$ (由 1 和 2);

(4) $\neg(\alpha \vee \gamma)$ (c 使用 De Morgan 定律)

(5) 3 和 4 矛盾, 因此原命题集是不可满足的。

5.证明苏格拉底三段论“所有人都是要死的, 苏格拉底是人, 所以苏格拉底是要死的”。

解：设 $F(x)$: x 是人； $G(x)$: x 是要死的人； a 是苏格拉底。

前提： $(\forall x)(F(x) \rightarrow G(x))$ ； $F(a)$ 。

结论： $G(a)$ 。

证明：(1) $(\forall x)(F(x) \rightarrow G(x))$ ；

(2) $F(a) \rightarrow G(a)$ (1的全称量词消去)；

(3) $F(a)$ ；

(4) $G(a)$ (2和3的假言推理)。

1.下面对一阶归纳推理(*FOIL*)中信息增益值(*information gain*)阐释不正确的是()

A.信息增益值用来判断向推理规则中所加入前提约束谓词的质量

B.在算法结束前,每次向推理规则中加入一个前提约束谓词,该前提约束谓词得到的新推理规则具有最大的信息增益值

C.在计算信息增益值过程中,需要利用所得到的新推理规则和旧推理规则分别涵盖的正例和反例数目

D.信息增益值大小与背景知识样例数目直接相关

2.下面哪个描述的问题不属于因果分析的内容()

A.如果商品价格涨价一倍,预测销售量(*sales*)的变化

B.如果广告投入增长一倍,预测销售量(*sales*)的变化

C.如果放弃吸烟,预测癌症(*cancer*)的概率

D.购买了一种商品的顾客是否会购买另外一种商品

3.常用的知识图谱推理方法有?

一阶归纳逻辑推理/FOIL逻辑推理;路径排序推理/PRA

4.“总体样本上成立的某种关系在分组样本里恰好相反。”是著名的?

辛普森悖论


5.因果图常见的结构有?

链结构/链/*chain*;分连结构/分连/*fork*;汇连结构/汇连/*collider*

6.因果分析可被层次化表述为三个层次,即

关联;干预/介入;反事实

7.下图给出了不同变量之间的依赖关系,请写出因果图 $\mathcal{H}$ 中8个变量之间的联合概率形式,并区分哪些变量是内生变量、哪些变量是外生变量。



因果图 $\mathcal{H}$

解 使用乘积分解规则:

$$\begin{aligned} P(X_1, X_2, X_3, X_4, X_5, X_6, X_7, X_8) \\ = P(X_1) \times P(X_2 | X_4, X_5) \times P(X_3 | X_1) \times P(X_4 | X_1, X_3, X_5) \times P(X_5) \\ \times P(X_6 | X_3) \times P(X_7 | X_4, X_6, X_8) \times P(X_8 | X_5) \end{aligned}$$

外生变量: X_1, X_5 ; 内生变量: $X_2, X_3, X_4, X_6, X_7, X_8$

第三章 搜索求解

知识点

一些名词

状态	对智能体和环境当前情形的描述。例如，在最短路径问题中，城市可作为状态。将原问题对应的状态称为初始状态
动作	从当前时刻所处状态转移到下一时刻所处状态所进行操作。一般而言这些操作都是离散的
状态转移	对智能体选择了一个动作之后，其所处状态的相应变化
路径/代价	一个状态序列。该状态序列被一系列操作所连接。如从A到K所形成的路径
目标测试	评估当前状态是否为目标状态

搜索算法

集合 $\mathcal{F}$ 用于保存搜索树中可用于下一步探索的所有候选结点，这个集合叫作边缘集合，也叫作开表

函数：TreeSearch
输入：节点选择函数 pick_from，后继节点计算函数 successor_nodes
输出：从初始状态到终止状态的路径
<pre>1 $\mathcal{F} \leftarrow \{\text{根节点}\}$ 2 while $\mathcal{F} \neq \emptyset$ do 3 $n \leftarrow \text{pick_from}(\mathcal{F})$ 4 $\mathcal{F} \leftarrow \mathcal{F} - \{n\}$ 5 if goal_test(n) then 6 return $n.path$ 7 end 8 $\mathcal{F} \leftarrow \mathcal{F} \cup \text{successor_nodes}(n)$ 9 end</pre>

但是并不是所有的后继节点都值得被探索，所以我们需要再探索的过程中进行剪枝

函数：GraphSearch
输入：节点选择函数 pick_from，后继节点计算函数 successor_nodes
输出：从初始状态到终止状态的路径
<pre>1 $\mathcal{F} \leftarrow \{\text{根节点}\}$ 2 $\mathcal{C} \leftarrow \emptyset$ 3 while $\mathcal{F} \neq \emptyset$ do 4 $n \leftarrow \text{pick_from}(\mathcal{F})$ 5 $\mathcal{F} \leftarrow \mathcal{F} - \{n\}$ 6 if goal_test(n) then 7 return $n.path$ 8 end 9 if $n.state \notin \mathcal{C}$ then 10 $\mathcal{C} \leftarrow \mathcal{C} \cup \{n.state\}$ 11 $\mathcal{F} \leftarrow \mathcal{F} \cup \text{successor_nodes}(n)$ 12 end 13 end</pre>

上图就是图搜索，要求不能出现环


启发式搜索

分为贪婪最佳优先搜索和A*搜索

我们有两个函数来辅助我们进行搜索

辅助信息	所求解问题之外、与所求解 问题相关的特定信息或知识。	
评价函数 $f(n)$	从当前节点n出发，根据评价函数来选择后续结点。	下一个结点是谁？
启发函数 $h(n)$	从结点n到目标结点之间所形成路径的最小代价值，这里用两点之间的直线距离。	完成任务还需要多少代价？

在贪婪最佳优先搜索中，我们将评价函数定为启发函数，启发函数是由任意一个城市与终点城市K之间的直线距离



在A*搜索中，我们的评价函数是启发函数+开销函数

$f(n) = g(n) + h(n)$

$g(n)$ 表示从起始结点到结点n的开销代价值

$h(n)$ 表示从结点n到目标结点路径中所估算的最小开销代价值

$f(n)$ 可视为经过结点n、具有最小开销代价值的路径。

评价函数就是，起始结点到结点n代价(当前最小代价)加上结点n到目标结点代价(后续估计最小代价)

对抗搜索

也称为博弈搜索，就是在竞争的过程中，一方尽可能最大化利益，另一方尽可能的最小化利益

对抗搜索 { 最小最大搜索
Alpha - Beta剪枝搜索
蒙特卡洛树搜索


minimax搜索

就是双方都往不同的结果靠拢，而且必须是零和博弈，优点是双方都尽力的情况下，会获得最好的结果，缺点是时间复杂度太高，返回结果太慢，因此我们选择使用Alpha - Beta剪枝搜索来进行搜索

Alpha – Beta剪枝搜索

Alpha值(α)	MAX节点目前得到的最高收益
Beta值(β)	MIN节点目前可给对手的最小收益
α 和 β 的值初始化分别设置为 $-\infty$ 和 ∞	

给一个例子说明：



Alpha值(α)	玩家MAX(根节点)目前得到的最高收益
	假设 n 是MIN节点，如果 n 的一个后续节点可提供的收益小于 α ，则 n 及其后续节点可被剪枝
Beta值(β)	玩家MIN目前给对手的最小收益
	假设 n 是MAX节点，如果 n 的一个后续节点可获得收益大于 β ，则 n 及其后续节点可被剪枝
α 和 β 的值初始化分别设置为 $-\infty$ 和 ∞	

α 为可能解法的最小下界

β 为可能解法的最大上界

如果节点 N 是可能解法路径中的一个节点，则其产生的收益一定满足如下条件： $\alpha \leq \text{reward}(N) \leq \beta$ (其中 $\text{reward}(N)$ 是节点 N 产生的收益)

每个节点有两个值，分别是 α 和 β 。节点的 α 和 β 值在搜索过程中不断变化。其中， α 从负无穷大($-\infty$)逐渐增加、 β 从正无穷大(∞)逐渐减少。如果一个节点中 $\alpha > \beta$ ，则该节点的后续节点可剪枝。

修改方式： $\min$ 层改 β ， $\max$ 层改 α

当 $\alpha > \beta$ 的时候就剪枝 (注意等于号)


先传递到左子树，再返回父节点，然后再传递到右子树，再回溯就可以了

修改值的方法：

- 当在 $\max$ 层进行修改的时候，是取自己，下一层的 α 和 β 的最大值
- 当在 $\min$ 层进行修改的时候，是取自己，下一层的 α 和 β 的最小值

具体例子：见课本图3.16和图3.17

书本习题9(1):



学习网址: [最清晰易懂的MinMax算法和Alpha-Beta剪枝详解](#)

剪枝本身不影响算法输出结果

节点先后次序会影响剪枝效率

如果节点次序“恰到好处”, Alpha - Beta剪枝的时间复杂度为 $O(b^{\frac{m}{2}})$, 最小最大搜索的时间复杂度为 $O(b^m)$

蒙特卡洛树搜索


悔值函数: $R_n = \max_{i=1, \dots, k} \sum_{t=1}^n X_{i,t} - \sum_{t=1}^n X_{I_t,t}$

$$UCB = \bar{X}_j + C \times \sqrt{\frac{2 \ln n}{n_j}}$$

C是一个平衡因子, 来决定算法中选择偏重探索还是利用

蒙特卡洛树的具体流程: 分为四个步骤, 分别是**选择**, **扩展**, **模拟**, **反向传播**

- 选择: 从根节点 R 开始, 递归选择子节点, 直至到达叶节点或到达具有还未被扩展过的子节点的节点 L 。具体来说, 通常用UCB1 (Upper Confidence Bound, 上限置信区间) 选择最具“潜力”的后续节点
- 扩展: 如果 L 不是一个终止节点, 则随机创建其后的一个未被访问节点, 选择该节点作为后续子节点 C 。
- 模拟: 从节点 C 出发, 对游戏进行模拟, 直到博弈游戏结束。
- 反向传播: 用模拟所得结果来回溯更新导致这个结果的每个节点中获胜次数和访问次数。



记录 A/B : A 代表黑棋胜利数, B 代表白棋胜利数

假设黑棋先手, 则:

左1: 7/10对应

$$\frac{7}{10} + \sqrt{\frac{\log(21)}{10}} = 1.252$$

左2, 5/8对应

$$\frac{5}{8} + \sqrt{\frac{\log(21)}{8}} = 1.243$$

左3, 0/3对应

$$\frac{0}{3} + \sqrt{\frac{\log(21)}{3}} = 1.007$$

黑棋会选择局面7/10

然后就是白棋落子, 注意公式的第一部分需要用1去减掉原来的值, 再做加法

左1, 2/4对应

$$\frac{2}{4} + \sqrt{\frac{\log(10)}{4}} = 1.26$$

左2, 5/6对应

,

$$\frac{1}{6} + \sqrt{\frac{\log(10)}{6}} = 0.786$$

白棋会选择局面2/4

就这样一直往下遍历, 直到最底部, 黑棋选择1/1, 我们需要对其进行扩展

随机扩展一个新节点, 初始化为0/0, 在该节点下进行模拟

假设经过一系列仿真行棋后, 最终白棋获胜。该新节点的A/B值被更新为0/1, 并向上回溯, 所有父辈节点的A不变, B加1

这样我们就完成了蒙特卡洛树的四个步骤: 选择, 扩展, 模拟, 反向传播

习题

1.假如可以对围棋的规则做出如下修改,其中哪个修改方案不影响使用本章介绍的 $Minimax$ 算法求解该问题?()

A.由双方轮流落子,改为黑方连落两子后白方落一子

B.双方互相不知道对方落子的位置

C.由两人对弈改为三人对弈


D.终局时黑方所占的每目(即每个交叉点)计1分,且事先给定了白方在棋盘上每个位置取得一目所获取的分数,假设这些分数各不相同。双方都以取得最高得分为目标

2.考虑图中的问题, 给定每个状态的启发函数如下表所示。若仍以状态A为初始状态、状态I为终止状态, 请分别使用以下算法求解从A到I的路径, 请画出算法找到第一条路径时的搜索树, 并在搜索书中标出结点的扩展顺序, 以及找到的路径。(若有多个节点拥有相同的扩展优先度, 则优先扩展对应路径字典序较小的节点)。


(1) 基于树搜索的贪婪最佳优先搜索。

(2) 基于图搜索的A*算法。


状态	A	B	C	D	E	F	G	H	I
启发函数	5	4	3	2	5	5	2	1	0



(1)



(2)



3. 下列关于探索与利用的说法中,不正确的是()
- A. 在多臂赌博机问题中,过度探索会导致算法很少主动去选择比较好的摇臂
 - B. 在多臂赌博机问题中,过度利用可能导致算法对部分臂膀额奖励期望估计不准确
 - C. 在 ϵ 贪心算法中, ϵ 的值越大,表示算法越倾向于探索
 - D. 在多臂赌博机问题中,某时刻 $UCB1$ 算法选择的臂膀置信上界为 R ,则此时任意摇动一个臂膀,得到的硬币数量不会超过 R
4. 下列关于蒙特卡洛树搜索算法的说法中,不正确的是()

A.选择过程体现了探索与利用的平衡

B.算法进入扩展步骤时,当前节点的所有子节点必然都未被扩展

C.模拟步骤采取的策略与选择步骤不一定要相同


D.反向传播只需要更新当前路径上已被扩展的节点

5.下图展示了一个蒙特卡洛树搜索的例子。其中每个叶子节点（终止节点）下标出了该节点对应的奖励。为了最大化取得的奖励，可利用蒙特卡洛树搜索求解奖励最大的路径。假设执行了若干步骤后，算法的状态如图3所示，节点内的数字分别表示“总奖励/访问次数”，虚线节点表示尚未扩展的节点。算法此时正要开始新一轮选择-扩展-模拟-反向传播的迭代

(1)假设UCB1算法中的超参数 $c = 1$ ，请计算并画出算法选择过程经过的路径。

(2)请继续执行扩展、模拟、反向传播步骤，并画出完成后的搜索树状态。（为了避免随机性，假设扩展总是扩展最左侧的未扩展节点，模拟总是选择最左侧的路径。）

(3)尝试进行若干次迭代，请问此时算法是否能有效地找到奖励最大的叶子结点（奖励为9），那么进行足够多次迭代以后又如何？如果希望提高算法的效率，应该做出怎样的调整？




一棵蒙特卡洛树搜索的搜索树。


解答：

答案：

(1) 第一步三个节点的 UCB 值从左到右分别为 $\frac{1}{1} + \sqrt{\frac{2\ln 7}{1}} = 2.97$, $\frac{21}{4} + \sqrt{\frac{2\ln 7}{4}} = 6.24$, $\frac{7}{2} + \sqrt{\frac{2\ln 7}{2}} = 4.89$ ，因此第一步选择第二层中间的节点。第二步三个节点的 UCB 值从左到右分别为 $\frac{6}{1} + \sqrt{\frac{2\ln 4}{1}} = 7.67$, $\frac{2}{1} + \sqrt{\frac{2\ln 4}{1}} = 3.67$, $\frac{7}{1} + \sqrt{\frac{2\ln 4}{1}} = 8.67$ ，因此第二步选择奖励为 7 的节点。如下图所示。



(2) 由于此时已经到达叶子节点，因此不需要进行扩展和模拟过程，反向传播后结果如下图所示



(3) 算法在很长一段时间内都会选择奖励为 7 的节点，而不会探索奖励为 9 的节点。当实验次数足够多时，第二层左侧的节点的 UCB 值最终会超过第二层中间节点的 UCB 值，因此只要实验次数足够多，算法是有可能探索到奖励为 9 的节点的。如果希望提高算法的效率，可考虑加大探索的力度，即取一个更大的超参数 C 。不难验证，在原题中的状态下，取 $C = 10$ 即可令算法选择第二层左侧的节点。

第四章 监督学习

知识点

机器学习基本概念

图像数据→类别分类，文本数据→情感分类

机器学习的三种类型：监督学习，无监督学习和强化学习，其中**监督学习**和**无监督学习**合起来叫作**半监督学习**

监督学习就是提供了对应的 $label$ ，无监督学习就是不提供对应的 $label$ ，强化学习就是在环境交互中进行学习

监督学习的几个重要因素：标注数据——学什么，学习模型——怎么学，损失函数——学到了吗？

损失函数：

我们的训练集共有 n 组训练数据，分别是 (x_i, y_i) ，就是我们根据我们的映射函数 $f(x_i)$ ，我们去与我们的 y_i 进行对比，找出中间的差值，这样就是我们的损失函数。

损失函数最小化——

$$\min \sum_{i=1}^n Loss(f(x_i), y_i)$$

常见的损失函数：

0 - 1 损失函数：

$$Loss(y_i, f(x_i)) = \begin{cases} 1, & f(x_i) \neq y_i \\ 0, & f(x_i) = y_i \end{cases}$$

平方损失函数：

$$Loss(y_i, f(x_i)) = (y_i - f(x_i))^2$$

绝对损失函数：

$$Loss(y_i, f(x_i)) = |y_i - f(x_i)|$$

对数损失函数：

$$Loss(y_i, P(y_i|x_i)) = -\log P(y_i|x_i)$$

我们的机器学习的训练过程，就是先训练数据集，得到映射函数 f ，然后我们通过在测试数据集上测试我们的映射函数，得到一个较好的结果后，我们再将其运用于我们的未知的数据集上

对应着有两种风险：

- 一个是**经验风险**，就是训练集中数据产生的损失。经验风险越小说明学习模型对训练数据拟合程度越好
- 一个是**期望风险**，当测试集中存在无穷多数据时产生的损失。期望风险越小，学习所得模型越好

我们的映射函数的训练目标就是让经验风险最小化，如下所示：

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n Loss(y_i, f(x_i))$$

还需要让期望风险也最小化，如下所示：

$$\min_{f \in \Phi} \int_{x,y} Loss(y, f(x)) P(x, y) dx dy$$

训练集上表现	测试集上表现	
经验风险小	期望风险小	泛化能力强
经验风险小	期望风险大	过学习（模型过于复杂）
经验风险大	期望风险大	欠学习
经验风险大	期望风险小	“神仙算法”或“黄粱美梦”


为了防止过拟合，让结构风险最小，我们在经验风险中加上惩罚项，在最小化经验风险与降低模型复杂度之间寻找平衡

$$\min_{f \in \Phi} \frac{1}{n} \sum_{i=1}^n Loss(y_i, f(x_i)) + \lambda J(f)$$

生成模型与判别模型

监督学习方法又可以分为生成方法和判别方法，所学到的模型分别称为生成模型和判别模型

判别模型：判别方法直接学习判别函数 $f(X)$ 或者条件概率分布 $P(Y|X)$ 作为预测的模型，即判别模型。判别模型关心在给定输入数据下，预测该数据的**输出**是什么。比如说下面的：输入一张图片，我们将其判别为人脸



生成模型：生成模型从数据中学习联合概率分布 $P(X, Y)$ （通过似然概率 $P(X|Y)$ 和类概率 $P(Y)$ 的乘积来求取）

$P(Y|X) = \frac{P(X,Y)}{P(X)}$ 或者 $P(Y|X) = \frac{P(X|Y) \times P(Y)}{P(X)}$ ，比如说下面的：我们目的是去计算这张照片为人脸的条件概率，而不是去识别

$$P(\text{人脸} | \text{人脸图片}) = 0.99$$

回归分析

一元线性回归

回归模型: $y = a + bx$

我们有两个未知量, 一个是 x , 一个是 y , 我们需要去找到这两个未知数之间的关系, 用线性去表示出来

我们在求解的过程当中, 会产生一定的误差, 为 $L(a, b) = \sum_{i=1}^n (y_i - a \times x_i - b)^2$

我们可以利用最小二乘法来解出我们误差最小的情况:

$$a = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i x_i - n \bar{x}^2}$$
$$b = \bar{y} - a \bar{x}$$

以上就是我们的一元回归的两个参数的求解过程

多元线性回归

回归模型: $f(\mathbf{x}_i) = a_0 + \sum_{j=1}^D a_j x_{i,j} = a_0 + \mathbf{a}^T \mathbf{x}_i$

其中 $\mathbf{x}_i$ 代表了多元的变量, 是一个矩阵, 矩阵的行数代表了其变量的个数

均方误差函数: $J_m = \frac{1}{m} \sum_{i=1}^m (y_i - f(\mathbf{x}_i))^2$

$$J_m(\mathbf{a}) = (\mathbf{y} - \mathbf{X}^T \mathbf{a})^T (\mathbf{y} - \mathbf{X}^T \mathbf{a})$$

最后的求解公式: $\mathbf{a} = (\mathbf{X} \mathbf{X}^T)^{-1} \mathbf{X} \mathbf{y}$

逻辑斯蒂回归

在回归函数中引入 $sigmoid$ 函数, 是一种非线性回归模型, 如下表示:

$$y = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

其中 $y \in (0, 1)$, $z = \mathbf{w}^T \mathbf{x} + b$, 其中的 $\frac{1}{1+e^{-z}}$ 是 $sigmoid$ 函数

为什么要使用逻辑斯蒂回归?


$$\text{logit}(p(y = 1|\mathbf{x})) = \log \left(\frac{p(y = 1|\mathbf{x})}{p(y = 0|\mathbf{x})} \right) = \log \left(\frac{p}{1-p} \right) = \mathbf{w}^T \mathbf{x} + b$$

虽然我们的激活函数是非线性的, 但是我们经过对数运算之后, 结果居然变成了线性模型

而且, 在预测时, 可以计算线性函数 $\mathbf{w}^T \mathbf{x} + b$ 取值是否大于0来判断输入数据 x 的类别归属, 这样我们就变成了一个线性的模型!

决策树

大致原理: 在分支处做判断, 做出我们的决策



在决策树中起到关键作用的就是**信息熵**(*entropy*)了

假设有 K 个信息，其组成了集合样本 D ，记第 k 个信息发生的概率为 $p_k (1 \leq k \leq K)$ 。如下定义这 K 个信息的信息熵：


$$E(D) = - \sum_{k=1}^K p_k \log_2 p_k$$

这个值越小，说明我们的**信息越确定，纯度越高**

对照着上面的图，流程大概是：计算出按照每一类别进行分类产生的信息熵，然后看哪个最大，就按照哪个特征进行区分

线性区别分析(LDA)

用于降维，利用类别信息，将高维数据样本线性投影到低维空间



我们可以做到类内方差小，类间间隔大，也就是做到一个良好的分离性能

两个散度矩阵(二分类)：

类内散度矩阵

$$S_W = \Sigma_1 + \Sigma_2$$

类间散度矩阵

$$S_b = (m_2 - m_1)(m_2 - m_1)^T$$

如何求解？

最大化目标：我们要使我们的 $J(w)$ 函数值最大，也就是最大化分子，最小化分母

$$J(\mathbf{w}) = \frac{\|\mathbf{m}_2 - \mathbf{m}_1\|_2^2}{s_1 + s_2}$$

$$J(\mathbf{w}) = \frac{\|\mathbf{w}^T(\mathbf{m}_2 - \mathbf{m}_1)\|_2^2}{\mathbf{w}^T \Sigma_1 \mathbf{w} + \mathbf{w}^T \Sigma_2 \mathbf{w}} = \frac{\mathbf{w}^T(\mathbf{m}_2 - \mathbf{m}_1)(\mathbf{m}_2 - \mathbf{m}_1)^T \mathbf{w}}{\mathbf{w}^T(\Sigma_1 + \Sigma_2)\mathbf{w}} = \frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$$

我们需要对其进行求解最大值，我们令分母 $\mathbf{w}^T \mathbf{S}_w \mathbf{w}$ 为1，然后用拉格朗日乘子法去求解

$$L(\mathbf{w}) = \mathbf{w}^T \mathbf{S}_b \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{S}_w \mathbf{w} - 1)$$

我们对 $\mathbf{w}$ 求偏导，令其等于0，得到： $\mathbf{S}_W^{-1} \mathbf{S}_b \mathbf{w} = \lambda \mathbf{w}$

最后求解得： $\mathbf{w} = \mathbf{S}_W^{-1}(\mathbf{m}_2 - \mathbf{m}_1)$

多分类问题(了解即可):

类内散度矩阵

$$\mathbf{S}_W = \sum_{i=1}^K \Sigma_i, \text{其中} \Sigma_i = \sum_{\mathbf{x} \in \text{class } i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T$$

类间散度矩阵

$$\mathbf{S}_b = \sum_{i=1}^K \frac{N_i}{N} (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T$$

求解过程与二分类相似，我们需要做的是将每一个 $\frac{\mathbf{w}_i^T \mathbf{S}_b \mathbf{w}_i}{\mathbf{w}_i^T \mathbf{S}_w \mathbf{w}_i}$ 都使其取值最大，也就是说，每一个 $\mathbf{w}_i$ 都是 $\mathbf{S}_w^{-1} \mathbf{S}_b \mathbf{W} = \lambda \mathbf{W}$ 的一个解

线性判别分析的降维步骤:

1. 计算数据样本集中每个类别样本的均值
2. 计算类内散度矩阵 $\mathbf{S}_w$ 和类间散度矩阵 $\mathbf{S}_b$
3. 根据 $\mathbf{S}_w^{-1} \mathbf{S}_b \mathbf{W} = \lambda \mathbf{W}$ 来求解 $\mathbf{S}_w^{-1} \mathbf{S}_b$ 所对应前 r 个最大特征值所对应特征向量 $(w_1, w_2, \dots, w_r)$ ，构成矩阵 $\mathbf{W}$
4. 通过矩阵 $\mathbf{W}$ 将每个样本映射到低维空间，实现特征降维

Ada Boosting

若一个分类器只能完成整体任务的一小部分，那么我们就称为弱分类器；我们将多个弱分类器结合在一起，就成为了强分类器。弱分类器指的是那些分类准确率低于50%的算法。

强可学习：学习模型能够以较高精度对绝大多数样本完成识别分类任务

弱可学习：学习模型仅能完成若干部分样本识别与分类，其精度略高于随机猜测

如果已经发现了“弱学习算法”，可将其提升 (boosting) 为“强学习算法”

两个核心问题：

- 在每个弱分类器学习过程中，如何改变训练数据的**权重**
- 如何将一系列弱分类器组合成强分类器

*Ada Boosting*训练过程

给定包含 N 个标注数据的训练集合 $\Gamma = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, $\mathbf{x}_i (1 \leq i \leq N) \in X \subseteq R^n, y_i \in Y = -1, 1$

1. 初始化每个训练样本的权重 $D_1 = (w_{11}, \dots, w_{1N})$, 其中 $w_{1i} = \frac{1}{N} (1 \leq i \leq N)$
2. 迭代地利用加权样本训练弱分类器并增加错分类样本权重
 - 分别计算每个弱分类器的分类误差, 对于第 m 个弱分类器的误差计算如下, 其中 $I(\cdot)$ 为示性函数

$$err_m = \sum_{i=1}^N w_{mi} I(G_m(x_i) \neq y_i)$$

其实就是把该分类器分类不正确的样本权重求和

- 选择 err 最低的分类器 $G_m(x)$
 - 计算弱分类器 $G_m(x)$ 权重: $\alpha_m = \frac{1}{2} \ln \frac{(1-err_m)}{err_m}$
 - 更新样本的分布权重, 其中分类正确的样本 i 权重更新为 $\frac{1}{2(1-err_m)} \times w_i$, 分类错误的样本 i 权重更新为 $\frac{1}{2err_m} \times w_i$
 - 重新计算每个弱分类器的分类误差, 重复上述步骤
3. 以线性加权形式来组合弱分类器
 - 得到的强分类器 $G(x) = \text{sign}(\sum_{i=1}^M \alpha_m G_m(x))$


注意的是, 我们在训练新一轮前, 需要调整我们训练数据的权重

$$w_{m+1,i} = \begin{cases} \frac{w_{m,i}}{Z_m} e^{-\alpha_m}, & G_m(x_i) = y_i \\ \frac{w_{m,i}}{Z_m} e^{\alpha_m}, & G_m(x_i) \neq y_i \end{cases}$$

支持向量机

经验风险越小, 对数据的拟合程度越好, 但是一味的降低经验风险容易造成过学习的问题

所以我们通过降低结构化风险, 使其最小化的方法来解决我们的过学习问题



一个两类分类问题的最佳分类平面。图中存在多个可将样本分开的超平面。支持向量机学习算法会去寻找一个最佳超平面, 使得每个类别中距离超平面最近的样本点到超平面的最小距离最大。


支持向量机认为: 分类器对未知数据 (即测试数据) 进行分类时所产生的期望风险 (即真实风险) 不是由经验风险单独决定的, 而是由两部分组成

- 第一个就是我们的经验风险, 会造成过学习的问题
- 第二个是我们的置信风险, 和我们的支持向量机的训练模型有关

就是说, 我们需要先做到经验风险最小, 也就是说在训练集上的误差最小; 然后我们再做到结构风险最小化, 也就是说大间隔为宜

总体的公式是： $\max\{\min(\delta)\}$

我们做的就是，将样本从特征空间映射到高维，使其可分



上图我们就解决了原先的样本点不可分的问题，将其映射到高维，这样就可分了

但是随着高维的维数的增加，我们也会出现维数灾难和过拟合的情况

我们怎么解决将不可分转化为可分的呢？我们的映射函数使用了核函数 $\mathcal{K}(x_i, x_j) = \phi(x_i)^T \phi(x_j)$


常见的核函数	对应的表达式
线性	$x_i^T x_j$
多项式	$(\gamma x_i^T x_j + c)^n$
径向基函数	$e^{-\frac{\ x_i - x_j\ ^2}{2\sigma^2}}$
<i>Sigmoid</i>	$\tanh(x_i, x_j - \gamma)$

举个例子：

图中的特征映射采用了那种核函数？

- ☐ A 线性
- ☐ B 多项式
- ☒ C 径向基
- ☐ D Sigmoid

提交



线性	$x_i^T x_j$
多项式	$(\gamma x_i^T x_j + c)^n$
径向基	$e^{-\frac{\ x_i - x_j\ ^2}{2\sigma^2}}$
Sigmoid	$\tanh(x_i, x_j - \gamma)$

生成学习模型

判别式学习和生成式学习有什么区别？

- 判别式学习是，学习到具体的判别线；也就是说我们得到的应该是某一条线，该线左边就是类别1，右边就是类别2
- 生成式学习是，学到具体的曲线；也就是说我们无法得到具体的分类，只是有我们的曲线，相当于我们求解的是概率，而不是分类

生成学习方法从数据中学习联合概率分布 $P(X, C)$ ，然后求出条件概率分布 $P(C|X)$ 作为预测模型，即

$$P(\mathbf{x}, c_i) = \overbrace{P(\mathbf{x}|c_i)}^{\text{似然概率}} \times \overbrace{P(c_i)}^{\text{先验概率}}$$
$$\overbrace{P(c_i|\mathbf{x})}^{\text{后验概率}} = \frac{\overbrace{P(\mathbf{x}, c_i)}^{\text{联合概率}}}{P(\mathbf{x})} = \frac{\overbrace{P(\mathbf{x}|c_i)}^{\text{似然概率}} \times \overbrace{P(c_i)}^{\text{先验概率}}}{P(\mathbf{x})}$$

习题

1.请判断下面说法是否正确:线性判别分析是在最大化类间方差和类内方差的比值?

正确的，就是要最大化类间方差，最小化类内方差

2.在决策树建立过程中,使用一个属性对某个节点对应的数据集进行划分后,结果具有高信息熵(high entropy),对于结果的描述,最贴切的是()

A.纯度高 **B.纯度低** C.有用 D.没用

3.在一个监督学习任务中,每个数据样本有4个属性和一个类别标签,每种属性分别有3、2、2和2种可能的取值,类别标签有3种不同的取值。请问可能有多少种不同的样本?(注意,并不是在某个数据集中最多有多少种不同的样本,而是考虑所有可能的样本)

应该是 $3 \times 2 \times 2 \times 2 \times 3 = 72$

4.

4. 加入 L_2 标准化 (normalization) 后，对于包含参数 w 的线性回归损失函数的标准形式为：

$$L = (Y - Xw)^T(Y - Xw) + \lambda w^T w \quad \text{其中} \lambda > 0$$

(1) 假设 L_2 标准化项被误写为 $\lambda Y^T Y$ ，请解释为什么该项起不到标准化的作用。

(2) 在上述 L_2 标准化中，如果 λ 小于0，请解释为什么起不到标准化的作用。

(1)

该标准化项与参数 w 无关，该项对 w 的导数永远为0，对 w 的优化求解没有作用。

(2)

L_2 标准化项通过惩罚过大的参数 w 来避免过拟合， λ 小于0意味着该损失函数倾向于更大的 w ，从而激励过拟合，失去了标准化的作用。

5.关于支持向量机，哪一种选择能正确填充下面的说法？支持向量机是一种__模型，其目标是__分类间隔。

A.生成，最大化

B.生成，最小化

C.判别，最大化

D.判别，最小化

6.以下哪种方法不属于监督学习方法？

A.聚类

B.决策树

C.线性回归

D.朴素贝叶斯

E.支持向量机

F.以上都不属于监督学习方法

7.在Adaboosting的迭代中, 从第 t 轮到第 $t + 1$ 轮, 某个被错误分类样本的惩罚增加了, 可能因为该样本 ()

A.被第 t 轮训练的弱分类器错误分类

B.被第 t 轮后的集成分类器 (强分类器) 错误分类


C.被到第 t 轮为止训练的大多数弱分类器错误分类

D. B 和 C 都正确

E. A , B 和 C 都正确

8.

假设有两批从同样的真实数据分布中采样得到去完成同一任务的数据集A和B。A包含100K数据, B包含10K数据。按照9:1这一同样比例随机将A和B分别划分为训练集和测试集。图1给出了数据集A和数据集B随着模型复杂度增加所对应训练误差(A,Train以及B,Train)和测试误差(A,Test以及B,Test)的曲线图。请指出哪个图正确表示了随着模型复杂度增加所对应训练误差和测试误差的变化曲线图。



选A, 数据量小会导致过拟合, 错误率会相对低一点

9.

对于如下数据, 考虑使用Ada boosting方法来训练 “是否出去玩” 强分类器。每个弱分类器可考虑对单个属性的分类, 比如对于 “心情指数” 这一属性, 可考虑心情指数 >2 和心情指数 <4 两个方面。请问答下列问题:

- (1) Ada boosting在第一轮迭代中将会选择哪一个弱分类器?
- (2) 第一轮迭代前与迭代后每个样本的权重是多少?
- (3) 第二轮迭代选择的弱分类器是哪一个? 分类器权重是多少?
- (4) 写出三轮迭代后的强分类器的表达式 (每个弱分类器可用字母替代)

序号	出去玩	天气状况	有同伴	零花钱	特殊节日	心情指数 (1 差-5 好)
1	是	好	无	多	是	5
2	是	一般	有	多	是	5
3	是	一般	有	少	否	1
4	是	一般	有	少	否	3
5	是	一般	有	少	否	5
6	是	好	无	多	是	5
7	是	好	无	多	是	5
8	否	一般	无	多	是	1
9	否	一般	有	少	否	1
10	否	一般	无	少	否	5

H_1 : 天气 H_2 : 月份 H_3 : 战队 H_4 : 节目 H_5 : 心情

分类器	H_1 天气	H_2 月份	H_3 战队	H_4 节目	H_5 心情
err	$\frac{4}{10}$	$\frac{4}{10}$	$\frac{4}{10}$	$\frac{4}{10}$	$\frac{2}{10}$

2, 3, 4, 5 1, 6, 7, 9 3, 1, 5, 8 3, 4, 5, 8 3, 10

(1) 心情指数 > 2

(2) 前:

序号	1	2	3	4	5	6	7	8	9	10
权重	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$	$\frac{1}{10}$

$$\frac{1}{2(1-\text{err})} \times \frac{1}{10} = \frac{1}{16}$$

$$\frac{1}{2\text{err}} \times \frac{1}{10} = \frac{1}{4}$$

后:

序号	1	2	3	4	5	6	7	8	9	10
权重	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{4}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{4}$

$$\alpha_1 = \frac{1}{2} \ln \left(\frac{1-\text{err}}{\text{err}} \right) = \frac{1}{2} \ln \frac{0.8}{0.2} = \frac{1}{2} \ln 4$$

(3)

分类器	H_1	H_2	H_3	H_4	H_5
err	$\frac{7}{16}$	$\frac{4}{16}$	$\frac{7}{16}$	$\frac{7}{16}$	$\frac{1}{2}$

选择 H_2

$$\alpha_2 = \frac{1}{2} \ln \left(\frac{1-\frac{4}{16}}{\frac{4}{16}} \right) = \frac{1}{2} \ln 3$$

$$\frac{1}{2(1-\frac{1}{2})} = \frac{2}{1} = 2$$

(4)

序号	1	2	3	4	5	6	7	8	9	10
权重	$\frac{1}{8}$	$\frac{1}{24}$	$\frac{1}{6}$	$\frac{1}{24}$	$\frac{1}{24}$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{24}$	$\frac{1}{8}$	$\frac{1}{6}$

分类器	H_1	H_2	H_3	H_4	H_5
err	$\frac{7}{24}$	$\frac{1}{2}$	$\frac{7}{24}$	$\frac{7}{24}$	$\frac{1}{3}$

$$\text{选择 } H_1, \alpha_3 = \frac{1}{2} \ln \left(\frac{1-\frac{7}{24}}{\frac{7}{24}} \right) = \frac{1}{2} \ln \frac{17}{7}$$


$$\text{表达式为 } \text{sign} \left(\frac{1}{2} \ln 4 H_5 + \frac{1}{2} \ln 3 H_2 + \frac{1}{2} \ln \frac{17}{7} H_3 \right)$$

第五章 无监督学习


知识点

无监督学习，就是不给 $label$ 的值，只分类，但是我们不知道其具体的语义

监督学习的特征：



无监督学习的特征：



可以看出我们的监督学习是对我们的数据进行了分类，并且能够得知其类别；无监督学习只能起到**分类的作用**

我们的无监督学习有自己的相似度函数，比如说对上面的六个东西进行分类，我们根据颜色和形状，分类出来的结果是不一样的

K均值聚类(K-Means)

算法原理

输入： n 个数据，并且没有任何的标注

输出： k 个聚类结果

我们的目标是，将 n 个 d 维的数据分为 K 个聚簇，使得簇内方差最小化

两个 m 维数据之间的欧氏距离为

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_{i1} - \mathbf{x}_{j1})^2 + (\mathbf{x}_{i2} - \mathbf{x}_{j2})^2 + \cdots + (\mathbf{x}_{im} - \mathbf{x}_{jm})^2}$$

我们的欧氏距离越小，就说明我们类内越相似，反之欧氏距离越大就是类内越不相似

K-means聚类算法步骤

1. 初始化聚类质心
 - 初始化 k 个聚类质心 $c = \{c_1, c_2, \dots, c_k\}$, $c_j \in R^m (1 \leq j \leq k)$
 - 每个聚类质心 c_j 所在集合记为 G_j
2. 将每个待聚类数据放入唯一一个聚类集合中
 - 计算待聚类数据 x_i 和质心 c_j 之间的欧氏距离 $d(x_i, c_j) (1 \leq i \leq n, 1 \leq j \leq k)$
 - 将每个 x_i 放入与之距离最近聚类质心所在聚类集合中，即 $\arg\min_{c_j \in C} d(x_i, c_j)$
3. 根据聚类结果，更新聚类质心

- 根据每个聚类集合中所包含的数据，更新该聚类集合质心值，即： $c_j = \frac{1}{|G_j|} \sum_{x_i \in G_j} x_i$

4. 算法循环迭代，直到满足条件

- 循环2、3步骤
- 终止条件：**达到迭代次数上限，或者前后两次迭代中，聚类质心基本保持不变**

聚类算法的缺点

- 需要事先确定聚类数目
- 需要初始化聚类中心，而且会对结果产生很大的影响
- 算法是迭代执行，时间开销非常大
- 欧式距离假设数据每个维度之间的重要性是一样的

K均值聚类算法的应用：图像压缩，文本分类等

主成分分析(PCA)

是一种特征降维的方法，我们在过程中会将其化繁为简，降低我们的特征维数

方差

方差等于各个数据与样本均值之差的平方之和之平均数

方差描述了样本数据的波动程度

$$\text{Var}(X) = \frac{1}{n-1} \sum_{i=1}^n (x_i - u)^2$$

其中 u 是我们的样本均值

$$u = \frac{1}{n} \sum_{i=1}^n x_i$$

协方差

$$\text{cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - E(X))(y_i - E(Y))$$

我们用协方差来衡量两个变量之间的关系

- 当协方差 $\text{cov}(X, Y) > 0$ 时，称 X 与 Y 正相关
- 当协方差 $\text{cov}(X, Y) < 0$ 时，称 X 与 Y 负相关
- 当协方差 $\text{cov}(X, Y) = 0$ 时，称 X 与 Y 不相关（线性意义下）

为了归一化处理，我们采用了皮尔逊相关系数来对其进行约束

$$\text{corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y}$$

皮尔逊相关系数的性质如下：

- $|\text{corr}(X, Y)| \leq 1$
- $|\text{corr}(X, Y)|$ 越大，线性相关度越大
- $\text{corr}(X, Y) = 1$ 的充要条件是存在常数 a 和 b ，使得 $Y = aX + b$

- $|corr(X, Y)| = 0$ 表示两者不存在线性相关关系（可能存在其他非线性相关的关系）
- $corr(X, Y) = corr(Y, X)$
- 正线性相关意味着变量 X 增加的情况下，变量 Y 也随之增加；负线性相关意味着变量 X 减少的情况下，变量 Y 随之增加。

相关性与独立性：

- 如果 X 和 Y 的线性不相关，则 $|corr(X, Y)| = 0$
- 如果 X 和 Y 的彼此独立，则一定 $|corr(X, Y)| = 0$ ，且 X 和 Y 不存在任何线性或非线性关系

在降维之中，需要尽可能将数据向方差最大方向进行投影，使得数据所蕴含信息没有丢失，彰显个性

我们需要保证我们投影后，得到的样本方差最大，这样就不会丢失其中的信息

假设我们有 n 个 d 维的样本数据，构成集合 $D = \{x_1, x_2, \dots, x_n\}$

所以我们的集合 D 可以表示成一个 $n \times d$ 的矩阵 X

我们使用一个映射矩阵 $W \in \mathbb{R}^{d \times l}$

所以我们的给定的样本可以通过映射矩阵进行降维，从 l 维降到了 d 维

$$Y = XW$$

$$\begin{aligned} var(Y) &= \frac{1}{n-1} tr(Y^T Y) \\ &= trace(W^T \frac{1}{n-1} X^T X W) \end{aligned}$$

我们用拉格朗日来进行求解

目标函数：

$$\max_W tr(W^T \Sigma W)$$

约束条件：

$$w_i^T w_i = 1 \quad i \in \{1, 2, \dots, l\}$$

拉格朗日函数：

$$L(W, \lambda) = tr(W^T \Sigma W) - \sum_{i=1}^l \lambda_i (w_i^T w_i - 1)$$

得到结果：

$$\Sigma w_i = \lambda_i w_i$$

算法描述：

- 输入： n 个 d 维样本数据所构成的矩阵 X ，降维后的维数 l
- 输出：映射矩阵 $W = \{w_1, w_2, \dots, w_l\}$

步骤：

1. 对于每个样本数据 x_i 进行中心化处理： $x_i = x_i - \mu, \mu = \frac{1}{n} \sum_{j=1}^n x_j$
2. 计算原始样本数据的协方差矩阵： $\Sigma = \frac{1}{n-1} X^T X$
3. 对协方差矩阵 Σ 进行特征值分解，对所得特征根按其值大到小排序 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_l$
4. 取前 l 个最大特征根所对应特征向量 $w_1, w_2, \dots, w_l$ 组成映射矩阵 W
5. 将每个样本数据 x_i 按照如下方法降维： $(x_i)_{1 \times d} (W)_{d \times l} = 1 \times l$

特征人脸方法

我们也是使用主成分分析的方法，来进行特征降维

算法步骤：


跟前面的主成分分析是一样的，降维就可以了

将每幅人脸图像转换成列向量，如将一幅 32×32 的人脸图像转换成 1024×1 的列向量

我们输入的是 1024×1 的列向量构成的矩阵，和我们降维之后的维数 l

输出是我们中间的映射矩阵 $W = \{w_1, w_2, \dots, w_l\}$

使用 l 个特征人脸的线性组合来表达原始人脸数据 x_i


$$x_i = \alpha_{i1} \times \text{face}_1 + \alpha_{i2} \times \text{face}_2 + \dots + \alpha_{il} \times \text{face}_l$$

期望最大化算法(EM)

分为两个步骤，第一个是求取期望，第二个是期望最大化

- 在 EM 算法的 E 步骤时，先假设模型参数的初始值，估计隐变量取值；
- 在 EM 算法的 M 步骤时，基于观测数据、模型参数和隐变量取值一起来最大化“拟合”数据，更新模型参数。
- 基于所更新的模型参数，得到新的隐变量取值（ EM 算法的 E 步），然后继续极大化“拟合”数据，更新模型参数（ EM 算法的 M 步）。以此类推迭代，直到算法收敛，得到合适的模型参数。

具体例子见：书本182页5.5.1：二硬币投掷例子

习题

1. 可以从最小化每个类簇的方差这一视角来解释 K 均值聚类的结果,下面对这一视角描述不正确的是()

- A. 最终聚类结果中每个聚类集合中所包含数据呈现出来差异性最小
- B. 每个样本数据分别归属于与其距离最近的聚类质心所在聚类集合
- C. 每个簇类的方差累加起来最小
- D. 每个簇类的质心累加起来最小**

2. 下面对相关性和独立性描述不正确的是()

- A. 如果两维变量线性不相关,则皮尔逊相关系数等于0
- B. 如果两维变量彼此独立,则皮尔逊相关系数等于0
- C. “不相关”是一个比“独立”要强的概念,即不相关一定相互独立**
- D. 独立指两个变量彼此之间不相互影响

3. 下面对主成分分析的描述不正确的是()

- A. 主成分分析是一种特征降维方法
- B. 主成分分析可保证原始高维样本数据被投影映射后,其方差保持最大
- C. 在主成分分析中,将数据向方差最大方向进行投影,可使得数据所蕴含信息没有丢失,以便在后续处理过程中各个数据“彰显个性”

D.在主成分分析中,所得低维数据中每一维度之间具有极大相关度

4.下面对特征人脸算法描述不正确的是()

A.特征人脸方法是一种应用主成分分析来实现人脸图像降维的方法

B.特征人脸方法是用一种称为“特征人脸(*eigenface*)”的特征向量按照线性组合形式来表达每一张原始人脸图像

C.每一个特征人脸的维数与原始人脸图像的维数一样大

D.特征人脸之间的相关度要尽可能大

第六章 深度学习

知识点


前馈神经网络

神经元

深度学习和机器学习的区别？一个是浅层的学习，一个是端对端学习


我们输入一个需要学习的对象，然后经过我们的端对端学习（一般是卷积等方法进行特征化学习），然后最后输出我们的视觉对象

神经元：有两种形态，一种是抑制状态，一种是激活状态，只有在超过了一定的阈值之后，我们的神经元才会被激活，并且向其他的神经元传递信息，下图就是一个简单的神经元传递的模型：



使用函数 $\Phi(\cdot)$ 将加权累加结果映射为0或1，以完成两类分类的任务：中间利用我们的线性加权求和，来计算出一个值，将我们的结果通过神经元函数来进行映射，映射为0或者1

神经元是深度学习的基本单位，一般结构如下所示：



一般来说，首先我们输入我们的信息，然后通过一定的权值进行累加，将我们的累加结果通过非线性变换，通过激活函数去映射到我们的结果上，我们的输出就是 $out = g(in)$

我们的神经元越多，就说明我们的非线性映射越复杂

神经网络使用非线性函数作为激活函数(activation function)，通过对多个非线性函数进行组合，来实现对输入信息的非线性变换

常用的激活函数

第一个就是我们的常见的 *Sigmoid* 函数，还有我们的 *tanh* 函数，*relu* 函数等等

Sigmoid 函数

$$f(x) = \frac{1}{1 + e^{-x}}$$

- 优点是：该函数的值域在 $(0, 1)$ 之间，输出的值可以看作是概率值；单调递增，对输入的值的的大小没有限制；非线性变化，在 x 的值在 0 附近的时候，我们的函数的值变化最大，反而在 x 取值很大或者很小的时候，我们的函数值变化不是很明显
- 缺点是：在导数接近 0 的时候，存在梯度消失的问题，并且随着网络深度的增加而变得越来越严重

tanh 函数

$$f(x) = \frac{2}{1 + e^{-2x}} - 1$$

在原点处的梯度更大，使用该函数更加容易收敛，也面临着梯度消失的问题

relu 函数


$$f(x) = \begin{cases} 0, & \text{for } x < 0 \\ x, & \text{for } x \geq 0 \end{cases}$$

也就是说，我们截取掉了负数部分的函数值，将其全部赋值为 0，这也是一种非线性的变化，可以解决一定的过拟合的问题

softmax 函数

一般用在多分类问题中，我们将输入的数据映射到 0 — 1 的范围内，公式如下：

$$y_i = \text{softmax}(x_i) = \frac{e^{x_i}}{\sum_{j=1}^k e^{x_j}}$$



损失函数

均方误差损失函数

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

该函数可以输出我们的均方误差

交叉熵损失函数


$$H(p, q) = - \sum_x p(x) \times \log q(x)$$

交叉熵越小，就说明我们两个概率分布越接近


一个良好的神经网络要尽量保证对于每一个输入数据，类别分布概率的预测值与实际值之间的差距越小越好

感知机

我们的前馈神经网络层间“全连接”，即两个相邻层之间的神经元完全成对连接，但层内的神经元不相互连接




我们的感知机是一种特殊的前馈神经网络，我们没有隐藏层，只有输入层和输出层；但是我们无法拟合过于复杂的数据



单层感知机

我们的单层感知机可以用来区分线性可分数据



比如说图中的前三个，都是线性可分的，所以我们可以通过我们的单层感知机去进行区分；但是第四个异或我们就不能通过单层感知机去进行区分了

多层感知机

我们可以利用我们的多层感知机去区分我们的线性不可分的数据，比如说上面的异或

多层感知机由**输入层、输出层和至少一层的隐藏层**构成

- 各个隐藏层中神经元可接收相邻前序隐藏层中所有神经元传递的信息，加工处理后输出给相邻后续隐藏层中所有神经元
- 各个神经元接受前一级的输入，并输出到下一级，模型中没有反馈
- 层与层之间通过“全连接”进行链接，即两个相邻层之间的神经元完全成对连接，但层内的神经元不相互连接

参数优化与学习

我们常见的方法就是：给定一个评分函数，或者说给出一个损失函数，损失函数的差距越小，就说明我们模型的鲁棒性就越好，常用的损失函数有 $softmax$ 和 SVM 等，我们优化的目标就是**使参数的损失越小，而且我们的参数不复杂**

我们还可以通过梯度下降的方法来进行参数的优化

$$\frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$


在多元函数中，梯度是对每一变量所求导数组成的向量；梯度的反方向是函数值下降最快的方向，因此是求解的方向

误差反向传播：

将误差从后向前传递，将误差分摊给各层所有单元，从而获得各层单元所产生的误差，进而依据这个误差来让各层单元负起各自责任、修正各单元参数


[误差传播具体的例子](#)

$$f(w, x) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2x_2)}}$$




就是通过从后往前的计算，将我们的偏导和误差乘在一起，传递给前面的误差部分，一直传到最前面就可以了

$$f(w, x) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2x_2)}}$$



前馈神经网络实例：



以这个为例，我们对其进行反向传播的梯度计算

以 h_1 和 h_2 为例，有如下函数关系

$$\begin{aligned}
In_{h_1} &= w_1 \times x_1 + w_3 \times x_2 \\
h_1 = Out_{h_1} &= Sigmoid(In_{h_1}) \\
In_{o_1} &= w_5 \times h_1 + w_7 \times h_2 \\
o_1 = Out_{o_1} &= Sigmoid(In_{o_1})
\end{aligned}$$

损失函数采取均方差误差，为

$$Error = \frac{1}{2} \sum_{i=1}^2 (o_i - y_i)^2$$

以 w_5 和 w_1 为例，计算梯度

在 w_5 中，由于 $Error$ 与 w_5 只通过 o_1 建立关系，所以可以得到

$$\delta_5 = \frac{\partial Error}{\partial w_5} = \frac{\partial Error}{\partial o_1} \times \frac{\partial o_1}{\partial In_{o_1}} \times \frac{\partial In_{o_1}}{\partial w_5}$$

其中第一项的值可以直接由 $Error$ 对 o_1 求偏导得到，第二项的值可以由Sigmoid函数的求导公式结合 o_1 的计算公式得到，注意这里第二项是 $o_1(1 - o_1)$ ，第三项可以由 In_{o_1} 的计算公式得到。于是计算上式

$$\delta = (o_1 - y_1) \times (o_1(1 - o_1)) \times h_1$$

在计算 w_1 时，由于 w_1 是 h_1 的参数，它通过 o_1 和 o_2 均与 $Error$ 建立起了联系，所以计算 w_1 的梯度要分成两部分之和，具体计算公式为

$$\begin{aligned}
\delta_1 &= \frac{\partial Error}{\partial w_1} = \frac{\partial Error}{\partial o_1} \times \frac{\partial o_1}{\partial w_1} + \frac{\partial Error}{\partial o_2} \times \frac{\partial o_2}{\partial w_1} \\
&= \frac{\partial Error}{\partial o_1} \times \frac{\partial o_1}{\partial In_{o_1}} \times \frac{\partial In_{o_1}}{\partial h_1} \times \frac{\partial h_1}{\partial In_{h_1}} \times \frac{\partial In_{h_1}}{\partial w_1} + \frac{\partial Error}{\partial o_2} \times \frac{\partial o_2}{\partial In_{o_2}} \times \frac{\partial In_{o_2}}{\partial h_1} \times \frac{\partial h_1}{\partial In_{h_1}} \times \frac{\partial In_{h_1}}{\partial w_1} \\
&= \left(\frac{\partial Error}{\partial o_1} \times \frac{\partial o_1}{\partial In_{o_1}} \times \frac{\partial In_{o_1}}{\partial h_1} + \frac{\partial Error}{\partial o_2} \times \frac{\partial o_2}{\partial In_{o_2}} \times \frac{\partial In_{o_2}}{\partial h_1} \right) \times \frac{\partial h_1}{\partial In_{h_1}} \times \frac{\partial In_{h_1}}{\partial w_1} \\
&= \left(\frac{\partial Error}{\partial o_1} \times \frac{\partial o_1}{\partial In_{o_1}} \times w_5 + \frac{\partial Error}{\partial o_2} \times \frac{\partial o_2}{\partial In_{o_2}} \times w_6 \right) \times \frac{\partial h_1}{\partial In_{h_1}} \times \frac{\partial In_{h_1}}{\partial w_1}
\end{aligned}$$

之后再继续计算其余偏导数即可。

最后需要对参数进行更新，其中 η 被称为学习率

$$w'_i = w_i - \eta \times \delta_i$$


卷积神经网络

主要结构

前馈神经网络中，输入层的输入直接与第一个隐藏层中所有神经元相互连接


这样所占用的内存很大，所以我们采用卷积的方法，这样就可以学习到对应的知识，还能降低内存的消耗

7×7 大小的图像，通过 3×3 大小卷积矩阵以1的步长进行卷积操作，可得到 5×5 大小的卷积结果




如果我们将步长改为2的话，这样我们的输出卷积就变成了 3×3 的结果

有一张 $32 \times 32 \times 3(RGB)$ 的图像，使用 $5 \times 5 \times 3$ 的卷积核 W_1 ，步长为1对其进行卷积操作。卷积核 W_1 在原始图像上从左到右、从上到下进行计算，改变 5×5 子块区域中的中心像素点值，得到 28×28 的特征图 m_1




同理，我们继续对剩下的两个卷积核来进行卷积，也可以得到两个 28×28 的特征图，我们现在就得到了三个 28×28 的特征图

也就是说，我们几个卷积核，就会得到几张卷积图。卷积核的数量只会影响最后的卷积图的数量，而不会改变我们卷积得到的维度




再举一个例子：



这一个就是，先是通过6个卷积核，我们就会生成维度为6的特征图，同理后面的10也是一样的

池化操作

常见的操作有：**最大池化操作**；**平均池化操作**




最大池化就是，我们选取我们的卷积核内的最大值进行输出；平均池化就是，我们计算我们卷积核内的平均值进行输出

池化操作对卷积结果特征图进行约减，实现了下采样，同时保留了特征图中主要信息

对于输入的海量标注数据，通过多次迭代训练，卷积神经网络在若干次卷积操作、接着对卷积所得结果进行激活函数操作和池化操作下，最后通过全连接层来学习得到输入数据的特征表达，即**分布式向量表达**(*distributed vector representation*)

- 全连接层：将我们前面的特征图转化为向量
- 分类层：就是输出我们的识别分类的置信度值



Padding操作

我们通常使用这个方法，将我们的边缘的图层都填充为0，这样我们就可以学习到我们边缘的知识了，补充的大小就是根据我们的步长来定，比如说我们原来的图像是 $32 \times 32 \times 3$ ，采用 $5 \times 5 \times 3$ 的卷积核，然后步长为1，这样的话我们想要全部训练，就需要将原先的图像填充为 $36 \times 36 \times 3$ ，这样就可以全部训练到了！

神经网络正则化

缓解神经网络在训练过程中出现的过拟合问题，我们采用两个范数去约束他

- L_1 范数：数学表示为 $\|W\|_1 = \sum_{i=1}^N |w_i|$ ，指模型参数 W 中各个元素的绝对值之和。 L_1 范数也被称为“稀疏正则算子” (*Lasso regularization*)

- L_2 范数：数学表示为 $\|W\|_2 = \sqrt{\sum_{i=1}^N w_i^2}$ ，指模型参数 W 中各个元素平方和的开方。


L_1 范数会趋向于产生少量的特征，而其他的特征都是0，而 L_2 范数会选择更多的特征，这些特征都会接近于0

循环神经网络

Recurrent Neural Network, RNN

适用于处理处理序列数据（如文本句子、视频帧等）

对于序列数据，在 t 时刻循环神经网络单元会读取当前输入数据 x_t 和前一时刻输入数据 x_{t-1} 所对应的隐式编码结果 h_{t-1} ，一起生成 t 时刻的隐式编码结果 h_t 。接着将 h_t 后传



在处理数据过程中，构成了我们的循环体

$$h_t = \Phi(U \times x_t + W \times h_{t-1})$$

其中， $\Phi(\cdot)$ 是激活函数，中间的 U 和 W 是我们的模型参数

当前时刻的隐式编码输出 h_t 不仅仅与当前输入数据 x_t 相关，与网络已有的“记忆” h_{t-1} 也有着密不可分的联系

综合起来看，我们有以下的公式：

$$\begin{aligned} h_t &= \Phi(U \times x_t + W \times h_{t-1}) = \Phi(U \times x_t + W \times \Phi(U \times x_{t-1} + W \times h_{t-2})) \\ &= \Phi \left(U \times \underbrace{x_t}_{t \text{ 时刻输入}} + W \times \Phi \left(U \times \underbrace{x_{t-1}}_{t-1 \text{ 时刻输入}} + W \times \Phi \left(U \times \underbrace{x_{t-2}}_{t-2 \text{ 时刻输入}} + \dots \right) \right) \right) \end{aligned}$$

这样我们就完成了神经网络的记忆

可利用反向传播算法和梯度下降算法来训练参数，称为“沿时间反向传播算法(*backpropagation through time, BPTT*)”

由于RNN每个时刻都有一个输出，所以在计算循环神经网络的损失时，通常需要将所有时刻上的损失进行累加

这种训练方式被广泛运用于文本的训练，因为单词之间存在前后依赖，这种依赖会被有效利用起来，得到各自单词的隐式编码以及句子的向量表达

习题

1.下面对误差反向传播 (*error back propagation, BP*)描述不正确的是 ()

- A. BP算法是一种将输出层误差反向传播给隐藏层进行参数更新的方法
- B. BP算法将误差从后向前传递，获得各层单元所产生误差，进而依据这个误差来让各层单元修正各单元参数
- C. 对前馈神经网络而言，BP算法可调整相邻层神经元之间的连接权重大小
- D. 在BP算法中，每个神经元单元可包含不可偏导的映射函数

2.以下关于批量梯度下降和随机梯度下降的说明，哪个描述是不正确的？

A.在批量梯度下降和随机梯度下降中，为了最小化损失函数，通常使用循环迭代的方式不断更新模型参数；

B.在每次迭代中，随机梯度下降需要计算训练集所有样本的误差和，用于更新模型参数；

C.在每次迭代中，梯度下降使用所有数据或者部分训练数据，用于更新模型参数。

3.关于sigmoid激活函数，下列描述正确的是？

A.它是凸函数，凸函数无法解决非凸问题；

B.它可以有负值；

C.它无法配合交叉熵损失函数使用；

D.当输入值过大或者过小时，梯度趋近于0，容易造成梯度消失问题。

4.下面对前馈神经网络这种深度学习方法描述不正确的是（ ）

A.是一种端到端学习的方法

B.是一种监督学习的方法

C.实现了非线性映射

D.隐藏层数目大小对学习性能影响不大

5.请问深度学习和传统的机器学习有什么区别？从数据大小、硬件要求、特征构建和解决问题方式等方面出发。

- 数据：深度学习适合处理大数据，机器学习算法更适用于小数据；
- 硬件：深度学习由于巨大的计算量，需要大量计算资源，比如GPU，机器学习算法对计算资源的需求相对较低；
- 特征构建：深度学习试图从数据中学习特征，机器学习中许多特征都需要由行业专家确定，并手工构造；
- 解决问题方式：深度学习通常利用“端到端”的方式构建模型，机器学习通常将问题分为几个步骤，每个步骤逐一解决，然后将结果组合。

6.（1）请说明单层感知机为何无法模拟逻辑异或操作？（2）请设计一个前馈神经网络，用于拟合异或函数。

（1）根据图6.2可知，在异或操作中，点(0,0)与(1,1)为0，点(0,1)和(1,0)为1，由于感知机是线性分类器，无法构建超平面可以将这两类分开。

（2）输入层维度为2，用于接收两个操作数；至少有一层隐藏层，且隐藏层中的神经元需要包含非线性激活函数；输出层维度为1，用于输出结果。


7.在前馈神经网络中，所有的参数能否被初始化为0？如果不能，能否全部被初始化为其他相同的值？为什么？

不能初始化为0，也不能被同时初始化为其他相同的值。

如果参数被初始化为相同的值后，在误差反向传播过程中，同一层的神经元所接收到的误差都相同，更新后这些参数的值仍然相同。不管经过多少轮迭代，同一层神经元的输出保持相同，因此不同的神经元无法学习到不同特征的重要程度，失去了深度神经网络学习特征的能力。

8.

利用链式法则，求损失函数L对w6和w12的偏导数：



对 w_{12} 的偏导：

$$\delta_{12} = \frac{\partial L}{\partial \omega_{12}} = \frac{\partial L}{\partial \widehat{y_3}} \cdot \frac{\partial \widehat{y_3}}{\partial In O_3} \cdot \frac{\partial In O_3}{\partial \omega_{12}} = (\widehat{y_3} - y_3) \cdot \widehat{y_3} \cdot (1 - \widehat{y_3}) \cdot Out h_2$$

对 ω_6 的偏导:

$$\delta_6 = \frac{\partial L}{\partial \omega_6} = \frac{\partial L}{\partial \widehat{y_1}} \cdot \frac{\partial \widehat{y_1}}{\partial \omega_6} + \frac{\partial L}{\partial \widehat{y_2}} \cdot \frac{\partial \widehat{y_2}}{\partial \omega_6} + \frac{\partial L}{\partial \widehat{y_3}} \cdot \frac{\partial \widehat{y_3}}{\partial \omega_6}$$

计算, 得出结果:

$$\delta_6 = (\omega_{10} \cdot \frac{\partial \widehat{y_1}}{\partial In O_1} + \omega_{11} \cdot \frac{\partial \widehat{y_2}}{\partial In O_2} + \omega_{12} \cdot \frac{\partial \widehat{y_3}}{\partial In O_3}) \cdot \frac{\partial Out h_2}{\partial In h_2} \cdot \frac{\partial In h_2}{\partial \omega_6}$$

9. 你有一个 $7 \times 7 \times 8$ 的输入, 并使用“ $pad = 2$ ”进行填充, 填充后的尺寸是多少?

A. $9 \times 9 \times 10$

B. $11 \times 11 \times 8$

C. $9 \times 9 \times 8$

D. $11 \times 11 \times 10$

10. 假设你的输入是 100×100 彩色 (RGB) 图像, 并且你使用卷积层和100个过滤器, 每个过滤器都是 3×3 的大小, 请问这个隐藏层有多少个参数 (包括偏置参数)?

A. 901

B. 1000

C. 2700

D. 2800

11. 假设你的输入是一个 100×100 的彩色 (RGB) 图像, 而你并没有使用卷积神经网络。如果第一个隐藏层有100个神经元, 每个神经元与输入层进行全连接, 那么这个隐藏层有多少个参数 (包括偏置参数)?

A. 1000001

B. 1000100

C. 3000001

D. 3000100

12. 你有一个 $16 \times 16 \times 8$ 的输入, 并使用步幅为2、过滤器大小为2的最大化池, 请问输出是多少?

A. $7 \times 7 \times 8$

B. $8 \times 8 \times 8$

C. $16 \times 16 \times 4$

D. $16 \times 16 \times 8$

13. 你有一个 $31 \times 31 \times 16$ 的输入, 有16个过滤器进行卷积, 每个过滤器的大小为 5×5 , 步幅为1, 你想要使用“ $same$ ”的卷积方式, 请问 pad 的值是多少?


A. 1

B. 2

C. 3

D. 7

14. 给定输入信号和卷积核, 当步长为2时输出各个输出 h 的表达式为?



输入

卷积核



输出

步长为2，就是每次向下或者向右平移时移动两个单位。卷积操作就是将对应位置的像素值与卷积核对应位置的权重相乘再求和，所以计算结果为

$$\begin{aligned}
 h_1 &= w_1 \times a + w_2 \times b + w_3 \times c + w_4 \times f + w_5 \times g + w_6 \times h + w_7 \times k + w_8 \times l + w_9 \times m \\
 h_2 &= w_1 \times c + w_2 \times d + w_3 \times e + w_4 \times h + w_5 \times i + w_6 \times j + w_7 \times m + w_8 \times n + w_9 \times o \\
 h_3 &= w_1 \times k + w_2 \times l + w_3 \times m + w_4 \times p + w_5 \times q + w_6 \times r + w_7 \times u + w_8 \times v + w_9 \times w \\
 h_4 &= w_1 \times m + w_2 \times n + w_3 \times o + w_4 \times r + w_5 \times s + w_6 \times t + w_7 \times w + w_8 \times x + w_9 \times y
 \end{aligned}$$

现在这里的输入的大小为 5×5 ，如果这里的输入改成 $5 \times 5 \times 3$ ，卷积核的大小也需要改为 $3 \times 3 \times 3$ ，但是输出依旧是 2×2 ，这时的输出里的每一个结果就是需要将27个位置对应的数相乘再相加。如果需要得到多个输出，可以使用多个卷积核分别进行卷积操作，比如使用4个不同的卷积核，输出的大小就变为 $2 \times 2 \times 4$ 。

第七章 强化学习

知识点

强化学习问题定义


强化学习可以学习到最大化收益的模式

强化学习的一些概念：

智能主体：按照某种策略(*policy*)，根据当前的状态(*state*)选择合适的动作(*action*)

- 状态指的是智能主体对环境的一种解释
- 动作反映了智能主体对环境主观能动的影响，动作带来的收益称为奖励(*reward*)

环境：系统中除去智能主体以外的部分，向智能主体反馈状态和奖励，按照一定的规律发生变化



强化学习&监督学习&无监督学习

	有监督学习	无监督学习	强化学习
学习依据	基于监督信息	基于对数据结构的假设	基于评价(<i>evaluative</i>)

数据来源	有监督学习	无监督学习	在强化学习
决策过程	单步(one-shot)	无	序列(sequential)
学习目标	样本到语义标签的映射	同一类数据的分布模式	选择能够获取最大收益的状态到动作的映射

为了介绍接下来的内容，我们基于一个简单的例子来介绍相关的定义。

在一个 3×3 的网格中，假设有一个机器人位于 s_1 ，试图从 s_1 这一初始位置向 s_9 这一目标位置移动，假设机器人每一步只能向上或向右移动一个方格，到达目标位置 s_9 则会获得奖励且游戏终止，机器人在移动过程中如果越出方格则会被惩罚，并且游戏终止。那么，如何学习一种策略能够帮助机器人从 s_1 走到 s_9 ？

在这个问题中，智能主体为迷宫机器人，环境是 3×3 的网格，状态是机器人当前所处的方格，状态的取值范围为 $\{s_1, s_2, \dots, s_9, s_d\}$ ，其中 s_d 表示机器人出界的情况。机器人每次可采取的行动为向上或者向右移动一个方格，机器人所获得的奖励包括他到达 s_9 时的正奖励，以及越界时得到的负奖励（惩罚），到达其他状态时不被奖励也不被惩罚。

在这个例子中，我们可以采取随机过程机器人与环境之间的交互。

一个随机过程是一列随时间变化的随机变量。当时间是离散量时，一个随机过程可以表示为 $\{X_i\}_{i=0,1,2,\dots}$ ，这里的每一个 X_i 都是一个随机过程，这被称为离散随机过程。我们可以将这个问题视为一个马尔可夫性的离散随机过程，即满足

$$P(X_{t+1} = x_{t+1} | X_0 = x_0, X_1 = x_1, \dots, X_t = x_t) = p(X_{t+1} = x_{t+1} | X_t = x_t)$$

可以理解成 $t+1$ 时刻的状态只与 t 时刻的状态有关。

定义离散马尔可夫过程 $\{S_t\}_{t=0,1,2,\dots}$ ，由于其满足马尔可夫性，因此可以定义状态转移概率 $P(S_{t+1} | S_t)$ 。

我们将到达 s_9 时的奖励定为 1，出界时的惩罚值为 -1，其他情况下奖励值为 0。为了比较不同奖励机制的优劣，在每个时刻定义回报来反映该时刻可以得到的累加奖励：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

其中折扣因子 $\gamma \in [0, 1]$ ， $R_{t+k} (k > 0)$ 表示 $t+k$ 时刻获得的奖励。

于是，我们得到了马尔可夫奖励过程，其形式化的定义为 $MRP = (S, P, R, \gamma)$ 。这个模型虽然能够用奖励和回报来刻画智能体的目标，但是仍然不能体现机器人的能动性，缺乏让机器人与环境进行交互的手段。

我们引入动作集合 A ，在这个问题中 $S = \{\text{上}, \text{右}\}$ ，状态转移概率与动作有关因此将状态转移概率重新定义为 $P(S_{t+1} | S_t, a_t), a_t \in A$ 。奖励也有可能受到动作的影响，因此修改奖励函数为 S_t, a_t, S_{t+1} 。现在就可以通过 $MDP(S, A, P, R, \gamma)$ 来刻画马尔可夫决策过程。

马尔可夫过程中产生的状态序列称为轨迹，轨迹的长度可以是无限的，也可以是有终止状态的。有终止状态的问题叫做分段的，否则叫做持续的。分段问题中，一个从初始状态到终止状态的完整轨迹称为一个片段或回合。

接下来我们对强化问题下定义。首先定义如下函数

- **价值函数** $V: S \mapsto \mathbb{R}$ ，其中 $V_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$ ，即在第 t 步状态为 s 时，按照策略 π 行动后在未来所获得的反馈值的数学期望
- **动作-价值函数** $q: S \times A \mapsto \mathbb{R}$ ，其中 $q_\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$ 表示在第 t 步状态为 s 时，按照策略 π 采取动作 a 后，在未来所获得的反馈值的期望

至此，强化学习转化为一个策略问题：寻找一个最优策略 π^* ，对任意 $s \in S$ 使得 $V_{\pi^*}(s)$ 值最大。

最后我们介绍贝尔曼方程，也称动态规划方程。

- 价值函数的贝尔曼方程

$$V_\pi(s) = \mathbb{E}_{a \sim \pi(s, \cdot)} \mathbb{E}_{S' \sim P(\cdot | s, a)} [R(s, a, s') + \gamma V_\pi(s')]$$

- 动作-价值函数的贝尔曼方程

$$q_{\pi}(s, a) = \mathbb{E}_{S' \sim P(\cdot | s, a)}[R(s, a, s') + \gamma \mathbb{E}_{a' \sim \pi(s', \cdot)}[q_{\pi}(s', a')]]$$

价值函数的贝尔曼方程描述了当前状态价值函数和其后续状态价值函数之间的关系，即当前状态价值函数等于瞬时奖励的期望加上后续状态的(折扣)价值函数的期望。而动作-价值函数的贝尔曼方程描述了当前动作-价值函数和其后续动作-价值函数之间的关系，即当前状态下的动作-价值函数等于瞬时奖励的期望加上后续状态的(折扣)动作-价值函数的期望。

基于价值的强化学习

策略优化定理：给定任意状态 $s \in S$ ，如果两个策略 π 和 π' 满足如下条件：

$$q_{\pi}(s, \pi'(s)) \geq q_{\pi}(s, \pi(s))$$

那么对于任意状态 $s \in S$ ，有

$$V_{\pi'}(s) \geq V_{\pi}(s)$$

即策略 π' 不比策略 π 差。

下面介绍在状态集合有限前提下三种常见的策略评估方法，它们分别是基于动态规划的方法、基于蒙特卡洛采样的方法和时序差分法。

- 基于动态规划的方法：使用迭代的方法求解贝尔曼方程组

缺点：

- 智能主体需要实现知道状态转移概率
- 无法处理状态集合大小无限的情况

- 蒙特卡洛采样：选择不同的起始状态，按照当前策略 π 采样若干轨迹，记他们的集合为 D ，枚举 $s \in S$ 。计算 D 中 s 每次出现时对应的反馈 $G_1, G_2, \dots, G_k$ ， $V_{\pi}(s) \leftarrow \frac{1}{k} \sum_{i=1}^k G_i$

优点：

- 不必知道状态转移概率
- 容易扩展到无限状态集合的问题中

缺点：

- 状态集合比较大时，一个状态在轨迹可能非常稀疏，不利于估计期望
- 在实际问题中，最终反馈需要在终止状态才能知晓，导致反馈周期较长

- 时序差分法：通过采样 a 和 s' 来估计 $V_{\pi}(s)$ 的取值 $R(s, a, s') + \gamma V_{\pi}(s')$ ，并以 α 作为权重接受新的估计值，即把价值函数更新为 $V_{\pi}(s) + \alpha[R + \gamma V_{\pi}(s') - V_{\pi}(s)]$

Q学习算法：一种基于时序差分的算法。分为以下几个步骤：

1. 初始化 s 为初始状态
2. 比较动作-价值函数最优的动作，设为 a
3. 执行动作 a ，观察奖励 R 和下一个状态 s'
4. 更新 $q_{\pi}(s, a) \leftarrow q_{\pi}(s, a) + \alpha[R + \gamma \max_{a'} q_{\pi}(s', a') - q_{\pi}(s, a)]$
5. 更新状态 $s \leftarrow s'$ ，重复执行步骤2到5，直到 s 是终止状态（一个片段）
6. 重复执行步骤1到6，直到 q_{π} 收敛

这样的Q学习算法也会收敛到非最优策略，因为他选择下一步策略总是选择目前已知最优的策略（称为利用），缺乏探索性。

ϵ 贪心策略：以 $1 - \epsilon$ 的概率执行最优的下一步动作，以 ϵ 的概率随机选择下一步动作。

注意这时采样时策略为 ϵ 贪心策略，但是更新 $q_{\pi}(s, a)$ 是里面计算采用的依然是策略最优的操作。像这样更新时的目标策略与采样策略不同的方法，叫做离策略方法。

将 q 函数参数化，用一个非线性回归模型来拟合 q 函数，例如（深度）神经网络，这使得算法称为深度 Q 学习，优点如下

- 能够用有限的参数刻画无限的状态
- 由于回归函数的连续性，没有探索过的状态也可通过周围的状态来估计

习题

第八章 博弈

知识点

博弈相关概念

玩家 (player)：参与博弈的决策主体

策略 (strategy)：玩家可以采取的行动方案，是一整套在采取行动之前就已经准备好的完整方案。

- 某个玩家可采纳策略的全体组合形成了策略集 (strategy set)
- 所有玩家各自采取行动后形成的状态被称为局势 (outcome)
- 混合策略 (mixed strategy): 玩家可通过一定概率来选择若干个不同的策略
- 纯策略 (pure strategy): 玩家每次行动都选择某个确定的策略

收益 (payoff)：各个玩家在不同局势下得到的利益

- 混合策略意义下的收益应为期望收益 (expected payoff)

规则 (rule)：对玩家行动的先后顺序、玩家获得信息多少等内容的规定

囚徒困境：警方逮捕了共同犯罪的甲和乙，但没有掌握充分证据，将他们分开审讯，并告诉他们如下事实：

- 若一人认罪并指证对方，而另一方保持沉默，则此人会被当即释放，沉默者会被判监禁10年
- 若两人都沉默，则根据已有的犯罪证据两人各判半年
- 若两人都认罪并相互指证，则两人各判5年

在囚徒困境中，最有可能的判决就是两个人都指认对方，都获得五年的监禁

(甲,乙)收益	乙沉默 (合作)	乙认罪 (背叛)
甲沉默 (合作)	(−0.5, −0.5)	(−10, 0)
甲认罪 (背叛)	(0, −10)	(−5, −5)

最优解为**两人同时沉默**；但是两人实际倾向于选择同时认罪 (均衡解)

博弈的分类：

- 合作博弈与非合作博弈
- 静态博弈和动态博弈
- 完全信息博弈与不完全信息博弈

博弈的稳定局势即为纳什均衡 (*Nash equilibrium*)

任何玩家单独改变策略都不会得到好处，也就是说**当所有其他人都**不改变策略时，**没有人会改变自己的策略**

*Nash*定理：若玩家有限，每位玩家的策略集有限，收益函数为实值函数，则博弈必存在混合策略意义下的纳什均衡

纳什均衡的本质就是**不后悔**

遗憾最小化算法

若干定义

- 玩家*i*所采用的策略为 σ_i ，一个策略组 σ 包含所有玩家的策略， $\sigma = (\sigma_1, \sigma_2, \dots, \sigma_{|N|})$
 - 玩家*i*的策略空间用 Σ_i 表示
 - σ_{-i} 表示 σ 中除了 σ_i 之外的策略
- 玩家*i*在给定策略 σ 下的期望收益为： $\mu_i(\sigma)$

策略选择

根据过去博弈中的遗憾程度来决定动作选择的方法

玩家*i*在过去*T*轮中采取策略 σ_i 的累加遗憾值为

$$Regret_i^T(\sigma_i) = \sum_{t=1}^T (\mu_i(\sigma_i, \sigma_{-i}^t) - \mu_i(\sigma^t))$$

在第*T* + 1轮次玩家*i*选择策略*a*的概率如下（悔值越大越选择）

$$P(a) = \frac{Regret_i^T(a)}{\sum_{b \in \Sigma_i} Regret_i^T(b)}$$

遗憾最小化例子：见*PPT*：石头剪刀布

习题
