



南開大學
Nankai University

计算机学院
编译原理实验报告

LAB1-了解编译器 __LLVM-IR 编程

姓名：王一诺
学号：2312331
专业：计算机科学与技术

2025 年 9 月 29 日

目录

1 摘要	2
2 引言	2
3 实验要求与分工	2
4 基于简单程序熟悉完整编译过程	3
4.1 测试程序	3
4.2 编译过程	3
4.3 预处理器	4
4.4 编译器	7
4.4.1 词法分析	8
4.4.2 语法分析	9
4.4.3 语义分析	11
4.4.4 中间代码生成	11
4.4.5 代码生成	14
4.5 汇编器——目标文件生成	17
4.5.1 从反汇编文件看汇编器输出	17
4.5.2 从 nm 的符号表看：符号的种类与链接责任	18
4.5.3 汇编器具体功能总结	18
4.6 链接器	19
4.6.1 地址分配（节内偏移 → 运行时虚拟地址）	19
4.6.2 未定义符号（U）如何被处理—PLT 与 GOT 的引入	19
4.6.3 插入的运行时间与启动代码	20
4.6.4 重定位已被解析	20
4.6.5 符号表的变化：更多运行时符号与段符号	20
4.6.6 功能总结	20
5 LLVM IR 编程和 ARM 汇编编程	21
5.1 测试程序	21
5.2 LLVM IR 编写	23
5.3 ARM 汇编编写	29
6 结论	35

1 摘要

本实验报告深入探究了编译原理中语言处理系统的完整工作流程,以 GCC/ARM 编译工具链为研究对象,系统分析了预处理器、编译器、汇编器和链接器各阶段的功能与实现机制。通过对经典阶乘程序的逐步编译分析,详细展示了从源代码到可执行文件的转换过程,包括词法分析、语法分析、语义分析、中间代码生成、代码优化和目标代码生成等编译器各阶段的具体输出。在此基础上,设计并实现了涵盖 SysY 语言核心特性的测试程序,包括数值运算、条件分支、循环结构、函数调用、递归和数组操作等语言特性,分别编写了等价的 LLVM IR 中间代码和 ARM 汇编代码。实验结果表明,手工编写的 LLVM IR 和 ARM 汇编程序能够成功链接 SysY 运行库并正确执行,验证了对编译原理核心概念和编译流程的深入理解。本实验为后续编译器设计与实现课程打下了坚实的理论和实践基础。

关键词 : 编译原理;LLVM IR;ARM 汇编;编译器设计;中间代码生成;目标代码生成

2 引言

编译器是计算机系统中最核心的基础软件之一,它将高级语言源程序转换为目标机器可执行的机器代码,是连接程序员与计算机硬件的关键桥梁。深入理解编译器的工作原理,不仅是计算机专业学生的必修课程,更是从事系统软件开发、性能优化和程序分析等工作的基础。

传统的编译原理学习往往侧重于理论知识,对编译过程的实际操作和中间表示缺乏直观认识。本实验采用理论与实践相结合的方法,通过实际操作 GCC/LLVM 编译工具链,观察并分析编译过程各阶段的输出结果,从源代码的预处理、词法分析、语法树生成,到 LLVM IR 中间表示、汇编代码生成,最后到目标文件的链接,完整展现了现代编译器的工作流程。

本实验的主要目标包括:(1) 深入理解编译器各阶段的功能与实现机制;(2) 掌握 LLVM IR 中间表示语言的设计原理与编程方法;(3) 学习 ARM 汇编语言的指令系统与调用约定;(4) 通过手工编写等价代码,加深对编译过程的理解。实验选用了 SysY 语言作为源语言,这是一个 C 语言的简化子集,包含了编译器需要支持的核心语言特性,便于集中精力理解编译的本质问题。

3 实验要求与分工

1. 以 GCC(或 LLVM/Clang 等你常用的、熟悉的编译工具)为研究对象更深入地探究语言处理系统的完整工作过程:预处理器做了什么?编译器做了什么(包括更细致的编译器各阶段的功能)?汇编器做了什么?链接器做了什么?

2. 熟悉 LLVM IR 中间语言和汇编语言:设计 SysY 示例程序涵盖编译器要支持的语言特性(各种数值运算,赋值、条件分支、循环等语句、函数,以及其他进阶特性),编写 LLVM IR 程序以及 ARM 汇编程序,与 SysY 源程序等价、且能链接 SysY 运行库,用 LLVM/Clang、汇编器编译成目标程序,验证运行结果是否正确。

要求:以一个简单的 C/C++ 源程序为例(如下面的阶乘程序、斐波那契程序等,做一个即可)利用编译器的命令行选项获得各阶段的输出,研究它们与源程序的关系。

分工:

第一小题小组成员各自独立完成；

第二小题，由王一诺同学（作者）负责 LLVM IR 代码编写，由小组另一成员王羿淼同学负责 ARM 汇编代码编写。

4 基于简单程序熟悉完整编译过程

4.1 测试程序

我们选择了一个经典的阶乘计算程序（factorial.c）作为分析对象：

```
1  #include <stdio.h>
2
3  int factorial(int n) {
4      int result = 1;
5      int i = 2;
6      while (i <= n) {
7          result = result * i;
8          i = i + 1;
9      }
10     return result;
11 }
12
13 int main() {
14     int n;
15     scanf("%d", &n);
16     printf("Factorial of %d is: %d\n", n, factorial(n));
17     return 0;
18 }
```

4.2 编译过程

通过学习可知，程序的编译过程一般需经过以下几部分：

- 预处理器。处理源代码中以 # 开始的预编译指令，例如展开所有宏定义、插入 #include 指向的文件等，以获得经过预处理的源程序。
- 编译器。将预处理器处理过的源程序文件翻译成为标准的汇编语言以供计算机阅读。
- 汇编器。将汇编语言指令翻译成机器语言指令，并将汇编语言程序打包成可重定位目标程序。
- 链接器。将可重定位的机器代码和相应的一些目标文件以及库文件链接在一起，形成真正能在机器上运行的目标机器代码。

整体流程可参考下图：




图 4.1: 源程序编译的一般过程

接下来我们逐步观察编译过程每一步的结果并对其展开分析。

4.3 预处理器

执行 `gcc factorial.c -E -o factorial.i` 指令得到预处理结果。

观察 `factorial.i`, 从源代码的 18 行扩充到了 831 行, 都多出了哪些代码? 仔细观察, 发现这些代码可以大致分为四类:

- 标准库头文件的展开内容

```

1 # 0 "factorial.c"
2 # 0 "<built-in>"
3 # 0 "<command-line>"
4 # 1 "/usr/include/stdc-predef.h" 1 3 4
5 # 0 "<command-line>" 2
6 # 1 "factorial.c"
7 # 1 "/usr/include/stdio.h" 1 3 4
8 # 28 "/usr/include/stdio.h" 3 4
9 # 1 "/usr/include/x86_64-linux-gnu/bits/libc-header-start.h" 1 3 4
10 # 33 "/usr/include/x86_64-linux-gnu/bits/libc-header-start.h" 3 4
11 # 1 "/usr/include/features.h" 1 3 4
12 # 394 "/usr/include/features.h" 3 4
13 # 1 "/usr/include/features-time64.h" 1 3 4
14 # 20 "/usr/include/features-time64.h" 3 4
15 # 1 "/usr/include/x86_64-linux-gnu/bits/wordsize.h" 1 3 4
16 # 21 "/usr/include/features-time64.h" 2 3 4
17 # 1 "/usr/include/x86_64-linux-gnu/bits/timesize.h" 1 3 4
18 # 19 "/usr/include/x86_64-linux-gnu/bits/timesize.h" 3 4
19 # 1 "/usr/include/x86_64-linux-gnu/bits/wordsize.h" 1 3 4
20 # 20 "/usr/include/x86_64-linux-gnu/bits/timesize.h" 2 3 4
21 # 22 "/usr/include/features-time64.h" 2 3 4
22 # 395 "/usr/include/features.h" 2 3 4
23 # 502 "/usr/include/features.h" 3 4
24 # 1 "/usr/include/x86_64-linux-gnu/sys/cdefs.h" 1 3 4
25 # 576 "/usr/include/x86_64-linux-gnu/sys/cdefs.h" 3 4
26 # 1 "/usr/include/x86_64-linux-gnu/bits/wordsize.h" 1 3 4
27 # 577 "/usr/include/x86_64-linux-gnu/sys/cdefs.h" 2 3 4
28 # 1 "/usr/include/x86_64-linux-gnu/bits/long-double.h" 1 3 4
29 # 578 "/usr/include/x86_64-linux-gnu/sys/cdefs.h" 2 3 4
30 # 503 "/usr/include/features.h" 2 3 4
31 # 526 "/usr/include/features.h" 3 4
32 # 1 "/usr/include/x86_64-linux-gnu/gnu/stubs.h" 1 3 4
33 # 10 "/usr/include/x86_64-linux-gnu/gnu/stubs.h" 3 4
34 # 1 "/usr/include/x86_64-linux-gnu/gnu/stubs-64.h" 1 3 4
35 # 11 "/usr/include/x86_64-linux-gnu/gnu/stubs.h" 2 3 4
36 # 527 "/usr/include/features.h" 2 3 4
37 # 34 "/usr/include/x86_64-linux-gnu/bits/libc-header-start.h" 2 3 4
38 # 29 "/usr/include/stdio.h" 2 3 4

```

图 4.2: 预处理结果——头文件展开

这些是在 factorial.c 中写的 `#include <stdio.h>`，预处理时被完整展开，把 `stdio.h` 及其嵌套的所有头文件源码都复制进来。它会继续 `include`: `stdc-predef.h`、`features.h` 等等等等，所以行数暴增！仔细观察，这类代码大致可以划成以下结构：

`# < 行号 > "< 文件名 >" < 标志...>`

通过查阅网上的资料，这是 GCC 预处理器生成的“行控制信息”，告诉编译器：当前行来自哪个源文件，行号是多少，标志各自有不同的含义，如：1：开始新的文件 2：回到上一个文件 3：以下文本来自系统头文件 4：应将下面的文本视为包含在隐式的外部“C”块中。

提问：为什么会有？方便编译器在编译错误时仍能正确报告原始文件位置。

- 类型定义（typedef）


```
# 3 "factorial.c"
int factorial(int n) {
    int result = 1;
    int i = 2;
    while (i <= n) {
        result = result * i;
        i = i + 1;
    }
    return result;
}

int main() {
    int n;
    scanf("%d", &n);
    printf("Factorial of %d is: %d\n", n, factorial(n));
    return 0;
}
```

图 4.6: 预处理结果——源码

在文件末尾找到了和源代码的函数定义以及 main 函数一模一样的代码块，只不过删除了注释。

根据观察以及网上资料，可以总结预处理器做了什么。

预处理器在编译器编译程序之前对源代码进行处理，通常分为以下几个阶段：

1. 文件包含：处理 `#include` 指令，将指定的头文件或代码文件插入到源代码中。
2. 宏展开：对所有宏进行替换，将宏名称替换成对应的文本或表达式。
3. 条件编译：根据条件编译指令 (`#ifdef`, `#if` 等) 来选择性地编译代码。
4. 去除注释：删除源代码中的注释部分。
5. 行号和调试信息：生成与行号、文件名等相关的调试信息。

最终，预处理器会生成一个新的源文件，这个文件会被传递给编译器进行编译。

4.4 编译器

在理论课程的学习中可知，编译的一般过程可以分为 6 步，分别是：

- 词法分析
- 语法分析
- 语义分析
- 中间代码生成
- 代码优化
- 代码生成

接下来逐步执行编译步骤并对结果进行分析。

4.4.1 词法分析

执行 `clang -E -Xclang -dump-tokens factorial.c` 命令，可以得到词法分析的结果，截取部分结果如图：

```

identifier 'main'      [LeadingSpace] Loc=<factorial.c:13:5>
l_paren '('            Loc=<factorial.c:13:9>
r_paren ')'            Loc=<factorial.c:13:10>
l_brace '{'           [LeadingSpace] Loc=<factorial.c:13:12>
int 'int'             [StartOfLine] [LeadingSpace] Loc=<factorial.c:14:5>
identifier 'n'        [LeadingSpace] Loc=<factorial.c:14:9>
semi ';'              Loc=<factorial.c:14:10>
identifier 'scanf'     [StartOfLine] [LeadingSpace] Loc=<factorial.c:15:5>
l_paren '('            Loc=<factorial.c:15:10>
string_literal "%d"    Loc=<factorial.c:15:11>
comma ','              Loc=<factorial.c:15:15>
amp '&' [LeadingSpace] Loc=<factorial.c:15:17>
identifier 'n'         Loc=<factorial.c:15:18>
r_paren ')'            Loc=<factorial.c:15:19>
semi ';'               Loc=<factorial.c:15:20>
identifier 'printf'    [StartOfLine] [LeadingSpace] Loc=<factorial.c:16:5>
l_paren '('            Loc=<factorial.c:16:11>
string_literal "Factorial of %d is: %d\n" Loc=<factorial.c:16:12>
comma ','              Loc=<factorial.c:16:38>
identifier 'n'         [LeadingSpace] Loc=<factorial.c:16:40>
comma ','              Loc=<factorial.c:16:41>
identifier 'factorial' [LeadingSpace] Loc=<factorial.c:16:43>
l_paren '('            Loc=<factorial.c:16:52>
identifier 'n'         Loc=<factorial.c:16:53>
r_paren ')'            Loc=<factorial.c:16:54>
r_paren ')'            Loc=<factorial.c:16:55>
semi ';'               Loc=<factorial.c:16:56>
return 'return' [StartOfLine] [LeadingSpace] Loc=<factorial.c:17:5>
numeric_constant '0'  [LeadingSpace] Loc=<factorial.c:17:12>
semi ';'               Loc=<factorial.c:17:13>
r_brace '}'           [StartOfLine] Loc=<factorial.c:18:1>
eof ''                 Loc=<factorial.c:18:2>

```

图 4.7: 词法分析结果

观察输出，可以看到词法分析把文件分解成一个个 Token（词法单元），并为每个 Token 标注以下信息：

- 词法类型（如 identifier、int、semi、l_paren 等）
- 词面值（如 `error__unlocked`、`(`、`;`、`__attribute__` 等）
- 位置信息（Location）（文件名 + 行号 + 列号）
- 是否有前导空格、是否为行首、拼写来源等元信息（如 `LeadingSpace`、`StartOfLine`、`Spelling`）

仔细观察，大致可以为 token 归类：

Token 类型	示例	用途
关键字	int、while、return	控制语句、类型声明
标识符	factorial、FILE、__stream	变量、函数、宏
常量	1、0、2	数字
字符串字面量	"%d"、"Factorial of %d is: %d n"	printf/scanf 参数
运算符	+, *, =, <=	表达式和赋值
分隔符/界符	() , ; &	语句/参数边界
属性标记	__attribute__, __nothrow__	GCC 扩展，来自头文件
宏展开结果	在 stdio.h 中被替换出的符号	<stdio.h> 展开后产生
行控制信息 (内部)	Spelling=/usr/include/...	表示宏来自哪里

表 1: token 归类

- VarDecl ... cinit IntegerLiteral: VarDecl 描述局部变量（如 result、i）。cinit 表示带有初始化表达式；初始化子节点是 IntegerLiteral 1 或 2。

语句节点

- WhileStmt（循环）

```

-WhileStmt 0x63bc3bf6aa50 <line:6:5, line:9:5>
  -BinaryOperator 0x63bc3bf6a888 <line:6:12, col:17> 'int' '<='
  -ImplicitCastExpr 0x63bc3bf6a858 <col:12> 'int' <LValueToRValue>
    -DeclRefExpr 0x63bc3bf6a818 <col:12> 'int' lvalue Var 0x63bc3bf6a778 'i' 'int'
  -ImplicitCastExpr 0x63bc3bf6a870 <col:17> 'int' <LValueToRValue>
    -DeclRefExpr 0x63bc3bf6a838 <col:17> 'int' lvalue ParmVar 0x63bc3bf6a560 'n' 'int'
  -CompoundStmt 0x63bc3bf6aa30 <col:20, line:9:5>
    -BinaryOperator 0x63bc3bf6a958 <line:7:9, col:27> 'int' '='
    -DeclRefExpr 0x63bc3bf6a8a8 <col:9> 'int' lvalue Var 0x63bc3bf6a6c0 'result' 'int'
    -BinaryOperator 0x63bc3bf6a938 <col:18, col:27> 'int' '*'
    -ImplicitCastExpr 0x63bc3bf6a908 <col:18> 'int' <LValueToRValue>
      -DeclRefExpr 0x63bc3bf6a8c8 <col:18> 'int' lvalue Var 0x63bc3bf6a6c0 'result' 'int'
    -ImplicitCastExpr 0x63bc3bf6a920 <col:27> 'int' <LValueToRValue>
      -DeclRefExpr 0x63bc3bf6a8e8 <col:27> 'int' lvalue Var 0x63bc3bf6a778 'i' 'int'
    -BinaryOperator 0x63bc3bf6aa10 <line:8:9, col:17> 'int' '='
    -DeclRefExpr 0x63bc3bf6a978 <col:9> 'int' lvalue Var 0x63bc3bf6a778 'i' 'int'
    -BinaryOperator 0x63bc3bf6a9f0 <col:13, col:17> 'int' '+'
    -ImplicitCastExpr 0x63bc3bf6a9d8 <col:13> 'int' <LValueToRValue>
      -DeclRefExpr 0x63bc3bf6a998 <col:13> 'int' lvalue Var 0x63bc3bf6a778 'i' 'int'
    -IntegerLiteral 0x63bc3bf6a9b8 <col:17> 'int' 1

```

图 4.10: 循环语句节点

WhileStmt 节点有两个重要子节点：1. 条件表达式（这里是 BinaryOperator '<='）——判断 i <= n。条件的左右是 DeclRefExpr（对变量的引用），通常被 ImplicitCastExpr 包裹（把 LValue 转成 RValue）。2. 循环体（CompoundStmt）——循环内的语句列表。每一条语句在 AST 中仍然有自己的节点，例如赋值是 BinaryOperator '='。

- ReturnStmt（返回语句）

```

-ReturnStmt 0x63bc3bf6aaa8 <line:10:5, col:12>
  -ImplicitCastExpr 0x63bc3bf6aa90 <col:12> 'int' <LValueToRValue>
    -DeclRefExpr 0x63bc3bf6aa70 <col:12> 'int' lvalue Var 0x63bc3bf6a6c0 'result' 'int'

```

图 4.11: 返回语句节点

表示 return result; DeclRefExpr 表示对 result 的引用，ImplicitCastExpr 把左值转换成右值以便返回。

表达式节点（算术运算 / 函数调用 / 隐式转换） 1. 算术运算不再赘述 2.CallExpr（函数调用）

```

-CallExpr 0x63bc3bf6eb08 <line:16:5, col:55> 'int'
  -ImplicitCastExpr 0x63bc3bf6eb00 <col:5> 'int (*) (const char *, ...)' <FunctionToPointerDecay>
    -DeclRefExpr 0x63bc3bf6ae68 <col:5> 'int (const char *, ...)' Function 0x63bc3bf2af28 'printf' 'int (const char *, ...)'
  -ImplicitCastExpr 0x63bc3bf6eb08 <col:12> 'const char *' <NoOp>
  -ImplicitCastExpr 0x63bc3bf6eb00 <col:12> 'char *' <ArrayToPointerDecay>
    -StringLiteral 0x63bc3bf6ae00 <col:12> 'char[24]' lvalue 'Factorial of %d is: %d\n'
  -ImplicitCastExpr 0x63bc3bf6eb00 <col:40> 'int' <LValueToRValue>
    -DeclRefExpr 0x63bc3bf6af00 <col:40> 'int' lvalue Var 0x63bc3bf6ac08 'n' 'int'
  -CallExpr 0x63bc3bf6af08 <col:43, col:54> 'int'
    -ImplicitCastExpr 0x63bc3bf6af90 <col:43> 'int (*) (int)' <FunctionToPointerDecay>
      -DeclRefExpr 0x63bc3bf6af20 <col:43> 'int (int)' Function 0x63bc3bf6a5f8 'factorial' 'int (int)'
    -ImplicitCastExpr 0x63bc3bf6af00 <col:53> 'int' <LValueToRValue>
      -DeclRefExpr 0x63bc3bf6af40 <col:53> 'int' lvalue Var 0x63bc3bf6ac08 'n' 'int'

```

图 4.12: 函数调用节点

CallExpr 是函数调用节点。第一个子节点通常是函数表达式（DeclRefExpr，在需要时外面包 ImplicitCastExpr 做 FunctionToPointerDecay），之后是各个参数表达式。可以注意到 factorial(n) 在 printf 的参数中以一个子 CallExpr 的形式出现：AST 支持任意嵌套表达式。3.ImplicitCastExpr（隐式类型转换）可以频繁看到 ImplicitCastExpr，常见的转换类型包括：

- `<LValueToRValue>`: 把变量的左值 (lvalue) 转换为右值 (rvalue), 例如在表达式中读取变量的值。大量出现在算术操作和参数传递处。
- `<FunctionToPointerDecay>`: 函数名在调用处从函数类型退化为函数指针 (scanf/printf/factorial 的节点里可见)。
- `<ArrayToPointerDecay>`: 字符串字面量或数组名在做参数时退化为指针 (例如 StringLiteral 被 ArrayToPointerDecay 包裹, 再可能被 NoOp 转为 const char *)。
- `<NoOp>`: 类型无需调整但是 AST 仍显示一个“无操作”转换 (常见于 char * -> const char * 的 const 加装)。

这些隐式类型转换为什么重要? 这些隐式转换节点记录了编译器在语义层面做的类型调整, 后续生成 IR / 代码时要根据这些信息插入适当的读取/转换指令。

4.4.3 语义分析

在上一步生成的语法分析中其实已经进行了语义分析处理, 不再赘述。

4.4.4 中间代码生成

执行 `clang -S -emit-llvm factorial.c -o factorial.ll` 命令生成 LLVM IR 文件: factorial.ll。接下来分析一下 LLVM IR 结构:

模块头

```
1 ; ModuleID = 'factorial.c'
2 source_filename = "factorial.c"
3 target datalayout =
4     "e-m:e-p270:32:32-p271:32:32-p272:64:64-i64:64-i128:128-f80:128-n8:16:32:64-S128"
5 target triple = "x86_64-pc-linux-gnu"
```

ModuleID / source_filename: 模块与源文件标识。

target datalayout: 目标机器的数据对齐与内存布局规则 (整数/浮点宽度、对齐、指针大小等)。生成的 IR 必须遵守这些规则以便后端生成正确机器码。

target triple: 目标架构和平台, 影响 ABI、调用约定等。

全局常量 (字符串字面量)

```
1 @.str = private unnamed_addr constant [3 x i8] c"%d\00", align 1
2 @.str.1 = private unnamed_addr constant [24 x i8] c"Factorial of %d is: %d\0A\00",
    align 1
```

原 C 中的 "%d" 和 "Factorial of %d is: %d \n" 被放在程序的只读数据区 (全局常量), 用数组类型 [N x i8] 表示每个字符并以 \00 结尾。

这样 scanf/printf 在运行时可以接收指向这些内存的指针作为格式字符串参数。

private unnamed_addr 等表示链接可见性与地址不关心 (优化提示)。

函数定义: @factorial 的 IR

```

1  define dso_local i32 @factorial(i32 noundef %0) #0 {
2      %2 = alloca i32, align 4          ; stack slot for param n (saved)
3      %3 = alloca i32, align 4          ; stack slot for result
4      %4 = alloca i32, align 4          ; stack slot for i
5      store i32 %0, ptr %2, align 4    ; store argument into %2
6      store i32 1, ptr %3, align 4     ; result = 1
7      store i32 2, ptr %4, align 4     ; i = 2
8      br label %5                      ; jump to loop-test block
9      5:
10     %6 = load i32, ptr %4, align 4
11     %7 = load i32, ptr %2, align 4
12     %8 = icmp sle i32 %6, %7
13     br i1 %8, label %9, label %15    ; if (i <= n) goto body else goto exit
14     9:
15     %10 = load i32, ptr %3, align 4
16     %11 = load i32, ptr %4, align 4
17     %12 = mul nsw i32 %10, %11
18     store i32 %12, ptr %3, align 4   ; result = result * i
19     %13 = load i32, ptr %4, align 4
20     %14 = add nsw i32 %13, 1
21     store i32 %14, ptr %4, align 4   ; i = i + 1
22     br label %5, !llvm.loop !6      ; jump back to test (loop metadata)
23     15:
24     %16 = load i32, ptr %3, align 4
25     ret i32 %16
26 }

```

- `alloca` (栈上分配)

每个局部变量 (包括编译器将函数参数拷贝到的“本地槽”) 在函数入口用 `alloca` 分配栈空间。AI 提示, 这是典型的 `-O0` (未优化) 策略: 变量保存在内存里, 方便逐步调试 (与寄存器机械式保存相比更容易与源代码一一对应)。因为 IR 包含大量 `load/store` 而没有 SSA 节点, 说明编译器选择把变量保持在内存 (不是寄存器) —— 这是由 `optnone` (未优化) 影响的常见结果。

- 将参数存入栈

`%0` 是函数参数 (直接传入的寄存器或栈位置), 第一件事即 `store %0, %2`, 把它拷入本地槽 `%2` (这样后面用 `load %2` 得到 `n` 的值)。这保证调试时 `%2` 与源代码变量 `n` 一一对应。

- 分支/基本块

`br label %5`、`br i1 %8, label %9, label %15` 表示基本块之间的控制流。编号 (5、9、15) 只是 LLVM 为基本块生成的符号。

`%8 = icmp sle i32 %6, %7` 对应 `i <= n` 条件判断。`icmp` 是整数比较 (signed less-or-equal)。

- 算术运算 `mul nsw`、`add nsw`

`mul nsw i32 %10, %11` 表示带 NSW (No Signed Wrap) 的乘法: 此运算假定带符号整数溢出不发生 (若发生则行为未定义), 编译器可据此进行某些优化 (但在 `-O0` 并未利用)。`add nsw i32 %13, 1` 同理。

- `!llvm.loop !6` (loop metadata)

这是循环元数据 (后面文件有 `!6 = distinct !6, !7` 和 `!7 = !"llvm.loop.mustprogress"`)，表示循环相关属性 (例如必须有进展等)，有助于后续的 loop 优化分析。

@main 的 IR

```

1  define dso_local i32 @main() #0 {
2      %1 = alloca i32, align 4
3      %2 = alloca i32, align 4
4      store i32 0, ptr %1, align 4
5      %3 = call i32 @__isoc99_scanf(ptr noundef @.str, ptr noundef %2)
6      %4 = load i32, ptr %2, align 4
7      %5 = load i32, ptr %2, align 4
8      %6 = call i32 @factorial(i32 noundef %5)
9      %7 = call i32 (ptr, ...) @printf(ptr noundef @.str.1, i32 noundef %4, i32 noundef
        %6)
10     ret i32 0
11 }
```

`%2` 是 `n` 的栈槽 (用于 `scanf` 写入)。`scanf` 被调用时传入 `@.str` (格式字符串全局地址) 和 `%2` 的指针 (`ptr noundef %2`)。

`load` 两次 (`%4`、`%5`) 都是把 `n` 的值从内存读出来——这里重复读取用于传递给 `printf` 的第一个参数和传给 `factorial` 的参数。编译器在 `-O0` 不做冗余消除，所以出现重复 `load`。

调用 `@factorial`: `call i32 @factorial(i32 noundef %5)`，把刚才加载的 `n` 传入。`printf`: 以格式字符串与两个整型参数 (`n`、`factorial(n)` 的返回值) 调用。最后 `ret i32 0`: 返回 0 (`main` 的返回值)。

函数声明 (外部可变参数函数)

```

1  declare i32 @__isoc99_scanf(ptr noundef, ...) #1
2  declare i32 @printf(ptr noundef, ...) #1
```

`declare` 表示外部函数的原型 (没有定义体)。格式 `i32 (ptr, ...)` 标明这些函数是可变参数 (`vararg`) 的 C 库函数，LLVM 必须按目标平台 ABI 为 `vararg` 调用生成正确的参数传递代码 (例如寄存器/栈使用)。

属性集合 `#1` (在后面有定义) 包含与目标相关的属性 (`frame-pointer`、`no-trapping-math` 等)。

属性 (attributes) 与模块元数据

```

1  attributes #0 = { noline nounwind optnone uwtable "frame-pointer"="all "
        "min-legal-vector-width"="0" "no-trapping-math"="true "
        "stack-protector-buffer-size"="8" "target-cpu"="x86-64"
        "target-features"="+cmov,+cx8,+fxsr,+mmx,+sse,+sse2,+x87" "tune-cpu"="generic" }
2  attributes #1 = { "frame-pointer"="all " "no-trapping-math"="true "
        "stack-protector-buffer-size"="8" "target-cpu"="x86-64"
        "target-features"="+cmov,+cx8,+fxsr,+mmx,+sse,+sse2,+x87" "tune-cpu"="generic" }
3
4  !llvm.module.flags = [{!0, !1, !2, !3, !4}]
5  !llvm.ident = [{!5}]
6
```

```

7  !0 = !{i32 1, !"wchar_size", i32 4}
8  !1 = !{i32 8, !"PIC Level", i32 2}
9  !2 = !{i32 7, !"PIE Level", i32 2}
10 !3 = !{i32 7, !"uwtable", i32 2}
11 !4 = !{i32 7, !"frame-pointer", i32 2}
12 !5 = !{!"Ubuntu clang version 18.1.3 (1ubuntu1)"}
13 !6 = distinct !{!6, !7}
14 !7 = !{!"llvm.loop.mustprogress"}

```

- **noinline:**
不要内联（对于 -O0，保持可见函数边界便于调试）。
- **nounwind:**
函数不会抛出 C++ 异常。
- **optnone:**
禁止优化（常见于 -O0，保留源码结构用于调试）。
- **uwtable:**
生成 unwind table（异常/栈展开信息），对调试与栈回溯有用。
- **模块 flags**（PIC Level、PIE Level、frame-pointer 等）
记录了编译目标/选项信息。
- **!llvm.loop.mustprogress:**
标记循环必须进展，避免无限循环的某些优化假设被破坏。

总结 中间代码是前端（语法/语义分析）和后端（目标机器代码生成）之间的跨平台、可优化的中间抽象层，用于表示程序的语义与控制流，使得大量与目标无关的分析与优化可以统一、重复地执行，把语言语义与目标平台解耦，然后再 lower 到具体机器指令。

4.4.5 代码生成

执行 `aarch64-linux-gnu-gcc factorial.i -S -o factorial.S` 命令，以中间表示形式作为输入，将其映射到目标语言。

观察生成的汇编语言，可以分析编译器在这阶段做了什么：

- 把“架构无关的中间代码”转换成“目标机器相关的汇编指令”
LLVM IR 或内部 SSA 表示的运算、控制流、函数调用、变量访问，会被降级为具体 CPU 指令集的操作。

```
factorial:
.LFB0:
.cfi_startproc
sub sp, sp, #32
.cfi_def_cfa_offset 32
str w0, [sp, 12]
mov w0, 1
str w0, [sp, 24]
mov w0, 2
str w0, [sp, 28]
```

上图对应的源代码：

```
1  int factorial(int n) {
2      int result = 1;
3      int i = 2;
```

可见进行了变量分配与栈帧建立。

- 控制流结构变成跳转和标签

```
b    .L2
.L3:
ldr w1, [sp, 24]
ldr w0, [sp, 28]
mul w0, w1, w0
str w0, [sp, 24]
ldr w0, [sp, 28]
add w0, w0, 1
str w0, [sp, 28]
.L2:
ldr w1, [sp, 28]
ldr w0, [sp, 12]
cmp w1, w0
ble .L3
```

这里对应的是源码里的一处 while 循环，.L2 / .L3 是基本块标签，cmp + ble 实现 $\leq$ 分支控制。

- 算术表达式变为机器指令

例如：

```
1      mul w0, w1, w0    ; result * i
2      add w0, w0, 1     ; i = i + 1
```

- 函数调用使用 ABI 调用约定

调用 factorial、printf、scanf 时，GCC 遵循 ARM64 ABI：参数放在寄存器：x0, x1, x2, ... 返回值在 w0 / x0

- 字符串常量放入.rodata 段

```
1      .section .rodata
2      .LC0:
3      .string "%d"
```

把 C 的格式字符串静态放入只读内存，并通过 adrp + add 访问。

- 主函数多了栈保护

可以观察到 main 函数中有额外逻辑：

```
1      adrp    x0, :got:___stack_chk_guard
2      ldr     x0, [x0, :got_lo12:___stack_chk_guard]
3      ldr     x1, [x0]
4      str     x1, [sp, 8]
5      ...
6      ldr     x3, [sp, 8]
7      ldr     x2, [x0]
8      subs    x3, x3, x2
9      beq     .L7
10     bl      ___stack_chk_fail
```

结合 AI 分析，这是 GCC 自动加入的栈溢出保护机制（默认开启 -fstack-protector）。

- 符号定义与可链接信息生成

```
1      .global factorial
2      .type factorial, %function
3      .size factorial, .-factorial
```

这些告诉链接器：哪些函数是外部可见的、它们的范围和地址、需要如何组织可执行文件

- 函数栈结构与调试信息

```
1      .cfi_startproc
2      .cfi_offset 29, -32
3      .cfi_endproc
```

这些是调用帧信息 (CFI)，用于调试器和异常回溯。

4.5 汇编器——目标文件生成

执行 `aarch64-linux-gnu-gcc factorial.S -c -o factorial.o` 命令进行交叉编译，把汇编语言程序代码翻译成目标机器指令，最终生成可重定位的机器代码。

由于二进制文件不易分析，我又执行了 `aarch64-linux-gnu-objdump -d factorial.o > factorial-obj-disasm.s` 和 `nm factorial.o > factorial-obj-symbols.txt` 生成了反汇编文件和符号表，以此分析汇编器的工作和功能：

4.5.1 从反汇编文件看汇编器输出

反汇编显示的格式是：

`<offset> <machine-code-bytes> <asm-instruction>`。

因为这是可重定位目标文件，所有地址/相对位移都是节内偏移 / 占位，真正的绝对地址要留待链接器修正。

- 函数前序：栈帧/局部变量分配

```

1      00000000 <factorial>:
2      0: d10083ff  sub sp, sp, #0x20
3      4: b9000fe0  str w0, [sp, #12]
4      ...
5      48: b9401be0  ldr w0, [sp, #24]
6      4c: 910083ff  add sp, sp, #0x20
7      50: d65f03c0  ret

```

汇编器把函数抽象（局部变量）映射成具体栈偏移的 `str/ldr` 操作，生成函数头尾（`prologue/epilogue`）保证 ABI 与栈平衡。

- 循环与条件分支的翻译（控制流）

```

1      18: 14000008  b 38 <factorial+0x38>
2      1c: b9401be1  ldr w1, [sp, #24]
3      20: b9401fe0  ldr w0, [sp, #28]
4      24: 1b007c20  mul w0, w1, w0
5      ...
6      38: b9401fe1  ldr w1, [sp, #28]
7      3c: b9400fe0  ldr w0, [sp, #12]
8      40: 6b00003f  cmp w1, w0
9      44: 54fffecb  b.le 1c <factorial+0x1c>

```

观察反汇编，这段代码通过翻译 `b` 和 `b.le` 实现 `while (i <= n)` 控制流。控制流的基本块在目标代码中以标签（`offset`）表示，分支是机器跳转指令。

- 主函数中：调用约定、全局/常量引用、栈保护
- 地址/常量的生成：`adrp + add` / GOT 访问

在 AArch64，访问远距离的全局地址通常用 `adrp`（把页基地址加载到寄存器）配合 `add`（加上页内偏移），或 `adrp + ldr [x0, :got_lo12:]` 之类的序列。因为 `.o` 仍是可重定位的，`adrp` 的立即数/补位不是最终值，链接器会对这些指令产生重定位修正。

4.5.2 从 nm 的符号表看：符号的种类与链接责任

```

1 0000000000000000 r $d
2 0000000000000014 r $d
3 0000000000000000 t $x
4      U __isoc99_scanf
5      U __stack_chk_fail
6      U __stack_chk_guard
7 0000000000000000 T factorial
8 0000000000000054 T main
9      U printf

```

- **T (大写)**: 该符号在 .text 段, 是全局 (外部) 可见的函数符号 (linker 可在其它对象文件中引用)。factorial、main 为 T, 说明汇编器把它们导出以便链接器连接成程序入口等。地址是节内偏移 (0x0、0x54)。
- **t (小写)**: 本地 (非导出) 的 .text 符号 (只在当前目标文件可见)。这里 \$x 是汇编器/链接器自动生成的局部符号名 (通常用于对齐/填充或临时标签)。
- **r**: 表示在只读数据 (.rodata) 段的本地符号 (read-only data)。能看到两个 \$d, 这很可能是汇编器为字符串常量 (.LC0、.LC1 等) 生成的内部局部符号 (名字以 \$ 开头是 assembler 内部生成的临时符号)。地址 0x0、0x14 是该节的节内偏移。
- **U**: 未定义 (undefined) 符号——表示该符号在当前.o 中被引用但未定义, 需由链接器在其他对象/库中解析。__isoc99_scanf, printf, __stack_chk_guard, __stack_chk_fail 都为 U, 它们通常在 libc 或运行时库中实现。

4.5.3 汇编器具体功能总结

汇编器的职责可以分为“翻译层面”和“链接准备层面”两大类:

A. 翻译 / 编码 (把汇编文本 → 机器语言)

- 指令编码
将汇编指令 (mnemonics 与操作数) 编码为对应的机器码字节 (如 sub sp, sp, #0x20 编为 d10083ff)。
- 伪指令/序列展开
把某些伪操作展开为一系列真实指令 (例如文字常量地址访问会展开为 adrp + add/ldr 等序列)。
- 指令/数据分节将文本放入 .text, 字面量放入 .rodata, 生成相应节头 (section headers)。

B. 产生符号表与重定位信息 (为链接器留空)

- 符号表
为标签、函数、全局变量、局部常量生成符号条目 (并标注是否全局/本地、类型、节偏移)。例如 T factorial、U printf。

- 重定位记录 (relocations)

当指令/数据引用尚未定义或需要链接器修正 (跨节/跨对象的地址) 时, 汇编器不会算最终值, 而是在对象中产生重定位条目, 说明 “在这个位置需要把某个符号的地址/偏移填上来的信息” —— 常见于 `adrp`、`add` 的高/低位对、`bl` 的 `call` 立即数等。

例如 `bl printf` 在 `.o` 中会留下 `R_AARCH64_CALL26` 类型的重定位而不是直接编码目标地址。链接器负责对这些重定位进行修正 (并可能生成 `PLT/GOT` 条目以支持动态链接)。

- 节内地址/偏移

汇编器把符号地址设置为节内偏移 (在未链接时), 为链接器合并节做准备。

C. 其他辅助信息

调试/回溯信息: 生成 `.eh_frame` / `CFI` 伪指令 (`.cfi_*`), 帮助调试器进行栈回溯与异常展开。

生成可供 `nm/objdump` 读取的信息 (节头、节表、符号表、字符串表等)。

4.6 链接器

执行了 `aarch64-linux-gnu-gcc factorial.o -o factorial` 得到了可执行文件, 然后运行了 `aarch64-linux-gnu-objdump -d factorial > factorial-exe-disasm.s` 和 `nm factorial > factorial-exe-symbols.txt` 得到了可执行文件的反汇编文件和符号表, 与上一阶段的反汇编文件对比可以分析链接器的作用:

4.6.1 地址分配 (节内偏移 → 运行时虚拟地址)

在 `.o` (`factorial-obj-disasm.s`):

`factorial` 在节内偏移 `0x0`, `main` 在 `0x54`。这些是 “节内偏移”, 不是最终虚拟地址。

在 `EXE` (`factorial-exe-disasm.s`):

相同函数现在有了最终虚拟地址: `factorial` 显示在 `0x898`, `main` 在 `0x8ec` (另外可执行文件有许多新段放在前面, 因此偏移增加)。

可见: 链接器将各目标文件的 `.text`、`.rodata`、`.data` 等节合并, 并把它们放到可执行文件的地址空间中 (按链接脚本/ABI/对齐规则), 所以函数的地址会被整体上移或重排。

4.6.2 未定义符号 (U) 如何被处理—PLT 与 GOT 的引入

在 `.o`:

`nm` 显示 `U printf`, `U __isoc99_scanf`, `U __stack_chk_guard`: 表示这些函数/变量被引用但在当前 `.o` 中未定义。

反汇编中可以看到很多 `bl 0 <printf>` 或 `adrp x0, 0 <__stack_chk_guard>`: 这里编译器/汇编器写入了占位 (0) 并在对象文件中留下重定位表, 告诉链接器 “这里需要填地址”。

在 `EXE`: 链接器生成了 `.plt` (Procedure Linkage Table) 和 `.got` (Global Offset Table) 等段: 在反汇编可以看到 `.plt` 区域 (例如 `__isoc99_scanf@plt`、`printf@plt` 等), 这些都是链接器生成的跳转/间接调用桩。

可执行文件中的调用指令不再跳到偏移 0, 而是跳到 `PLT` 表项 (例如 `bl 740 <__isoc99_scanf@plt>`)。 `PLT` 再进一步通过 `GOT` 去调用真正的库函数。

在符号表中仍可看到 `U printf@GLIBC_2.17`, 表示该符号由运行时负责最终解析; 但代码中调用的是 `PLT stub`, 运行时将填充 `GOT` 条目以实现函数地址分发。

4.6.3 插入的运行时与启动代码

EXE 引入了很多链接器/CRT 提供的代码段：

`_start`（程序入口），它会调用 `__libc_start_main` 由 `libc` 启动最终调用 `main`。

`_init` / `.fini` 段（初始化/终结器），`__do_global_ctors_aux`、`frame_dummy` 等，用于静态构造/析构和初始化表的处理。

`call_weak_fn`, `register_tm_clones`, `deregister_tm_clones`：用于运行时支持工具链/线程局部等。这些在.o 不存在，都是链接器与运行时库合并后加入的。

4.6.4 重定位已被解析

在.o，`adrp/add/bl` 等指令中有“需要链接器补偿”的立即数或页基，高位/低位分离，所以在 obj 里看到 0 或占位。

链接后，链接器根据符号在最终地址的虚拟内存地址计算真正的立即数并修补机器码：因此 EXE 中 `bl`、`adrp` 的操作数不再是 0，而是实际跳转到 PLT、GOT 或最终函数地址。

例如：在.o 中看到 `bl 0 <factorial>`（占位），在 exe 中改为 `bl 898 <factorial>`，调用已改为指向最终地址或 PLT。

4.6.5 符号表的变化：更多运行时符号与段符号

EXE 的 `nm` 输出里出现了大量新的符号：

`_start`, `_init`, `_fini`（由 crt/链接器产生）；

`_GLOBAL_OFFSET_TABLE_`, `_DYNAMIC`, `.eh_frame_hdr` 等动态链接/异常处理相关符号；
`.bss` / `.data` / `.rodata` 的实际地址与大小信息；

以及某些符号的版本信息（如 `printf@GLIBC_2.17`）——这些由链接器根据库符号版本处理产生。
.o 的一些本地符号（`$d`, `$x`）在 EXE 中被再次重新定位或合并到全局节中，地址变成真实地址。

4.6.6 功能总结

可以总结概括链接器的作用：

- 读取所有输入对象与库
- 合并同名节

把输入文件的 `.text` 合并到输出的 `.text`，`.rodata` 合并到输出 `.rodata`，并进行地址对齐。

- 分配虚拟地址（VMA）与文件偏移
给每个节与符号，决定最终的地址。

- 处理重定位条目

根据重定位类型计算要写回的立即数/位域，并修补对应的机器码

- 解析符号：


如果符号在某个输入文件中定义，就把引用解析到那个定义；如果符号在外部库，创建动态符号条目，并把调用改为 PLT/GOT 形式。

- 生成 PLT/GOT 和动态段，用于动态链接与懒绑定

- 插入启动/运行时代码
- 写出最终 ELF:
包含头、节表、段表、节内容、符号表与重定位已修补的机器码。

5 LLVM IR 编程和 ARM 汇编编程

LLVM IR 设计架构可参考下图:



为了更好的理解 LLVM IR 与汇编程序, 下面将设计一个 SysY 测试程序的 LLVM IR 与汇编代码, 并链接 SysY 运行库, 用 LLVM/Clang、汇编器编译成目标程序, 验证运行结果是否正确。

5.1 测试程序

先设计出测试程序的 C 源码, 方便对照着编写 LLVM IR 和 ARM 汇编代码。

```

1  // SysY语言特性测试程序
2  // 包含: 数值运算、赋值、条件分支、循环、函数调用
3
4  // 全局变量
5  int global_var = 10;
6  int array[5] = {1, 2, 3, 4, 5};
7
8  // 数值运算函数
9  int arithmetic_ops(int a, int b) {
10     int sum = a + b;
11     int diff = a - b;
12     int prod = a * b;
13     int quot = a / b;
14     int mod = a % b;
15     return sum + diff + prod + quot + mod;
16 }
17
18 // 条件分支函数
19 int conditional_test(int x) {
20     if (x > 0) {
21         return 1;
22     } else if (x < 0) {
23         return -1;
24     } else {
25         return 0;
  
```

```
26     }
27 }
28
29 // 循环函数 - while 循环
30 int while_loop(int n) {
31     int sum = 0;
32     int i = 1;
33     while (i <= n) {
34         sum = sum + i;
35         i = i + 1;
36     }
37     return sum;
38 }
39
40 // 循环函数 - for 循环
41 int for_style_loop(int n) {
42     int product = 1;
43     int i;
44     for (i = 1; i <= n; i = i + 1) {
45         product = product * i;
46     }
47     return product;
48 }
49
50 // 递归函数
51 int fibonacci(int n) {
52     if (n <= 1) {
53         return n;
54     }
55     return fibonacci(n - 1) + fibonacci(n - 2);
56 }
57
58 // 数组操作
59 int array_sum() {
60     int sum = 0;
61     int i;
62     for (i = 0; i < 5; i = i + 1) {
63         sum = sum + array[i];
64     }
65     return sum;
66 }
67
68 int main() {
69     int a, b, n;
70
71     // 输入测试
72     printf("Enter two integers: ");
73     scanf("%d %d", &a, &b);
74 }
```

```

75 // 数值运算测试
76 printf("Arithmetic result: %d\n", arithmetic_ops(a, b));
77
78 // 条件分支测试
79 printf("Conditional test for %d: %d\n", a, conditional_test(a));
80 printf("Conditional test for %d: %d\n", b, conditional_test(b));
81
82 // 循环测试
83 printf("Enter n for loop tests: ");
84 scanf("%d", &n);
85
86 printf("Sum 1 to %d (while): %d\n", n, while_loop(n));
87 printf("Factorial of %d: %d\n", n, for_style_loop(n));
88
89 // 递归测试
90 if (n <= 10) {
91     printf("Fibonacci(%d): %d\n", n, fibonacci(n));
92 }
93
94 // 数组测试
95 printf("Array sum: %d\n", array_sum());
96
97 // 全局变量测试
98 printf("Global variable: %d\n", global_var);
99
100 return 0;
101 }

```

5.2 LLVM IR 编写

首先明确，为了保证编写出的效果与 SysY 源代码等价，应该遵循以下编写原则：

- 语义等价：相同输入产生相同输出
- 数据流等价：变量的生命周期和数据依赖关系一致
- 控制流等价：分支和循环的执行逻辑相同
- 函数调用等价：参数传递和返回值处理一致

那么，以数值运算函数为例，探究如何编写与之对应的正确的 LLVM IR 中间代码：

1. 先对源代码进行简单的语义分析：

- 识别变量和作用域

可以明确：输入参数：a, b (int 类型)；局部变量：sum, diff, prod, quot, mod (int 类型)；返回值：int 类型。

- 分析数据流

a, b $\rightarrow$ sum = a + b

$a, b \rightarrow \text{diff} = a - b$
 $a, b \rightarrow \text{prod} = a * b$
 $a, b \rightarrow \text{quot} = a / b$
 $a, b \rightarrow \text{mod} = a \% b$
 $\text{sum}, \text{diff}, \text{prod}, \text{quot}, \text{mod} \rightarrow$ 返回值计算

- 分析控制流

可以明确这部分代码：单一基本块，顺序执行；无分支，无循环；单一出口点 (return)。

2. 根据语义分析展开转换：

- 函数签名转换

例如 `int arithmetic_ops(int a, int b)`

转换为 `define dso_local i32 @arithmetic_ops(i32 %a, i32 %b) {`

转换规则：

`int` $\rightarrow$ `i32` (32 位有符号整数)

函数名前加 `@` 符号

参数使用 `%` 标记的 SSA 变量

`dso_local` 表示符号在当前模块内

- 局部变量处理

局部变量在 LLVM IR 中有两种处理方式：

`alloca` 指令（模拟栈分配）

```

1      entry:
2          %sum = alloca i32, align 4
3          %diff = alloca i32, align 4
4          %prod = alloca i32, align 4
5          %quot = alloca i32, align 4
6          %mod = alloca i32, align 4
  
```

和 SSA 形式

```

1      entry:
2          %sum = add nsw i32 %a, %b
3          %diff = sub nsw i32 %a, %b
4          %prod = mul nsw i32 %a, %b
5          %quot = sdiv i32 %a, %b
6          %mod = srem i32 %a, %b
  
```

这里采用 SSA 形式：更接近编译器优化后的结果，还可以避免不必要的内存访问

- 算术运算转换

见表 2：

SysY 运算	LLVM IR 指令	说明
a + b	add nsw i32 %a, %b	nsw 即 no signed wrap
a - b	sub nsw i32 %a, %b	检测有符号溢出
a * b	mul nsw i32 %a, %b	有符号乘法
a / b	sdiv i32 %a, %b	有符号除法
a % b	srem i32 %a, %b	有符号取余

表 2: 算术转换

- 返回值计算

```
1  return sum + diff + prod + quot + mod;
```

转换写成:

```
1  %temp1 = add nsw i32 %sum, %diff
2  %temp2 = add nsw i32 %temp1, %prod
3  %temp3 = add nsw i32 %temp2, %quot
4  %result = add nsw i32 %temp3, %mod
5  ret i32 %result
```

按照类似的过程，我们能逐步写出完整的 LLVM IR 代码:

```
1  ; SysY测试程序的LLVM IR实现
2  target datalayout =
3      "e-m:e-p270:32:32-p271:32:32-p272:64:64-i64:64-f80:128-n8:16:32:64-S128"
4  target triple = "x86_64-pc-linux-gnu"
5
6  ; 声明SysY运行库函数
7  declare i32 @getint()
8  declare void @putint(i32)
9  declare void @putch(i32)
10
11 ; 全局变量定义
12 @global_var = dso_local global i32 10, align 4
13 @array = dso_local global [5 x i32] [i32 1, i32 2, i32 3, i32 4, i32 5], align 16
14
15 ; 数值运算函数
16 define dso_local i32 @arithmetic_ops(i32 %a, i32 %b) {
17     entry:
18     %sum = add nsw i32 %a, %b
19     %diff = sub nsw i32 %a, %b
20     %prod = mul nsw i32 %a, %b
21     %quot = sdiv i32 %a, %b
22     %mod = srem i32 %a, %b
23
24     %temp1 = add nsw i32 %sum, %diff
25     %temp2 = add nsw i32 %temp1, %prod
26     %temp3 = add nsw i32 %temp2, %quot
```

```

26     %result = add nsw i32 %temp3, %mod
27
28     ret i32 %result
29 }
30
31 ; 条件分支函数
32 define dso_local i32 @conditional_test(i32 %x) {
33     entry:
34     %cmp_pos = icmp sgt i32 %x, 0
35     br i1 %cmp_pos, label %if.positive, label %check_negative
36
37     if.positive:
38     ret i32 1
39
40     check_negative:
41     %cmp_neg = icmp slt i32 %x, 0
42     br i1 %cmp_neg, label %if.negative, label %if.zero
43
44     if.negative:
45     ret i32 -1
46
47     if.zero:
48     ret i32 0
49 }
50
51 ; while 循环函数
52 define dso_local i32 @while_loop(i32 %n) {
53     entry:
54     br label %while.cond
55
56     while.cond:
57     %sum.0 = phi i32 [ 0, %entry ], [ %sum.1, %while.body ]
58     %i.0 = phi i32 [ 1, %entry ], [ %i.1, %while.body ]
59
60     %cmp = icmp sle i32 %i.0, %n
61     br i1 %cmp, label %while.body, label %while.end
62
63     while.body:
64     %sum.1 = add nsw i32 %sum.0, %i.0
65     %i.1 = add nsw i32 %i.0, 1
66     br label %while.cond
67
68     while.end:
69     ret i32 %sum.0
70 }
71
72 ; 递归函数 (斐波那契)
73 define dso_local i32 @fibonacci(i32 %n) {
74     entry:

```

```

75     %cmp = icmp sle i32 %n, 1
76     br i1 %cmp, label %base_case, label %recursive_case
77
78     base_case:
79     ret i32 %n
80
81     recursive_case:
82     %n_minus_1 = sub nsw i32 %n, 1
83     %fib_n_1 = call i32 @fibonacci(i32 %n_minus_1)
84
85     %n_minus_2 = sub nsw i32 %n, 2
86     %fib_n_2 = call i32 @fibonacci(i32 %n_minus_2)
87
88     %result = add nsw i32 %fib_n_1, %fib_n_2
89     ret i32 %result
90 }
91
92 ; 数组求和函数
93 define dso_local i32 @array_sum() {
94     entry:
95     br label %for.cond
96
97     for.cond:
98     %sum.0 = phi i32 [ 0, %entry ], [ %sum.1, %for.body ]
99     %i.0 = phi i32 [ 0, %entry ], [ %i.1, %for.body ]
100
101     %cmp = icmp slt i32 %i.0, 5
102     br i1 %cmp, label %for.body, label %for.end
103
104     for.body:
105     %arrayidx = getelementptr inbounds [5 x i32], [5 x i32]* @array, i64 0, i32 %i.0
106     %load_val = load i32, i32* %arrayidx, align 4
107     %sum.1 = add nsw i32 %sum.0, %load_val
108     %i.1 = add nsw i32 %i.0, 1
109     br label %for.cond
110
111     for.end:
112     ret i32 %sum.0
113 }
114
115 ; 主函数
116 define dso_local i32 @main() {
117     entry:
118     ; 获取两个整数输入
119     %a = call i32 @getint()
120     %b = call i32 @getint()
121
122     ; 数值运算测试
123     %arith_result = call i32 @arithmetic_ops(i32 %a, i32 %b)

```

```

124     call void @putint(i32 %arith_result)
125     call void @putch(i32 10)    ; 换行符
126
127     ; 条件分支测试
128     %cond_a = call i32 @conditional_test(i32 %a)
129     call void @putint(i32 %cond_a)
130     call void @putch(i32 10)
131
132     %cond_b = call i32 @conditional_test(i32 %b)
133     call void @putint(i32 %cond_b)
134     call void @putch(i32 10)
135
136     ; 循环测试
137     %n = call i32 @getint()
138
139     %while_result = call i32 @while_loop(i32 %n)
140     call void @putint(i32 %while_result)
141     call void @putch(i32 10)
142
143     ; 递归测试 (限制输入范围)
144     %small_check = icmp sle i32 %n, 10
145     br i1 %small_check, label %do_fibonacci, label %skip_fibonacci
146
147     do_fibonacci:
148     %fib_result = call i32 @fibonacci(i32 %n)
149     call void @putint(i32 %fib_result)
150     call void @putch(i32 10)
151     br label %array_test
152
153     skip_fibonacci:
154     br label %array_test
155
156     array_test:
157     ; 数组测试
158     %array_result = call i32 @array_sum()
159     call void @putint(i32 %array_result)
160     call void @putch(i32 10)
161
162     ; 全局变量测试
163     %global_val = load i32, i32* @global_var, align 4
164     call void @putint(i32 %global_val)
165     call void @putch(i32 10)
166
167     ret i32 0
168 }

```

编译并测试成功，如下图所示

```

nuo@wyn:~/project/arm-work/work1/sysy-arm$ clang -o lltest sysy_manual.ll libsysy_x86.a
nuo@wyn:~/project/arm-work/work1/sysy-arm$ ./lltest
5
4
32
1
1
10
55
55
15
10

```

5.3 ARM 汇编编写

要编写与源代码等价的、能正确运行的汇编代码，应满足以下要求：

- 语义等价性：ARM 汇编完全保持了 C 语言的执行语义
- 控制流映射：while 循环被转换为条件分支 + 跳转的组合
- 数据流保持：变量的生命周期和数据依赖关系得到正确维护
- 调用约定遵循：正确使用 ARM 约定进行参数传递和返回值处理

接下来以循环函数 while_loop 的汇编编写为例探究汇编代码的编写：

1. 先对这段程序进行简单的语义分析：

- 输入：整数 n
- 输出：1+2+3+...+n 的和
- 算法流程：
 - 初始化 sum=0, i=1
 - 检查条件 i <= n
 - 如果条件成立：sum += i, i++, 跳转到步骤 2
 - 如果条件不成立：返回 sum

2.ARM 汇编逐步转换：

函数框架设计

```

1  .align 2
2  .global while_loop
3  .type while_loop, %function
4  while_loop:
5  // 函数入口 - w0包含参数n
6  // 需要决定：用寄存器还是栈来存储局部变量？
7  // 这个简单函数可以全部用寄存器
8
9  // 返回值通过w0寄存器返回
10 ret

```

接着确定寄存器分配：

- w0: 输入参数 n，后续用作返回值
- w1: sum 变量
- w2: i 变量

循环条件检查

```

1  .L_while_cond:
2      cmp w2, w0          // compare i with n
3      bgt .L_while_end    // if i > n, exit
4      //后面是循环体

```

cmp w2, w0 执行 w2-w0 并设置条件标志

bgt 检查有符号比较结果，如果 $i > n$ 执行跳转

否则顺序执行到循环体

循环体实现

```

1      add w1, w1, w2      // sum += i
2      add w2, w2, #1      // i++
3      b .L_while_cond

```

add w1, w1, w2: 目标寄存器 $w1 = w1 + w2$

add w2, w2, #1: i 自增 1，立即数加法

b .L_while_cond: 无条件跳转回条件检查

循环结束和返回

```

1  .L_while_end:
2      mov w0, w1          // return sum
3      ret

```

返回值约定:w0 用于返回 32 位整数

需要将结果从 w1 移动到 w0

完整 ARM 汇编实现

```

1  .arch armv8-a
2  .text
3
4  // SysY运行库函数声明
5  .extern getint
6  .extern putint
7  .extern putchar
8
9  // 全局变量定义
10 .section .data
11 .align 2
12 .global global_var
13 global_var:
14     .word 10
15
16 .global array
17 array:
18     .word 1, 2, 3, 4, 5
19

```

```
20 .text
21
22 // 数值运算函数
23 .align 2
24 .global arithmetic_ops
25 .type arithmetic_ops, %function
26 arithmetic_ops:
27     // w0 = a, w1 = b
28     add w2, w0, w1          // sum = a + b
29     sub w3, w0, w1          // diff = a - b
30     mul w4, w0, w1          // prod = a * b
31     sdiv w5, w0, w1          // quot = a / b
32     msub w6, w5, w1, w0      // mod = a - (quot * b)
33
34     add w7, w2, w3          // temp1 = sum + diff
35     add w7, w7, w4          // temp2 = temp1 + prod
36     add w7, w7, w5          // temp3 = temp2 + quot
37     add w0, w7, w6          // result = temp3 + mod
38
39     ret
40
41 // 条件分支函数
42 .align 2
43 .global conditional_test
44 .type conditional_test, %function
45 conditional_test:
46     cmp w0, #0
47     bgt .L_positive
48     blt .L_negative
49
50 .L_zero:
51     mov w0, #0
52     ret
53
54 .L_positive:
55     mov w0, #1
56     ret
57
58 .L_negative:
59     mov w0, #-1
60     ret
61
62 // while 循环函数
63 .align 2
64 .global while_loop
65 .type while_loop, %function
66 while_loop:
67     mov w1, #0              // sum = 0
68     mov w2, #1              // i = 1
```



```

69
70 .L_while_cond:
71     cmp w2, w0          // compare i with n
72     bgt .L_while_end    // if i > n, exit
73
74     add w1, w1, w2       // sum += i
75     add w2, w2, #1       // i++
76     b .L_while_cond
77
78 .L_while_end:
79     mov w0, w1          // return sum
80     ret
81
82 // 递归函数 (斐波那契)
83 .align 2
84 .global fibonacci
85 .type fibonacci, %function
86 fibonacci:
87     stp x29, x30, [sp, #-32]!
88     mov x29, sp
89     str w0, [sp, #28]    // 保存 n
90
91     cmp w0, #1
92     ble .L_fib_base
93
94     sub w0, w0, #1       // n-1
95     bl fibonacci         // fib(n-1)
96     str w0, [sp, #24]    // 保存 fib(n-1)
97
98     ldr w0, [sp, #28]    // 加载 n
99     sub w0, w0, #2       // n-2
100    bl fibonacci         // fib(n-2)
101
102    ldr w1, [sp, #24]     // 加载 fib(n-1)
103    add w0, w0, w1        // fib(n-1) + fib(n-2)
104    b .L_fib_end
105
106 .L_fib_base:
107     ldr w0, [sp, #28]    // 返回 n (0 或 1)
108
109 .L_fib_end:
110     ldp x29, x30, [sp], #32
111     ret
112
113 // 数组求和函数
114 .align 2
115 .global array_sum
116 .type array_sum, %function
117 array_sum:

```

```

118     adrp x1, array           // 获取数组地址
119     add x1, x1, :lo12:array
120
121     mov w0, #0               // sum = 0
122     mov w2, #0               // i = 0
123
124 .L_array_loop:
125     cmp w2, #5               // compare i with 5
126     bge .L_array_end        // if i >= 5, exit
127
128     ldr w3, [x1, w2, uxtw #2] // 加载 array[i]
129     add w0, w0, w3           // sum += array[i]
130     add w2, w2, #1           // i++
131     b .L_array_loop
132
133 .L_array_end:
134     ret
135
136 // 主函数
137 .align 2
138 .global main
139 .type main, %function
140 main:
141     stp x29, x30, [sp, #-48]!
142     mov x29, sp
143
144     // 获取输入 a, b
145     bl getint
146     str w0, [sp, #20]        // 保存 a
147
148     bl getint
149     str w0, [sp, #24]        // 保存 b
150
151     // 数值运算测试
152     ldr w0, [sp, #20]        // 加载 a
153     ldr w1, [sp, #24]        // 加载 b
154     bl arithmetic_ops
155     bl putint
156     mov w0, #10
157     bl putch                 // 换行
158
159     // 条件分支测试
160     ldr w0, [sp, #20]        // 加载 a
161     bl conditional_test
162     bl putint
163     mov w0, #10
164     bl putch
165
166     ldr w0, [sp, #24]        // 加载 b

```

```
167     bl conditional_test
168     bl putint
169     mov w0, #10
170     bl putch
171
172     // 获取n用于循环测试
173     bl getint
174     str w0, [sp, #28]          // 保存n
175
176     // while循环测试
177     ldr w0, [sp, #28]
178     bl while_loop
179     bl putint
180     mov w0, #10
181     bl putch
182
183     // 递归测试（限制范围）
184     ldr w0, [sp, #28]
185     cmp w0, #10
186     bgt .L_skip_fib
187
188     bl fibonacci
189     bl putint
190     mov w0, #10
191     bl putch
192
193     .L_skip_fib:
194     // 数组测试
195     bl array_sum
196     bl putint
197     mov w0, #10
198     bl putch
199
200     // 全局变量测试
201     adrp x0, global_var
202     add x0, x0, :lo12:global_var
203     ldr w0, [x0]
204     bl putint
205     mov w0, #10
206     bl putch
207
208     mov w0, #0
209     ldp x29, x30, [sp], #48
210     ret
```

编译并测试成功，如下图所示

```
nuo@wyn:~/project/arm-work/work1/sysy-arm$ aarch64-linux-gnu-gcc -o armtest.out sysy_arm.s libsysy_aarch.a
nuo@wyn:~/project/arm-work/work1/sysy-arm$ qemu-aarch64 -L /usr/aarch64-linux-gnu ./armtest.out
5
4
32
1
1
10
55
55
15
10
```

6 结论

本实验通过对编译工具链的深入研究和实践操作,系统地掌握了从源代码到可执行程序的完整转换过程。主要完成了以下工作和认识:

1. 编译流程的深入理解: 通过对阶乘程序的逐步分析,清晰地观察到预处理器如何展开宏定义和头文件、编译器如何进行词法语法分析并生成抽象语法树、如何转换为 LLVM IR 中间表示、如何生成目标平台的汇编代码,以及汇编器和链接器如何协同工作最终生成可执行文件。每个阶段的输出都得到了详细分析,加深了对编译原理的理解。

2.LLVM IR 编程实践: 成功设计并实现了包含 SysY 语言核心特性的 LLVM IR 程序,涵盖了算术运算、条件分支、while 循环、递归、数组操作等语言特性。通过手工编写 IR 代码,深刻理解了 SSA 形式、基本块、phi 节点等中间表示的核心概念,以及 LLVM 如何通过平台无关的中间表示实现前后端分离。

3.ARM 汇编编程实践: 完成了与源程序语义等价的 ARM 汇编代码编写,正确实现了寄存器分配、栈帧管理、函数调用约定、控制流转换等底层细节。通过汇编编程,理解了高级语言特性如何映射到机器指令层面,以及调用约定、栈保护等运行时机制的实现。

4. 理论与实践的结合: 实验不仅验证了理论知识,更通过实际操作加深了理解。手工编写的 LLVM IR 和 ARM 汇编程序均能成功链接 SysY 运行库并正确执行,证明了对编译原理核心概念的准确把握。

通过本次实验,不仅掌握了编译器的工作原理和实现技术,更培养了系统思维和工程实践能力,为后续的编译器设计与实现课程打下了坚实基础。