

基于深度学习的端到端语音识别研究进展

强博

南开大学 学号: 2313825

摘要 自动语音识别 (Automatic Speech Recognition, ASR) 是语音信息处理领域的重要研究方向, 也是实现智能语音交互、自然语言理解 and 多模态人工智能的重要基础技术。近年来, 随着深度学习、大规模预训练模型以及自监督学习技术的快速发展, 端到端语音识别逐渐取代传统统计建模方法, 成为当前学术界和工业界的研究热点。本文围绕端到端语音识别技术的发展历程, 对传统HMM-GMM模型、深度学习声学模型、连接时序分类 (CTC)、注意力编码器-解码器 (AED)、循环神经网络转换器 (RNN-T)、Transformer、Conformer以及基于wav2vec 2.0、Whisper、SenseVoice等语音基础模型的代表性方法进行了系统梳理与分析, 总结了各类方法的基本原理、技术特点及适用场景。在此基础上, 分析了当前语音识别技术在复杂噪声环境、低资源语言、模型部署、多模态融合以及模型安全性等方面面临的主要挑战, 并对大规模语音基础模型、自监督学习、多模态融合、轻量化部署及可信人工智能等未来发展方向进行了展望。本文旨在为端到端语音识别技术的研究与应用提供系统性的参考, 为后续相关研究提供理论依据和研究思路。

关键词 自动语音识别; 端到端语音识别; Transformer; Conformer; 语音基础模型

1 引言

随着人工智能技术的快速发展, 语音作为人类最自然、最便捷的信息交互方式之一, 在智能终端、人机交互、智能客服、车载系统及数字人等场景中得到了广泛应用。自动语音识别 (Automatic Speech Recognition, ASR) 旨在将连续的语音信号自动转换为对应的文本, 是语音信息处理领域最核心的研究方向之一, 也是实现自然语言理解、语音翻译、智能问答等上层应用的重要基础。近年来, 随着计算能力的提升、大规模语音数据集的开放以及深度学习技术的不断发展, 语音识别系统的性能得到了显著提升, 推动了相关产业的快速发展。

传统语音识别系统通常采用隐马尔可夫模型 (Hidden Markov Model, HMM) 与高斯混合模型 (Gaussian Mixture Model, GMM) 相结合的框架, 并依赖复杂的发音词典、语言模型及人工设计的声学特征。虽然该类方法在较长时间内取得了良好的应用效果, 但其模块之间相互独立, 训练过程复杂, 误差难以进行全局优化, 同时对于复杂环境和跨领域场景的泛化能力有限。随着深度神经网络 (Deep Neural Network, DNN) 的提出, 研究者逐

渐将深度学习引入声学建模, 并进一步推动语音识别向端到端 (End-to-End) 建模方向发展, 使模型能够直接完成从语音信号到文本序列的映射, 大幅降低了系统设计复杂度。

近年来, 端到端语音识别技术取得了快速发展。以连接时序分类 (Connectionist Temporal Classification, CTC)、注意力编码器-解码器 (Attention-based Encoder-Decoder, AED)、循环神经网络转换器 (RNN-Transducer, RNN-T) 等为代表的方法相继提出, 并逐渐成为语音识别研究的主流方向。在此基础上, Transformer、Conformer等网络结构进一步提升了模型对长距离时序依赖关系和局部声学特征的建模能力。与此同时, 以wav2vec 2.0为代表的自监督学习方法有效缓解了标注语音数据不足的问题, 而Whisper、SenseVoice等大规模预训练基础模型则进一步推动语音识别向大模型、多语言、多任务和强泛化能力方向发展, 使语音识别系统在复杂噪声环境、跨语言及低资源场景下均表现出较强的鲁棒性。

尽管近年来语音识别技术取得了显著进展, 但在低资源语言识别、口音适应、噪声鲁棒性、实时

流式识别、多模态融合以及大模型高效部署等方面仍面临诸多挑战。因此，有必要对近年来端到端语音识别的发展脉络、关键技术及未来趋势进行系统梳理和总结。

本文围绕端到端语音识别技术的发展历程展开综述，首先介绍语音识别的发展背景及研究现状；随后按照CTC、AED、RNN-T、Transformer、Conformer、自监督学习以及语音基础模型等技术路线，对近年来代表性研究工作进行分类分析与比较；最后总结当前研究存在的问题，并对未来的发展方向进行展望，以期对相关研究人员和工程实践提供参考。

2 问题定义

自动语音识别（Automatic Speech Recognition, ASR）是语音信息处理领域的重要研究方向，其目标是将输入的连续语音信号自动转换为对应的文本序列，从而实现人与计算机之间基于自然语言的高效交互。作为语音智能技术的重要基础，语音识别广泛应用于智能语音助手、语音输入、智能客服、会议记录、车载语音交互、实时字幕以及语音翻译等场景，并为自然语言处理、语音合成和多模态人工智能等任务提供基础支撑。从数学角度来看，语音识别本质上是一个序列到序列（Sequence-to-Sequence）的映射问题。设输入语音信号表示为声学特征序列 $X = \{x_1, x_2, \dots, x_T\}$ 其中， (x_t) 表示第 (t) 帧语音特征， (T) 为语音帧数；输出文本序列表示为 $Y = \{y_1, y_2, \dots, y_N\}$ 其中， (y_i) 表示第 i 个文本符号（字符、拼音或子词）， N 为输出序列长度。由于语音帧数通常远大于文本长度，且输入与输出之间不存在显式对应关系，因此语音识别需要学习条件概率 $P(Y | X)$ 即在给定语音信号条件下生成最可能的文本序列。传统语音识别系统通常采用声学模型、发音词典和语言模型相结合的级联框架，各模块分别进行训练和优化。这种方法虽然具有较高的稳定性，但系统结构复杂、误差传播明显，并且难以实现全局最优。近年来，随着深度学习的发展，端到端语音识别模型能够直接学

习从语音到文本的映射关系，减少人工设计模块，提高训练效率和识别性能，逐渐成为当前研究的主流方向。为了客观评价语音识别系统的性能，通常采用词错误率（Word Error Rate, WER）和字符错误率（Character Error Rate, CER）作为主要评价指标。其中，WER主要适用于英文等以单词为基本单位的语言，CER则广泛应用于中文语音识别任务。两种指标均综合考虑替换（Substitution）、删除（Deletion）和插入（Insertion）三类错误，其计算公式为 $WER(CER) = \frac{S+D+I}{N}$ 其中， S 、 D 和 I 分别表示替换、删除和插入错误的数量， N 表示参考文本中的词数（或字符数）。WER（或CER）越低，说明语音识别系统的性能越好。综上所述，自动语音识别的核心任务是在复杂、多变的语音环境中准确建立语音信号与文本序列之间的映射关系，并在保证识别精度的同时兼顾实时性、鲁棒性和泛化能力。近年来，随着端到端建模、自监督学习和语音基础模型的发展，语音识别技术不断取得突破，为智能语音交互系统的发展提供了重要支撑。

3 语音识别发展历程

自动语音识别（Automatic Speech Recognition, ASR）的研究始于20世纪50年代，其目标是将连续语音信号自动转换为对应的文本序列。经过几十年的发展，语音识别技术经历了从传统统计模型到深度学习，再到大规模预训练模型的发展过程，系统性能和应用范围均得到了显著提升。总体来看，语音识别的发展可以划分为传统统计建模阶段、深度学习建模阶段、端到端建模阶段以及语音基础模型阶段。

3.1 传统统计模型阶段

20世纪80年代至2010年前后，语音识别系统主要采用隐马尔可夫模型（Hidden Markov Model, HMM）结合高斯混合模型（Gaussian Mixture Model, GMM）的经典框架。该方法利用HMM描述语音序列的时间变化规律，采用GMM建立声学特征与语音状态之间的概率分布，同时结合发音词

典和N-gram语言模型完成解码过程。

HMM-GMM框架具有理论成熟、工程实现稳定等优点，在连续语音识别领域长期占据主导地位。然而，该方法需要分别训练声学模型、发音词典和语言模型，各模块之间相互独立，难以实现全局优化。同时，GMM对于复杂非线性特征的建模能力有限，在复杂噪声环境和大规模数据集上的性能逐渐达到瓶颈。

3.2 深度学习建模阶段

2012年前后，深度神经网络（Deep Neural Network, DNN）的成功应用推动了语音识别技术进入深度学习时代。研究者利用DNN替代传统GMM进行声学建模，形成DNN-HMM混合模型。相比于GMM，DNN能够学习更加复杂的非线性映射关系，显著提升了声学特征表示能力，使语音识别错误率大幅下降。

随后，卷积神经网络（CNN）、循环神经网络（RNN）以及长短时记忆网络（LSTM）相继被引入语音识别任务。其中，CNN能够提取局部频谱特征，提高模型对噪声和频率变化的鲁棒性；RNN和LSTM则能够建模语音信号中的长时间依赖关系，进一步提升连续语音识别性能。这一阶段虽然仍采用HMM进行序列建模，但深度学习已经成为语音识别系统的核心组成部分。

3.3 端到端语音识别阶段

随着计算能力和训练数据规模的不断提升，研究者开始探索端到端（End-to-End）语音识别模型。端到端方法能够直接建立语音信号到文本序列之间的映射关系，不再依赖复杂的发音词典和人工设计模块，从而简化了系统结构，提高了整体优化能力。

连接时序分类（Connectionist Temporal Classification, CTC）首次解决了输入语音与输出文本之间无需帧级对齐的问题，为端到端语音识别奠定了基础。随后，基于注意力机制（Attention）的编码器—解码器（Attention Encoder-Decoder, AED）模型进一步增强了模型对长距离依赖关系

的建模能力，实现了更加灵活的序列生成。与此同时，RNN-Transducer（RNN-T）结合了CTC和序列建模的优势，兼顾了识别精度与实时性能，目前已广泛应用于移动设备和在线语音识别系统。

3.4 Transformer与Conformer阶段

2017年，Transformer结构提出后，其基于自注意力机制（Self-Attention）的建模方式有效解决了传统RNN难以并行计算和长距离依赖建模不足的问题，很快成为语音识别的重要基础网络。Transformer能够充分利用全局上下文信息，提高模型对长语音序列的建模能力。

然而，Transformer对局部声学模式的建模能力相对不足。为此，Conformer在Transformer基础上融合卷积神经网络结构，在保持全局建模能力的同时增强了局部特征提取能力，实现了全局信息与局部信息的协同建模。由于兼具较高的识别精度和较好的计算效率，Conformer目前已成为学术界和工业界最广泛采用的语音识别主干网络之一，并被WeNet等主流开源框架广泛采用。

3.5 语音基础模型阶段

近年来，大规模预训练技术推动语音识别进入基础模型（Foundation Model）时代。以wav2vec 2.0、HuBERT等自监督学习模型为代表的方法，利用海量未标注语音数据学习高质量语音表示，有效缓解了人工标注数据不足的问题，在低资源语种和跨领域任务中取得了优异性能。

随着大模型技术的发展，Whisper、SenseVoice等语音基础模型进一步融合了多语言、多任务学习能力，不仅能够完成自动语音识别，还支持语音翻译、语种识别、情感识别等多种任务，在复杂噪声环境、跨语言场景及开放领域应用中表现出较强的泛化能力。这标志着语音识别技术正由单一任务模型向统一语音智能基础模型方向发展，为未来语音交互系统提供了新的技术路径。

总体而言，语音识别技术的发展经历了“统计建模—深度学习—端到端建模—基础模型”四个主要阶段。模型结构不断简化，表示能力持续增强，

训练方式由监督学习逐渐扩展到自监督学习和大规模预训练。未来，如何进一步提升模型在低资源、复杂环境、多语言及实时部署等场景下的性能，仍然是语音识别领域的重要研究方向。

4 存在问题

尽管近年来自动语音识别技术在模型结构、训练范式和应用落地等方面取得了显著进展，但从实际应用需求来看，现有方法仍然面临复杂环境适应性、数据资源依赖、模型部署效率以及系统可信性等方面的挑战。

首先，复杂声学环境下的识别鲁棒性仍有待进一步提升。当前主流语音识别模型在公开数据集和相对理想的录音条件下已表现出较高的识别准确率，但在强噪声、混响、远场采集、多人交谈以及说话人重叠等真实场景中，模型性能仍会出现明显下降。与此同时，不同麦克风设备、采样条件和录音环境所造成的声学分布差异，也会削弱模型在跨设备、跨场景应用中的泛化能力。

其次，低资源语言、方言及口音场景下的建模能力仍然不足。高性能语音识别系统通常依赖大规模标注语音数据进行训练，而对于少数民族语言、方言以及专业领域语音数据而言，可用标注资源相对有限，导致模型难以充分学习其声学特征和语言规律。此外，不同地区说话人在口音、语速、发音习惯和表达方式上的差异，也进一步增加了语音识别系统的建模难度。

再次，大规模预训练模型在提升识别性能的同时，也带来了较高的计算和部署成本。以 Whisper、SenseVoice 等为代表的语音基础模型通过大规模数据训练显著增强了模型的泛化能力，但其参数规模和计算复杂度通常较高，对 GPU 算力、存储空间和推理延迟提出了更高要求。这在一定程度上限制了其在移动终端、车载系统和边缘设备等资源受限场景中的实际应用。

此外，多模态信息的有效利用仍不充分。人类在语音交流过程中往往会结合唇形、表情、手势及上下文信息进行理解，而现有多数语音识别系统仍

主要依赖单一语音模态。当语音信号受到噪声、遮挡或信息缺失影响时，单模态模型难以充分利用视觉和语义信息进行补偿。因此，如何实现语音、视觉和文本等多源信息的协同建模，是提升复杂场景下识别鲁棒性的关键问题之一。

最后，模型可解释性、安全性和可信性仍需加强。深度神经网络模型通常具有较强的非线性表达能力，但其决策过程缺乏透明性，难以解释具体识别错误产生的原因。随着语音识别系统逐渐应用于金融、医疗、司法和政务等高可靠性场景，语音深度伪造、对抗样本攻击、隐私泄露等问题也对系统安全提出了更高要求。因此，构建可解释、可验证、可防护的可信语音识别系统，已成为自动语音识别进一步发展必须解决的重要问题。

5 未来发展方向

针对上述问题，未来自动语音识别技术的发展将更加注重模型泛化能力、数据利用效率、多模态融合能力、部署效率以及系统可信性的协同提升。

大规模语音基础模型将成为自动语音识别发展的重要方向。随着预训练技术和大规模语音数据资源的不断发展，语音识别模型将逐步从单一任务建模转向统一语音基础模型建模。未来模型不仅需要完成语音转文本任务，还应具备语音翻译、说话人识别、情感识别、语音问答和语音理解等多种能力，从而实现跨任务、跨语言和跨场景的统一表征学习。通过多任务学习和指令化建模，语音基础模型有望进一步提升系统的泛化能力和应用适应性。

利用海量未标注语音数据进行自监督预训练，可以有效降低对人工标注数据的依赖，并增强模型对不同语言、方言和领域语音的适应能力。在此基础上，结合迁移学习、持续学习、少样本学习和领域自适应等方法，有望进一步缓解低资源语音识别中的数据稀缺问题，提高模型在跨领域、跨口音和跨语种场景下的泛化性能。

通过联合建模语音、视频、文本及上下文信息，模型可以利用唇形、表情、语义上下文等辅助信息弥补单一语音模态在复杂环境下的不足。尤其

是在强噪声、远场会议、智能座舱和数字人交互等场景中，多模态信息融合有助于提升系统的鲁棒性和交互自然性。未来研究需要进一步解决多模态特征对齐、跨模态信息融合、模态缺失补偿以及实时推理等关键问题。

随着语音识别技术逐渐向智能终端、车载设备、可穿戴设备和物联网系统扩展，模型需要在有限计算资源和功耗约束下实现实时、稳定的语音识别。未来可通过模型压缩、知识蒸馏、参数共享、低比特量化和高效推理框架等技术，在尽可能保持识别性能的同时降低计算开销，从而推动语音识别系统在边缘侧和端侧场景中的广泛部署。

未来研究也需要从模型可解释性、隐私保护、鲁棒性评估和安全防御等多个层面提升系统可信程度。一方面，应发展更加透明和可分析的模型解释方法，帮助研究者理解模型错误来源；另一方面，也需要加强对语音伪造、对抗攻击和隐私泄露等风险的检测与防护。通过构建安全、可靠、可控的语音识别系统，可进一步提升其在金融、医疗、教育和公共服务等领域的应用价值。

6 结论

自动语音识别是语音信息处理领域的重要研究方向，也是实现自然人机交互的关键基础技术。近年来，在深度学习、大规模预训练模型和自监督学习等技术推动下，语音识别系统经历了从传统HMM-GMM框架到端到端建模，再到Transformer、Conformer以及Whisper、SenseVoice等语音基础模型的发展过程。相关技术在识别精度、模型泛化能力和应用范围等方面均取得了显著提升。

本文围绕自动语音识别技术的发展脉络，对CTC、Attention、RNN-T、Transformer、Conformer、自监督学习及语音基础模型等主流方法进行了系统梳理，并结合当前研究现状分析了复杂环境识别、低资源学习、模型部署、多模态融合以及系统可信性等方面存在的主要问题。在此基础上，进一步讨论了自动语音识别未来可能的发展趋势。

总体而言，未来语音识别技术将朝着基础模型化、多模态化、轻量化和可信化方向持续演进，并与自然语言处理、多模态学习和生成式人工智能等技术深度融合。随着算法能力、算力条件和数据资源的不断提升，自动语音识别将在智能助手、数字人、智能座舱、医疗健康、教育培训和公共服务等领域发挥更加重要的作用，为构建更加自然、高效和可靠的人机交互方式提供有力支撑。

参考文献

- [1] Graves A, Fernández S, Gomez F, Schmidhuber J. Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks. In: Proceedings of the International Conference on Machine Learning, 2006: 369–376.
- [2] Graves A, Mohamed A, Hinton G. Speech Recognition with Deep Recurrent Neural Networks. In: IEEE International Conference on Acoustics, Speech and Signal Processing, 2013: 6645–6649.
- [3] Chan W, Jaitly N, Le Q, Vinyals O. Listen, Attend and Spell: A Neural Network for Large Vocabulary Conversational Speech Recognition. In: IEEE International Conference on Acoustics, Speech and Signal Processing, 2016: 4960–4964.
- [4] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need. In: Proceedings of the 31st International Conference on Neural Information Processing Systems, 2017: 6000–6010.
- [5] Rao K, Sak H, Prabhavalkar R. Exploring Architectures, Data and Units for Streaming End-to-End Speech Recognition with RNN-Transducer. In: IEEE Automatic Speech Recognition and Understanding Workshop, 2017: 193–199.
- [6] Gulati A, Qin J, Chiu C C, et al. Conformer: Convolution-Augmented Transformer for Speech Recognition. arXiv preprint arXiv:2005.08100, 2020.
- [7] Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. IEEE/ACM Transactions on

- Audio, Speech, and Language Processing, 2021, 29: 3451–3460.
- [8] Wu D, Zhang B, Yang C, et al. U2++: Unified Two-Pass Bidirectional End-to-End Model for Speech Recognition. arXiv preprint arXiv:2106.05642, 2021.
- [9] Radford A, Kim J W, Xu T, et al. Robust Speech Recognition via Large-Scale Weak Supervision. In: Proceedings of the 40th International Conference on Machine Learning, 2023.
- [10] Zhang B, Wu D, Peng Z, et al. WeNet 2.0: More Productive End-to-End Speech Recognition Toolkit. 2022.
- [11] Yao Z, Wu D, Wang X, et al. WeNet: Production Oriented Streaming and Non-Streaming End-to-End Speech Recognition Toolkit. arXiv preprint arXiv:2102.01547, 2021.
- [12] Watanabe S, Hori T, Kim S, Hershey J R, Hayashi T. Hybrid CTC/Attention Architecture for End-to-End Speech Recognition. IEEE Journal of Selected Topics in Signal Processing, 2017, 11(8): 1240–1253.

端到端自动语音识别研究综述：从 CTC/Attention 到 Conformer、自监督预训练与中文多模态识别

王一诺

南开大学 学号: 2312331

摘要 自动语音识别旨在将连续语音信号转换为文本，是语音信息处理中的核心任务。近年来，语音识别从以声学模型、发音词典和语言模型为中心的混合系统，逐步发展为以端到端神经网络为主的统一建模框架。本文围绕 15 篇代表性文献，对端到端自动语音识别的发展脉络进行综述。首先从问题定义出发，分析语音识别面临的帧级对齐缺失、输入输出长度不一致、噪声与口音变化、低资源标注和流式延迟等挑战。随后梳理 CTC、attention encoder-decoder、联合 CTC-Attention 等主要建模范式，比较其训练稳定性、上下文建模能力和流式适配性。本文还讨论了 ContextNet、Conformer 和 E-Branchformer 等编码器结构的演进，以及 SpecAugment 和 HuBERT 在数据增强、自监督预训练方面的作用。进一步地，本文总结 ESPnet、WeNet、U2++ 和 Paraformer 所体现的可复现工具链、流式部署和高效推理趋势。最后，结合 AISHELL-1、音视频 Conformer 和 Chinese-LiPS，讨论中文语音识别与多模态鲁棒识别的发展方向。本文认为，当前 ASR 的核心趋势已经从单一模型精度竞争，转向面向真实场景的“高准确率、低延迟、低标注成本、强鲁棒性和多模态上下文利用”的综合优化。

关键词 自动语音识别；端到端语音识别；CTC；Conformer；自监督学习；中文语音识别；多模态识别

1 引言

自动语音识别 (Automatic Speech Recognition, ASR) 的目标是把语音波形或声学特征序列转换为文字序列。传统 ASR 通常由声学模型、发音词典和语言模型组成，典型系统以 HMM-GMM 或 DNN-HMM 为基础，通过复杂的帧级状态对齐、上下文相关建模和解码图搜索完成识别。这类方法工程上成熟，但模块较多，误差容易在不同组件之间传播，也需要大量专家知识调参。深度学习推动 ASR 从模块化系统转向端到端系统：模型直接学习从输入声学序列到输出字符、词或子词序列的映射，从而减少手工对齐和复杂词典设计。

端到端 ASR 的早期突破来自循环神经网络与 CTC 目标的结合。Graves 等人使用深层双向 LSTM 进行语音识别，展示了深度循环网络对长时语音上下文建模的能力^[1]。随后，Listen, Attend and Spell (LAS) 将 attention encoder-decoder 引入语音识别，使模型能够以自回归方式直接生成字符序列^[2]。由于 CTC 和 attention 各有短板，联合 CTC-Attention 框架

进一步通过多任务学习和联合解码，从而兼顾单调对齐与上下文建模^[3]。近年来，Conformer、自监督预训练、非自回归解码和多模态建模持续刷新 ASR 的准确率和部署能力。

本文选取的文献覆盖端到端 ASR 的主要技术链条：早期序列建模、CTC/Attention 范式、工具链与训练策略、现代编码器、自监督预训练、流式部署、高效非自回归推理、中文公开数据集以及音频-视觉多模态识别。与按年份罗列论文不同，本文按问题和方法分类展开，重点讨论不同技术路线解决了什么问题以及仍留下什么限制。

2 问题定义与核心挑战

从形式上看，ASR 可表示为：给定输入语音序列 $X = (x_1, \dots, x_T)$ ，模型需要输出文本序列 $Y = (y_1, \dots, y_L)$ ，目标是寻找

$$\hat{Y} = \arg \max_Y P(Y|X).$$

其中 T 通常远大于 L ，且语音帧与文字之间没有天然的一一对应关系。因此，ASR 的第一个难点是未

对齐序列学习：模型既要识别内容，又要隐式学习语音片段与输出符号之间的对齐。

第二个难点是真实环境下的鲁棒性。真实语音会受到噪声、混响、远场录音、设备差异、语速变化、口音、方言和说话人年龄等因素影响。相同文字在不同说话人和环境下的声学表现差异很大，而同音词和近音词又要求模型结合语言上下文进行消歧。第三个难点是数据成本。高质量转写需要人工标注，中文方言、儿童语音、老年语音和专业领域语音尤其缺少标注数据。第四个难点是部署。实际系统往往要求低延迟流式识别，不能等整句话结束后再解码；同时，移动端或在线服务还要求模型规模、实时率和能耗可控。

因此，评价 ASR 方法不能只看离线测试集错误率，还应关注训练稳定性、推理速度、流式延迟、对低资源场景的适应能力、对噪声和多说话人场景的鲁棒性，以及是否容易复现和部署。

3 端到端建模范式

3.1 CTC：单调对齐与条件独立

CTC (Connectionist Temporal Classification) 是端到端 ASR 的关键基础。它通过引入 blank 标签和路径求和机制，在没有帧级标注的情况下学习输入帧到输出符号的单调对齐。深层神经网络配合 CTC 的工作表明，BLSTM 可以利用前后文声学信息，CTC 则使模型摆脱显式帧级对齐^[1]。这一路线的优势是训练目标清晰、对齐单调、易于与流式解码结合。

CTC 的主要限制在于条件独立假设。它通常把不同输出时刻的预测近似看作相互独立，因此对字符之间、词之间的语言依赖建模不足。虽然可以通过外部语言模型或重打分弥补，但这也说明 CTC 本身更偏向声学对齐模型，而不是完整的序列生成模型。

3.2 Attention Encoder-Decoder：直接序列生成

LAS 提出 listener 和 speller 结构：listener 将声学帧编码为高层表示，speller 通过 attention 选择相

关声学片段并逐步生成字符^[2]。相比 CTC，AED 模型不再假设输出条件独立，而是通过链式分解显式利用历史输出，因此能把一部分语言模型能力内化到解码器中。

然而，AED 也带来两个问题。第一，attention 对齐虽然灵活，但在长语音、噪声语音或训练数据不足时可能出现跳帧、重复或漏识别。第二，AED 通常是自回归解码，每生成一个 token 都依赖前一个 token，推理速度受限，流式场景下还需要额外设计。

3.3 联合 CTC-Attention：稳定性与表达能力的折中

联合 CTC-Attention 框架将两类目标结合起来：训练时 CTC 帮助 encoder 学习单调对齐，attention decoder 学习输出历史依赖；解码时则融合 CTC 分数和 attention 分数，提高搜索稳定性^[3]。这一思想成为后续 ESPnet、WeNet、U2/U2++ 等系统的重要基础。

表 1 总结了主要建模范式的差异。可以看到，ASR 的核心矛盾并不是某一种目标函数绝对优越，而是对齐、语言上下文、推理速度和流式适配之间的权衡。

表 1 端到端 ASR 主要建模范式比较

范式	主要优势	主要局限
CTC	对齐单调，训练稳定，适合流式	条件独立，语言上下文较弱
AED	序列建模强，可直接生成字符	自回归较慢，对齐可能不稳定
CTC-Att	兼顾对齐约束与上下文建模	解码和调参复杂度增加
RNN-T/U2	支持流式与工业部署	搜索、重打分和延迟需平衡
NAR	并行解码，速度快	输出依赖和长度预测较难

4 架构演进、训练策略与预训练

早期端到端 ASR 大量使用 RNN，尤其是 BLSTM。RNN 适合时序建模，但并行性较差，长序列训练成本高。CNN 结构具有更好的并行性和局部模式提取能力，ContextNet 通过全局上下文增强卷积网络，并与 RNN-T 训练结合，说明卷积结构也

可以在 ASR 中取得强性能^[4]。但纯卷积结构对长距离依赖的灵活建模仍有限。

Transformer 引入 self-attention 后，全局依赖建模能力显著增强，但语音信号还具有很强的局部连续性，例如音素内部的短时变化、共振峰轨迹和发音过渡。Conformer 的重要贡献就在于把卷积模块嵌入 Transformer block，使模型同时拥有 self-attention 的全局建模能力和卷积的局部建模能力^[5]。从后续大量工作看，Conformer 已成为现代 ASR encoder 的主流选择之一。

E-Branchformer 进一步反思局部和全局信息的融合方式。它不再简单串联自注意力和卷积，而是通过分支分别建模全局与局部上下文，再利用增强合并模块融合^[6]。这说明当前 ASR 架构优化已经从“换一个网络”发展到更细致地设计局部、全局和融合路径。

除模型结构外，训练策略同样关键。SpecAugment 在频谱特征上进行时间遮蔽、频率遮蔽和时间扭曲，不改变标签却能显著增强模型鲁棒性^[7]。它的启发是：ASR 模型容易过拟合局部频带或短时片段，适当遮蔽可迫使模型利用更稳定的上下文信息。HuBERT 则代表自监督预训练路线。它先通过聚类获得离散伪标签，再让模型预测被遮蔽语音片段对应的隐藏单元，从大量无标注语音中学习通用表示^[8]。对中文方言、儿童语音、老年语音等低资源场景而言，自监督预训练比单纯扩大人工标注更现实。

5 工具链、流式部署与高效推理

端到端 ASR 的发展不仅依赖模型论文，也依赖开源工具链。ESPnet 将 CTC、attention、联合 CTC/Attention 等方法整理为可复现实验流程，并提供数据准备、训练、解码和评测 recipe^[9]。这类工具使研究者可以在统一设置下比较模型，也降低了项目和工程实践的门槛。

WeNet 更强调生产可用性。它围绕 U2 框架支持流式与非流式统一训练，通过动态 chunk 训练、CTC first-pass 解码和 attention rescoring，在低延迟

和高精度之间取得折中^[10]。U2++ 则在 U2 的基础上加入从右到左的 decoder 和双向重打分，使第二阶段可以利用更完整的上下文评估候选序列^[11]。这类方法反映了一个工程事实：实际 ASR 系统往往不是单次前向传播结束，而是由候选生成、重打分、语言模型融合和延迟控制共同组成。

自回归解码的速度限制推动了非自回归 ASR。Paraformer 通过 predictor 预测输出 token 数量和隐变量，再并行生成文本，并用 glancing language model sampler 和最小词错误率训练缓解 token 依赖不足的问题^[12]。它说明高效推理不是简单牺牲精度，而是需要重新设计长度预测、上下文补偿和训练目标。对在线会议转写、字幕生成和移动端识别来说，Paraformer 代表了准确率之外的另一个重要方向：吞吐率和实时性。

6 中文 ASR 与多模态鲁棒识别

中文 ASR 还需要考虑语言和数据集特点。AISHELL-1 发布了 400 名说话人、约 170 小时普通话语音，并提供 Kaldi 基线，是中文普通话 ASR 常用公开评测数据集^[13]。它的重要性不只在规模，也在于提供了可复现的数据划分和基线，使后续 WeNet、U2++、Paraformer 等中文系统能够进行公平比较。但 AISHELL-1 主要是相对规范的普通话朗读语音，年轻和北方口音说话人占比较高，不能完全代表方言、儿童、老年人、远场噪声等真实复杂场景。

鲁棒 ASR 的一个前沿方向是多模态识别。基于 Conformer 的端到端音频-视觉语音识别模型直接从原始波形和嘴部图像序列学习特征，再融合音频和视觉表示进行识别^[14]。其意义在于，当音频被噪声污染时，嘴唇运动仍能提供发音线索。实验也表明，音视频模型在高噪声条件下比单纯音频模型退化更慢。

Chinese-LiPS 进一步将中文 AVSR 从“听声音 + 看嘴型”扩展到“听声音 + 看嘴型 + 看演示文稿”^[15]。该数据集包含约 100 小时中文语音、嘴部视频、幻灯片视频和人工转写。论文提出的 LiPS-AVSR 利用 AV-HuBERT 提取唇读特征，用 OCR 和

视觉语言模型提取幻灯片关键词，再接入 Whisper 系统。实验显示，speech-only 的 CER 为 3.99%，加入全部视觉信息后降至 2.58%。更细的错误分析表明，唇读主要减少删除错误，幻灯片信息主要减少专业术语和专有名词的替换错误。这一结果对课堂、会议、演讲和科普视频识别尤其有启发：真实场景中的视觉上下文不只是背景，而可能直接提供领域词和语义约束。

7 横向分析与启示

从横向比较看，ASR 文献中的改进大致可以分为三类。第一类改进来自建模假设变化，例如 CTC 解决无对齐训练，AED 强化输出依赖，联合 CTC-Attention 用多目标学习折中二者。第二类改进来自表示能力提升，例如 Conformer 和 E-Branchformer 通过更合理的局部-全局融合提升 encoder 上限。第三类改进来自系统与数据层面，例如 SpecAugment、HuBERT、WeNet 和 Chinese-LiPS 分别从增强、无标注预训练、部署工具链和多模态上下文角度提高实际可用性。若只比较 WER 或 CER，很容易忽略这些论文实际解决的问题不同：有的提升离线准确率，有的降低标注成本，有的缩短延迟，有的面向噪声或专业词场景。

8 讨论与未来方向

综合上述文献，端到端 ASR 的发展可以概括为五条主线。第一，目标函数从单一 CTC 或 AED 走向多目标协同，核心是平衡对齐稳定性和上下文建模能力。第二，encoder 从 RNN、CNN、Transformer 走向 Conformer 和多分支融合，核心是同时建模局部发音细节和全局语义依赖。第三，训练范式从监督学习扩展到数据增强和自监督预训练，核心是降低标注成本并提升迁移能力。第四，系统形态从离线论文模型走向可复现、可部署的工具链，核心是兼顾流式延迟、模型大小、实时率和精度。第五，输入信息从单一音频扩展到唇读、幻灯片、视觉语义和领域上下文，核心是提高复杂真实场景下的鲁棒性。

未来值得关注的方向包括以下四点。其一，面向特殊人群和口音的中文 ASR。儿童、老年人、方言和带口音普通话与 AISHELL-1 等标准数据分布差异明显，需要结合自监督预训练、少样本适配和数据增强。其二，低延迟与高精度的统一。流式系统不能简单照搬离线模型，如何在 chunk 大小、右上下文、重打分和语言模型融合之间取得可控权衡仍是关键。其三，多模态上下文增强。课堂和会议场景中可利用 PPT、OCR、术语表、说话人身份和历史文本，未来模型应从简单 prompt 融合走向更稳定的跨模态对齐与动态可信度估计。其四，可解释与可控识别。ASR 在医疗、教育和会议纪要中常需要追踪错误来源，模型应能说明错误来自声学不清、语言上下文不足、术语缺失还是视觉提示冲突。

9 结论

本文围绕 15 篇代表性论文综述了端到端自动语音识别的发展。从 Deep RNN 与 CTC 到 LAS、联合 CTC-Attention，端到端 ASR 逐步解决了未对齐序列建模问题；从 ContextNet、Conformer 到 E-Branchformer，编码器结构不断强化局部与全局上下文融合；SpecAugment 和 HuBERT 表明训练策略与预训练同样决定模型上限；ESPnet、WeNet、U2++ 和 Paraformer 则推动 ASR 从离线论文走向可复现、可部署和高效推理；AISHELL-1、音视频 Conformer 与 Chinese-LiPS 展示了中文和多模态场景的研究价值。总体而言，未来 ASR 不会只追求单一 benchmark 的最低错误率，而会更重视真实场景中的低资源适应、流式部署、多模态鲁棒性和语义上下文利用。

致谢 感谢语音信息处理课程提供的文献综述训练机会。本文阅读和整理了自动语音识别方向的代表性工作，并结合中文 ASR 与多模态识别场景形成综述。

参考文献

- [1] GRAVES A, MOHAMED A R, HINTON G. Speech recognition with deep recurrent neural networks[C]//IEEE

- International Conference on Acoustics, Speech and Signal Processing. IEEE, 2013: 6645-6649.
- [2] CHAN W, JAITLY N, LE Q, et al. Listen, attend and spell [C]//IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2016: 4960-4964.
- [3] HORI T, WATANABE S, ZHANG Y, et al. Advances in joint ctc-attention based end-to-end speech recognition with a deep cnn encoder and rnn-lm[C]//Interspeech. 2017: 949-953.
- [4] HAN W, ZHANG Z, ZHANG Y, et al. Contextnet: Improving convolutional neural networks for automatic speech recognition with global context[C]//Interspeech. 2020: 3610-3614.
- [5] GULATI A, QIN J, CHIU C C, et al. Conformer: Convolution-augmented transformer for speech recognition [C]//Interspeech. 2020: 5036-5040.
- [6] KIM K, WU F, PENG Y, et al. E-branchformer: Branchformer with enhanced merging for speech recognition[C]//IEEE Spoken Language Technology Workshop. IEEE, 2022: 84-91.
- [7] PARK D S, CHAN W, ZHANG Y, et al. Specaugment: A simple data augmentation method for automatic speech recognition[C]//Interspeech. 2019: 2613-2617.
- [8] HSU W N, BOLTE B, TSAI Y H H, et al. Hubert: Self-supervised speech representation learning by masked prediction of hidden units[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3451-3460.
- [9] WATANABE S, HORI T, KARITA S, et al. Espnet: End-to-end speech processing toolkit[C]//Interspeech. 2018: 2207-2211.
- [10] YAO Z, WUD, WANG X, et al. Wenet: Production oriented streaming and non-streaming end-to-end speech recognition toolkit[C]//Interspeech. 2021: 4054-4058.
- [11] WU D, YAO Z, ZHANG B, et al. U2++: Unified two-pass bidirectional end-to-end model for speech recognition[A]. 2021.
- [12] GAO Z, ZHANG S, MCLOUGHLIN I, et al. Paraformer: Fast and accurate parallel transformer for non-autoregressive end-to-end speech recognition[C]//Interspeech. 2022: 2063-2067.
- [13] BU H, DU J, NA X, et al. Aishell-1: An open-source mandarin speech corpus and a speech recognition baseline [C]//Oriental COCOSA. IEEE, 2017: 1-5.
- [14] MA P, PETRIDIS S, PANTIC M. End-to-end audio-visual speech recognition with conformers[C]//IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2021: 7613-7617.
- [15] ZHAO J, JIA Y, WANG S, et al. Chinese-lips: A chinese audio-visual speech recognition dataset with lip-reading and presentation slides[A]. 2024.

中文会议转写系统课题建议

王一诺¹⁾ 强博¹⁾

¹⁾(南开大学 语音信息处理课程大作业小组, 天津)

摘 要 本 Proposal 面向“语音识别”和“说话人日志”方向, 选择中文会议转写作为课程大作业任务。会议录音同时包含远场多通道、多人轮流发言、重叠说话、口语化表达、长音频切分和说话人归属等困难, 单一 ASR 模型无法直接给出可阅读的会议记录。我们计划基于 AISHELL-4 和 AISHELL-1, 复现并组合 CTC、Conformer、ECAPA-TDNN、层次聚类等关键方法, 构建从会议音频到带时间戳、匿名说话人标签、中文标点和多格式导出的完整 pipeline。

关键词 中文会议转写; 语音识别; 说话人日志; Conformer; ECAPA-TDNN; AISHELL-4

成员信息 姓名: 王一诺; 学号: 2312331; 邮箱: 2312331@mail.nankai.edu.cn

姓名: 强博; 学号: 2313825; 邮箱: 2313825@mail.nankai.edu.cn

1 问题定义

本课题研究中文会议转写: 给定一段会议长音频 X , 系统需要输出按时间排序的片段序列

$$Y = \{(t_i^s, t_i^e, q_i, w_i)\}_{i=1}^N,$$

其中 t_i^s, t_i^e 为起止时间, q_i 为会议内部一致的匿名说话人标签, w_i 为中文转写文本。最终结果不仅要识别“说了什么”, 还要回答“什么时候说”和“谁在说”, 并生成适合阅读与展示的 JSON、Markdown、TXT、SRT 文件。

与常见的短句语音识别相比, 会议场景有四类额外困难。第一, AISHELL-4 等真实会议数据存在远场、多通道、噪声和混响, 音频质量不均衡。第二, 长会议必须先切分, VAD 边界错误会传递到 ASR。第三, 多人说话和重叠语音会造成 speaker confusion, 使单纯 CER 无法反映完整转写质量。第四, 原始识别文本缺少标点、热词和可读化处理, 难以直接作为会议记录。因此本文将任务拆为数据解析、语音活动检测、ASR、说话人日志、文本后处理和统一评测六个子问题。

评测指标采用字符错误率 CER、Speaker Independent CER (SI-CER)、Speaker Dependent CER

(SD-CER) 和 diarization error rate (DER)。其中

$$\text{CER} = (S + D + I) / N$$

用于衡量中文字符级替换、删除和插入错误; SI-CER 主要评价识别与切分; SD-CER 和 DER 则用来评估说话人归属错误。

2 目前国内外研究现状

语音识别研究已经从 HMM-DNN 混合系统逐步转向端到端建模。CTC 通过 blank 标签和前向后向算法在无帧级对齐条件下训练序列模型^[1], 随后 Attention/Transformer 结构提升了长程依赖建模和并行训练能力^[2]。Conformer 将自注意力的全局建模与卷积的局部声学建模结合, 在 ASR 中成为强基线^[3]。近年来, Whisper 利用大规模弱监督数据提升跨域鲁棒性^[4], 但我们计划不依赖外部预训练模型直接产出最终结果, 因此本课题更关注可复现的自训练方案。

中文 ASR 方面, AISHELL-1 为普通话 ASR 提供了公开语料和 Kaldi baseline^[5]; WeNet 以统一流式/非流式框架推动端到端 ASR 工程化^[6]; Paraformer 和 FunASR 面向中文工业长音频识别, 包含非自回归识别、时间戳、VAD 和标点等模块^[7-8];

FunAudioLLM/SenseVoice 进一步把语音识别、情感识别和声音事件建模融合到语音基础模型中^[9]。这些工作说明中文语音系统正在从单句识别走向长音频、多任务和可部署服务。

会议转写还依赖说话人日志。传统 pipeline 通常先做 VAD 和分段,再提取 i-vector/x-vector 或 d-vector 等说话人嵌入并聚类;深度学习推动了 ECAPA-TDNN 这类带通道注意力、Res2 结构和 attentive statistics pooling 的高质量说话人表征^[10]。国际上 pyannote.audio 提供了 VAD、说话人变换点、重叠检测和 embedding 的可训练模块^[11],EEND 则尝试直接输出多说话人活动并处理重叠^[12]。Park 等人的综述指出,ASR 与 diarization 正在从级联系统走向联合建模^[13]。中文会议数据方面,AISHELL-4 以 8 通道圆阵真实会议、120 小时录音、4–8 名说话人和转写/说话人标注,为中文会议 ASR 和 diarization 提供了重要公开基准^[14]。

3 计划复现论文理解阐述

本课题计划复现的核心不是单篇论文的单模型指标,而是把若干经典论文中的关键机制落实为一个可运行会议转写系统。

(1) CTC 与字符级 ASR。CTC 将所有与目标字符序列等价的帧级路径求和,适合语音帧数远多于文本长度且缺少强制对齐的场景^[1]。我们先实现 BiLSTM-CTC baseline,统一字符表、log-Mel 特征、CTC loss、greedy decoding 和 CER 评估,保证端到端训练链路可解释。

(2) Conformer-CTC。Conformer 的 macaron feed-forward、自注意力和卷积模块分别对应全局语义依赖、局部声学形态与稳健非线性变换^[3]。项目计划实现 4 倍卷积下采样、相对位置多头注意力、depthwise convolution 和 CTC 输出层,并在同一数据和评测脚本下与 BiLSTM-CTC 对比。

(3) ECAPA-TDNN 说话人嵌入。ECAPA-TDNN 通过 SE-Res2 block、多层特征聚合和 attentive statistics pooling 得到更区分说话人的定长向量^[10]。我们计划用 AISHELL-4 clean segments 自训练轻量

ECAPA,并与 log-Mel/MFCC 统计特征 baseline 对比,再用 AHC 或 spectral clustering 生成匿名说话人标签。

(4) AISHELL-4 会议基准。AISHELL-4 的价值在于它同时给出真实会议音频、TextGrid 转写和 RTTM 说话人区间^[14]。本课题将利用标注进行训练和离线评估,但在真实推理阶段只读取音频本身,避免把测试标注作为答案回填。

4 技术路线描述

总体架构采用“先上限、后自动化”的会议转写 pipeline。输入为 AISHELL-4 或真实会议音频,首先完成音频预处理和语音活动检测,再进行语音片段切分;切分结果一方面送入中文 ASR 模型得到文本,另一方面送入说话人日志模块得到匿名说话人标签;随后通过文本后处理恢复标点、热词和可读化格式,最后融合时间戳、说话人和文本,导出结构化会议转写,并用 SI-CER、SD-CER、DER 等指标评估。整体数据流为:会议音频 → 音频预处理 → VAD/切分 → ASR 与说话人日志并行处理 → 文本后处理与时间轴融合 → JSON、Markdown、TXT、SRT 会议记录 → 识别、切分、说话人和端到端指标分析。

逐步实施路线按 M1–M9 展开,保留每一步的输入、输出和验收条件,避免只给最终模型分数而无法定位错误来源。

M1 数据清点与标注解析。目标是正确解析 AISHELL-4 的 TextGrid 和 RTTM 标注,生成统一 manifest 作为所有模块的输入。计划读取每个说话人 tier,抽取 meeting id、speaker、start、end 和 text;过滤空文本、静音和特殊标记;解析 RTTM 中的起止时间和说话人标签;对齐音频、TextGrid 与 RTTM 文件。验收标准是生成 train/test JSONL manifest,统计会议数、说话人数、语音段数、总时长和平均段长,并抽样检查时间戳与文本。

M2 音频预处理与 oracle 切分。目标是先基于人工标注得到高质量切分片段,为 ASR 实验建立上限。计划读取长会议音频,按 manifest 的 start/end 裁

剪片段, 统一采样率, 过滤过短、过长和空文本片段, 并保留 segment id 到原始会议时间轴的映射。多通道音频计划采用 max-RMS 或固定通道策略, 过长片段按固定窗口或静音二次切分。验收标准是批量生成训练和测试片段, 每段都能回溯到原始会议, 并能通过抽样播放检查裁剪位置。

M3 文本规范化与 CER 评估。目标是在训练 ASR 前建立可靠评估工具, 保证后续实验可比。计划实现中文文本规范化, 去除标点、空格和不可见字符, 统一全角半角, 过滤标注符号; 实现字符级编辑距离, 输出替换、删除、插入和总字数; 进一步实现 SI-CER 和 SD-CER, 并支持按会议、说话人和片段长度分组的错误分析。验收标准是人工构造样例可以复核 CER, oracle 文本自评接近 0, 并输出统一 JSON 指标文件。

M4 ASR baseline: 自实现 CTC 模型训练。目标是复现一个结构清晰、可训练、可评估的端到端 ASR baseline, 在 oracle 切分条件下得到第一个 SI-CER。计划从训练文本构建中文字符表, 加入 blank 和 unknown 符号; 实现 dataset、collate function、log-Mel 特征提取和 padding; 实现 BiLSTM/Transformer 编码器、CTC loss、训练循环、验证循环、checkpoint 保存与恢复; 使用 greedy decoding 输出预测和错误样例。验收标准是完成训练、可加载 checkpoint, 并能在 test 或 dev 集上输出 SI-CER。

M5 更强 ASR 模型复现与改进。目标是在 M4 基础上参考论文复现更强的端到端 ASR 结构。计划实现 Conformer-CTC, 引入卷积下采样、相对位置自注意力、macaron feed-forward 和卷积模块; 与 M4 共用 tokenizer、dataset、CTC loss 和 CER 评估脚本; 加入 prefix beam search、字符级 n-gram LM、数据增强或 SpecAugment 等改进, 并在相同数据、相同切分和相同评估脚本下与 baseline 对比。验收标准是复现至少一种比基础 CTC 更前沿的模型结构, 并形成可解释的 SI-CER 对比。

M6 自动 VAD 与非 oracle 切分。目标是从 oracle 切分过渡到真实推理所需的自动语音活动检

测。计划先实现能量 VAD 作为可控 baseline, 再训练 BiGRU 或 CNN-BiGRU 帧级 VAD; 从 TextGrid manifest 生成 speech/non-speech 帧级标签; 对完整会议长音频进行分块推理、平滑、短间隔合并、上下文 padding 和最长片段拆分; 将自动段送入 ASR, 并比较 oracle segment 与 auto VAD 的 SI-CER 差距。验收标准是输出自动 VAD segment manifest, 计算 precision、recall、F1 和边界误差, 并能运行 auto VAD + ASR + SI-CER 的完整链路。

M7 说话人日志与说话人分配。目标是在不读取测试集 RTTM 或 TextGrid 说话人答案的前提下, 自动完成说话人日志与说话人分配。计划从自动 VAD 段或源会议音频中提取 log-Mel/MFCC 统计特征作为 baseline embedding; 训练轻量 ECAPA-TDNN speaker embedding 网络; 实现 AHC 与 spectral clustering, 支持阈值停止或说话人数估计; 进行短片段平滑、不确定片段标记和 ASR 文本合并; 评估时再用参考标注计算 DER、speaker assignment accuracy 和 SD-CER。验收标准是输入陌生会议音频时只依赖音频本身, 输出 start/end/speaker/text 四元组。

M8 文本后处理: 标点、热词与可读化。目标是让系统输出从 ASR 原始文本变成可阅读会议记录。计划保留评估用规范化文本, 同时新增展示用文本规范化; 根据段长、说话人切换、段间停顿、连接词和疑问词恢复逗号、句号和问号; 从训练集挖掘会议领域热词和高频 n-gram, 加入保守的混淆别名纠错; 导出 JSON、Markdown、TXT 和 SRT。验收标准是展示文本比原始 ASR 更适合阅读, 且不覆盖 CER/SD-CER 所需原始文本。

M9 端到端系统与演示。目标是提供完整会议转写入口和简单演示界面。计划用统一配置文件组织 VAD、ASR、说话人日志和后处理参数; 实现单条 wav 推理与 test manifest 批量推理; 保留自动 VAD manifest、ASR prediction、diarization JSONL、原始 transcript、后处理统计和最终导出文件; 实现端到端评估脚本, 统一计算 meeting-level SI-CER、SD-CER、DER 和片段级说话人准确率; 提供本地拖拽

前端, 上传会议音频后展示时间戳、匿名说话人和可读化文本。验收标准是可以对单个会议和 test 全集运行完整 pipeline, 并生成可提交和可展示的会议记录样例。

致 谢 感谢“语音信息处理”课程提供大作业选题建议和评测要求, 以及项目实践机会。

参 考 文 献

- [1] GRAVES A, FERNÁNDEZ S, GOMEZ F, et al. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks[C/OL]//Proceedings of the 23rd International Conference on Machine Learning. 2006: 369-376. DOI: 10.1145/1143844.1143891.
- [2] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C/OL]//Advances in Neural Information Processing Systems: Vol. 30. 2017. <https://arxiv.org/abs/1706.03762>.
- [3] GULATI A, QIN J, CHIU C C, et al. Conformer: Convolution-augmented transformer for speech recognition [C/OL]//Proceedings of Interspeech. 2020: 5036-5040. DOI: 10.21437/Interspeech.2020-3015.
- [4] RADFORD A, KIM J W, XU T, et al. Robust speech recognition via large-scale weak supervision[A/OL]. 2022. <https://arxiv.org/abs/2212.04356>.
- [5] BU H, DU J, NA X, et al. AISHELL-1: An open-source mandarin speech corpus and a speech recognition baseline [C/OL]//Proceedings of O-COCOSDA. 2017: 1-5. <https://arxiv.org/abs/1709.05522>.
- [6] YAO Z, WU D, WANG X, et al. WeNet: Production oriented streaming and non-streaming end-to-end speech recognition toolkit[C/OL]//Proceedings of Interspeech. 2021: 4054-4058. <https://arxiv.org/abs/2102.01547>. DOI: 10.21437/Interspeech.2021-1983.
- [7] GAO Z, ZHANG S, MCLOUGHLIN I, et al. Paraformer: Fast and accurate parallel transformer for non-autoregressive end-to-end speech recognition [C/OL]//Proceedings of Interspeech. 2022: 2063-2067. <https://arxiv.org/abs/2206.08317>. DOI: 10.21437/Interspeech.2022-9996.
- [8] GAO Z, LI Z, WANG J, et al. FunASR: A fundamental end-to-end speech recognition toolkit[A/OL]. 2023. <https://arxiv.org/abs/2305.11013>.
- [9] AN K, CHEN Q, DENG C, et al. FunAudioLLM: Voice understanding and generation foundation models for natural interaction between humans and llms[A/OL]. 2024. <https://arxiv.org/abs/2407.04051>.
- [10] DESPLANQUES B, THIENPOND T J, DEMUYNCK K. ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification[C/OL]//Proceedings of Interspeech. 2020: 3830-3834. <https://arxiv.org/abs/2005.07143>. DOI: 10.21437/Interspeech.2020-2650.
- [11] BREDIN H, YIN R, CORIA J M, et al. pyannote.audio: Neural building blocks for speaker diarization[C/OL]//Proceedings of ICASSP. 2020: 7124-7128. <https://arxiv.org/abs/1911.01255>. DOI: 10.1109/ICASSP40776.2020.9052974.
- [12] FUJITA Y, KANDA N, HORIGUCHI S, et al. End-to-end neural speaker diarization with permutation-free objectives [C/OL]//Proceedings of Interspeech. 2019: 4300-4304. <https://arxiv.org/abs/1909.05952>. DOI: 10.21437/Interspeech.2019-2899.
- [13] PARK T J, KANDA N, DIMITRIADIS D, et al. A review of speaker diarization: Recent advances with deep learning [J/OL]. Computer Speech & Language, 2022, 72: 101317. <https://arxiv.org/abs/2101.09624>. DOI: 10.1016/j.csl.2021.101317.
- [14] FU Y, CHENG L, LV S, et al. AISHELL-4: An open source dataset for speech enhancement, separation, recognition and speaker diarization in conference scenario[C/OL]//Proceedings of Interspeech. 2021: 3665-3669. <https://arxiv.org/abs/2104.03603>. DOI: 10.21437/Interspeech.2021-1965.

中文会议转写系统的复现、实现与改进

强博^{1)*} 王一诺^{1)†}

¹⁾(南开大学 语音信息处理课程大作业小组, 天津)

代码仓库: https://gitee.com/sky_whale/ch-meetingtrans.git, 仓库提交数为 27 次。

摘 要 本文实现了一个面向 AISHELL-4 真实会议场景的中文会议转写系统。系统输入多通道长会议音频, 输出带时间戳、匿名说话人标签、中文标点和多格式导出的会议记录。我们首先复现 CTC-BiLSTM 字符级 ASR baseline, 随后复现 Conformer-CTC, 并加入 prefix beam search 与字符级 3-gram 语言模型; 在 oracle clean 测试集上, Conformer-CTC+LM 的 SI-CER 为 0.4454, 相比 BiLSTM-CTC 的 0.7491 相对降低 40.5%。在此基础上, 本文提出并实现了面向完整会议转写的自动化改进: BiGRU 神经 VAD 将检测 F1 从能量 VAD 的 0.8003 提升到 0.9725; 自训练 ECAPA-TDNN 说话人嵌入结合 AHC 使 DER 从 0.6356 降至 0.4540; 文本后处理保留评估文本的同时恢复标点、热词和可读化格式。最终端到端系统在 AISHELL-4 test 的 20 个会议上均生成转写, meeting-level SI-CER 为 0.4975, SD-CER 为 1.0056, DER 为 0.4541, 验证了从论文复现到可运行系统集成的完整实现链路。

关键词 中文会议转写; 语音识别; 说话人日志; Conformer; ECAPA-TDNN; AISHELL-4

1 引言 Introduction

会议转写是语音识别在真实办公和教学场景中的典型落地形式。与短句朗读式 ASR 不同, 会议音频通常具有长时长、多通道远场录制、多人交替发言、重叠说话、口语化表达、领域热词和背景噪声等特点。一个完整系统不仅需要回答“说了什么”, 还需要回答“什么时候说”和“谁在说”, 并将原始识别文本整理为可读会议记录。因此, 会议转写天然就是语音活动检测、自动语音识别、说话人日志、文本后处理和系统评估的组合任务。

本课程大作业选择 AISHELL-4 中文会议语料作为主要数据集, 并补充 AISHELL-1 作为普通话 ASR 预训练数据。项目没有调用外部训练好的 ASR 或 diarization 模型权重, 而是基于 Python、PyTorch、torchaudio、scikit-learn 等工具从数据处理、模型训练、推理到评估完整实现。工程上设计了 M0-M9 的

阶段化路线: 先用人工标注切分建立 ASR 上限, 再替换为自动 VAD; 先比较文本识别错误, 再加入自动说话人标签; 最后加入标点、热词和本地演示前端。

本文贡献包括四点: (1) 复现并实现了 CTC-BiLSTM 与 Conformer-CTC 两类端到端 ASR 模型, 在同一数据、词表、训练脚本和评估脚本下比较; (2) 设计了 clean/overlap 切分和 oracle/auto 双轨评测, 使 ASR、VAD 与端到端会议错误可分层定位; (3) 实现了 BiGRU VAD、ECAPA-TDNN 说话人嵌入、AHC 聚类 and 保守文本后处理, 构成不依赖测试标注的完整 pipeline; (4) 提供可复现命令、JSON 指标、错误样例、图表和本地拖拽演示界面, 形成从论文复现到工程实现的闭环。

*强博, 学号: 2313825, 邮箱: 2313825@mail.nankai.edu.cn。负责规划中 M4 及以前的代码实现与论文复现, 包括项目框架、AISHELL-4/AISHELL-1 数据处理、oracle 切分、文本规范化、CER/SI-CER/SD-CER 评估和 BiLSTM-CTC baseline。

†王一诺, 学号: 2312331, 邮箱: 2312331@mail.nankai.edu.cn。负责规划中 M5 及以后的代码实现与论文复现, 包括 Conformer-CTC、prefix beam search、字符级 n-gram LM、自动 VAD、ECAPA 说话人日志、文本后处理、端到端推理和演示系统。

2 相关工作 Related Work

端到端 ASR 的重要基础是 Connectionist Temporal Classification (CTC)。CTC 通过 blank 标签和前向后向求和, 在没有帧级对齐的条件下训练声学帧到字符序列的映射^[1]。在神经网络编码器方面, Transformer 利用自注意力增强长程依赖建模^[2]; Conformer 进一步将 self-attention 的全局上下文与卷积的局部声学模式结合, 成为 ASR 中常用的强编码器^[3]。中文 ASR 公开语料中, AISHELL-1 提供了大规模普通话朗读数据和基线系统^[4], 适合学习基础声学到字符映射; AISHELL-4 面向真实会议, 包含多通道音频、转写文本和说话人标注, 是中文会议 ASR 与说话人日志的重要基准^[5]。

说话人日志通常由 VAD、分段、speaker embedding 和聚类组成。ECAPA-TDNN 使用 SE-Res2 block、多层特征聚合和 attentive statistics pooling, 在说话人验证任务中取得了强表征能力^[6]。pyannote.audio 将 VAD、说话人变换点和 embedding 等模块组织为可训练 diarization 组件^[7]; EEND 则尝试以端到端方式建模多说话人活动, 缓解重叠语音问题^[8]。结合综述研究, 现代会议转写正在从级联模块走向 ASR 与 diarization 的更紧密耦合^[9]。考虑课程项目的可控实现与可复现性, 本文采用经典级联 pipeline, 但在每一层保留独立指标和错误分析。

3 问题定义 Problem Definition

给定一条会议音频 X , 系统需要输出按时间排序的片段序列

$$Y = \{(t_i^s, t_i^e, q_i, w_i)\}_{i=1}^N,$$

其中 t_i^s, t_i^e 分别表示第 i 段的起止时间, q_i 表示会议内部一致的匿名说话人标签, w_i 表示中文转写文本。真实推理时系统只能读取音频本身和训练得到的模型参数, 不能读取测试集 TextGrid 或 RTTM 中的说话人答案、边界答案或参考文本。

评价分为三层。字符错误率定义为

$$\text{CER} = \frac{S + D + I}{N_{\text{ref}}},$$

其中 S, D, I 分别为替换、删除和插入错误数。SI-CER 忽略说话人, 将同一会议的参考文本和预测文本按时间拼接后计算 CER, 主要评估切分和 ASR。SD-CER 将说话人归属纳入文本拼接, 评估完整会议转写。DER 按时间帧统计 miss、false alarm 和 speaker confusion, 评估说话人日志。自动说话人标签是匿名的, 评估阶段才根据参考标注学习最优映射。

4 方法 Methodology

4.1 总体流程

系统按照“音频预处理 → VAD/切分 → ASR 与说话人日志并行 → 文本后处理 → 时间轴融合与导出”组织。代码中, src/ch_meetingtrans/datatest/ 负责 TextGrid、RTTM 和 manifest 解析; segment/ 负责多通道选择与 oracle 切分; asr/ 包含 CTC-BiLSTM、Conformer-CTC、字符表和解码; vad/ 包含能量 VAD、BiGRU VAD 和检测指标; diarization/ 包含 speaker embedding、聚类、DER、SD-CER 和 transcript 构建; postprocess/ 负责标点、热词和多格式导出; scripts/infer_meeting.py 将所有模块串联为 M9 端到端入口。

4.2 复现方法一: CTC-BiLSTM

M4 复现 CTC 字符级 ASR。输入音频统一为 16 kHz, 提取 80 维 log-Mel 特征, 字符表由 AISHELL-1 与 AISHELL-4 训练文本共同构建, 包含 blank 和 unk。模型为 2 层双向 LSTM, hidden size 为 256, 输出层直接预测字符分布。训练使用 CTC loss; 推理使用 greedy decoding, 并严格按照模型有效输出长度截断, 避免 batch padding 帧被错误解码。训练路线先在 AISHELL-1 上学习普通话基础声学映射, 再用 AISHELL-4 clean segments 微调。

4.3 复现方法二：Conformer-CTC 与语言模型融合

M5 复现 Conformer-CTC。实现包含 4 倍二维卷积下采样、正弦位置编码、相对位置多头自注意力、macaron feed-forward、depthwise convolution、batch normalization 和 CTC 输出层。默认配置为 model dimension 144、6 个 Conformer block、4 个 attention heads、FFN dimension 576、卷积核大小 31。该模型与 M4 共用 dataset、词表、CTC loss、checkpoint 和 CER 评估脚本，因此结果差异主要来自编码器和解码策略。

解码方面，除 greedy decoding 外，本文实现 CTC prefix beam search，并训练字符级 3-gram LM 进行 shallow fusion。扩展一个非 blank 字符时，前缀分数加入 $\lambda \log p_{LM}(c | \text{prefix})$ ，实验中 beam size 为 10，LM weight 为 0.2。语言模型只用训练文本统计，不引入外部语料。

4.4 复现难点与实现细节

第一，AISHELL-4 会议数据远场、多通道且训练子集较小，直接在 train_L 上从零训练 CTC 容易陷入高 CER。为此，系统增加 AISHELL-1 预训练，再在 AISHELL-4 clean segments 微调。第二，多通道音频不同通道信噪比差异明显，固定第 0 通道会损伤部分片段；实现中采用 max_rms 策略为片段选择 RMS 最大通道。第三，会议中重叠说话会同时影响 ASR 和 diarization，因此用 split_overlap_manifest.py 按重叠时长和比例划分 clean/overlap 子集，使主指标与困难场景分析分开。第四，自动 VAD 输出的片段粒度与 TextGrid 不一致，不能简单逐段比较文本；因此 M6/M9 增加 meeting-level SI-CER，将自动段文本按会议时间排序后拼接评估。

4.5 创新方法与系统级改进

在复现 ASR 模型之后，本文围绕“从 oracle 实验走向真实会议推理”实现四项系统级改进。第一，BiGRU 神经 VAD 从 TextGrid 生成帧级 speech/non-speech 标签，使用 80 维 log-Mel 特征和双向 GRU 进

行帧级二分类；长会议推理时按 20 秒窗口、2 秒重叠分块，之后做阈值化、平滑、短间隔合并、padding 和最长 30 秒拆分。第二，ECAPA-TDNN 说话人嵌入在 AISHELL-4 clean segments 上从零训练，网络包含 TDNN 前端、SE-Res2 block、多层聚合、attentive statistics pooling 和 AAM-Softmax；推理时对自动 VAD 段提取窗口级 embedding，使用 AHC 聚类，并对短片段做邻居平滑和置信度标记。第三，文本后处理将评估文本和展示文本解耦：text/eval_text 保持原始 ASR 结果用于 CER/SD-CER，display_text 单独做重复清理、保守热词纠错、标点恢复和 SRT 时间格式化。第四，M9 端到端入口以 configs/infer.yaml 固化最佳配置，批量推理会保留 VAD manifest、ASR predictions、diarization JSONL、raw transcript、postprocess stats 和最终 JSON/Markdown/TXT/SRT 文件。

5 实验 Experimental Results

5.1 实验数据集与设置

主要实验使用 AISHELL-4 的 train_L 和 test。原始 manifest 中训练集包含 30 个会议、12508 条标注片段；测试集包含 20 个会议、10561 条标注片段。oracle 切分后训练集保留 12503 段，测试集保留 10519 段；按重叠比例划分后，训练 clean/overlap 分别为 6969/5534 段，测试 clean/overlap 分别为 7056/3463 段。ASR 预训练使用 AISHELL-1 train/dev/test manifest。所有 ASR 模型使用 16 kHz、80 维 log-Mel 特征；Conformer 最佳推理配置为 prefix beam search、beam size 10、字符 3-gram LM、LM weight 0.2。VAD、ASR、diarization 和最终系统均保存 JSON 指标文件，图表由 scripts/plot_m*.py 生成。

表 1 ASR 复现结果

阶段	方法	测试设置	样本数	SI-CER
M4	BiLSTM-CTC	clean, greedy	7053	0.7491
M4	BiLSTM-CTC	full, greedy	10499	0.7696
M4	BiLSTM-CTC	overlap, greedy	3446	0.8377
M5	Conformer-CTC	clean, greedy	7053	0.4593
M5	Conformer-CTC	clean, prefix beam	7053	0.4587
M5	Conformer-CTC	clean, prefix beam + 3-gram LM	7053	0.4454

表 1 显示, Conformer-CTC 在相同 clean 测试集上明显优于 BiLSTM-CTC。加入 prefix beam search 后, SI-CER 从 0.4593 小幅降至 0.4587; 加入字符级 3-gram LM 后进一步降至 0.4454。与 M4 clean baseline 0.7491 相比, M5 最佳设置相对降低约 40.5%。同时, M4 在 overlap 子集上的 SI-CER 为 0.8377, 高于 full 和 clean, 说明重叠说话是会议 ASR 的主要困难之一。




图 1 M5 Conformer-CTC 与 M4 baseline 的 clean test SI-CER 对比

表 2 自动 VAD 与端到端 ASR 结果

设置	Precision	Recall	F1	Segment SI-CER	Meeting SI-CER	自动段数
Energy VAD + M5 ASR	0.9877	0.6727	0.8003	0.8918	0.6470	19944
BiGRU VAD + M5 ASR	0.9504	0.9958	0.9725	0.5703	0.4975	2766

表 2 中, 能量 VAD 具有较高 precision, 但 recall 只有 0.6727, 漏检语音导致 meeting-level SI-CER 达到 0.6470。BiGRU VAD 的 recall 提升到 0.9958, F1 达到 0.9725, meeting-level SI-CER 降至 0.4975。代价是 false alarm rate 从 0.0080 增至 0.0496, 平均起止边界误差约 5.16/5.20 秒, 高于能量 VAD 的 2.80/2.91 秒。这个结果说明会议转写中, 适度多召回语音比漏掉大段语音更有利于最终文本覆盖率。




图 2 oracle 与自动 VAD 条件下的 ASR SI-CER 对比

表 3 说话人日志结果

方法	DER	Miss	FA	Confusion	Weighted Acc	SD-CER
log-Mel stats + AHC	0.6356	0.0289	0.0188	0.5879	0.4131	1.2832
ECAPA embedding + AHC	0.4540	0.0289	0.0188	0.4063	0.6143	1.0056

表 3 显示, 统计特征 baseline 的主要错误来自 speaker confusion, 且估计说话人数偏少。ECAPA embedding + AHC 将 DER 从 0.6356 降至 0.4540, 相对降低约 28.6%; weighted speaker assignment accuracy 从 0.4131 提升到 0.6143; SD-CER 从 1.2832 降至 1.0056。由于 VAD miss 和 false alarm 在两种 diarization 设置下基本相同, DER 改善主要来自说话人混淆降低。




图 3 log-Mel baseline 与 ECAPA speaker embedding 的 diarization 指标对比

表 4 M8/M9 最终系统结果

指标	数值
测试会议数 / 输出会议数	20 / 20
参考片段数 / 系统输出片段数	10561 / 2676
M8 display segments	2558
M8 hotword replacements	24
M9 meeting-level SI-CER	0.4975
M9 SD-CER	1.0056
M9 DER	0.4541
M9 speaker accuracy	0.5717

最终系统使用 BiGRU VAD、Conformer-CTC + prefix beam + 3-gram LM、ECAPA + AHC 和 M8 后处理。M8 对 2676 个输入片段生成 2558 个可展示片段, 执行 24 次热词替换, 并保证原始 text 保留用于评估。M9 在 AISHELL-4 test 的 20 个会议上均生成 JSON、Markdown、TXT 和 SRT; 最终 SI-CER 与 M6 neural VAD meeting-level SI-CER 基本一致, 说

明 M8 展示层没有污染评估文本；SD-CER 与 DER 则反映当前说话人日志仍是完整会议转写的主要瓶颈。

5.2 结果分析

从 M4 到 M5，错误主要来自声学编码能力不足，Conformer 的局部卷积和全局注意力显著改善了替换和删除错误。语言模型融合进一步减少替换和插入，但由于会议口语噪声强、训练文本规模有限，LM 对 deletion 的改善并不稳定。M6 表明自动切分比 oracle 切分更接近真实场景，但切分粒度会影响 ASR：能量 VAD 过度切碎且漏检多，虽然 precision 高，却导致长文本缺失；BiGRU VAD 更偏召回，最终 meeting-level SI-CER 更好。M7 中 ECAPA 明显优于 log-Mel 统计特征，但 DER 仍有 0.4540，原因包括短片段 embedding 不稳定、重叠说话不可由单标签完全解释，以及 AHC 阈值对不同会议说话人数敏感。总体来看，ASR clean oracle 上限已降至 0.4454，而完整自动系统 SI-CER 为 0.4975，主要差距来自自动 VAD 边界和说话人日志，而不是单纯解码器能力。

6 总结与展望

本文按照课程 Implementation 要求，完成了中文会议转写系统从论文方法复现到端到端工程实现的完整链路。系统复现了 CTC-BiLSTM、Conformer-CTC、ECAPA-TDNN 等经典方法，并在 AISHELL-4 上给出可追踪的 ASR、VAD、diarization、后处理和最终系统指标。最终系统能对陌生会议音频执行自动切分、识别、说话人聚类、标点热词后处理和多格式导出。

后续可从三方面改进。第一，ASR 可加入 SpecAugment、更大 Conformer、联合 CTC/attention 或 RNN-T，以降低 clean oracle 上限。第二，VAD 与 diarization 可加入重叠语音检测和更稳健的说话人数估计，降低 speaker confusion。第三，可探索 ASR 与 diarization 的联合建模或二阶段重打分，使说话人一致性、语言模型和时间边界共同优化。若算力允许，还可以在不使用外部测试答案的前提下扩展

训练数据和领域热词，提高系统对真实会议、课堂讨论和多人访谈的泛化能力。

致谢 感谢“语音信息处理”课程提供项目要求、选题建议和实践机会。

参考文献

- [1] GRAVES A, FERNÁNDEZ S, GOMEZ F, et al. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks[C/OL]//Proceedings of the 23rd International Conference on Machine Learning. 2006: 369-376. DOI: 10.1145/1143844.1143891.
- [2] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C/OL]//Advances in Neural Information Processing Systems: Vol. 30. 2017. <https://arxiv.org/abs/1706.03762>.
- [3] GULATI A, QIN J, CHIU C C, et al. Conformer: Convolution-augmented transformer for speech recognition [C/OL]//Proceedings of Interspeech. 2020: 5036-5040. DOI: 10.21437/Interspeech.2020-3015.
- [4] BU H, DU J, NA X, et al. AISHELL-1: An open-source mandarin speech corpus and a speech recognition baseline [C/OL]//Proceedings of O-COCOSDA. 2017: 1-5. <https://arxiv.org/abs/1709.05522>.
- [5] FU Y, CHENG L, LV S, et al. AISHELL-4: An open source dataset for speech enhancement, separation, recognition and speaker diarization in conference scenario [C/OL]//Proceedings of Interspeech. 2021: 3665-3669. <https://arxiv.org/abs/2104.03603>. DOI: 10.21437/Interspeech.2021-1965.
- [6] DESPLANQUES B, THIENPOND T, DEMUYNCK K. ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification[C/OL]//Proceedings of Interspeech. 2020: 3830-3834. <https://arxiv.org/abs/2005.07143>. DOI: 10.21437/Interspeech.2020-2650.
- [7] BREDIN H, YIN R, CORIA J M, et al. pyannote.audio: Neural building blocks for speaker diarization[C/OL]//Proceedings of ICASSP. 2020: 7124-7128. <https://arxiv.org/abs/2005.07143>.

g/abs/1911.01255. DOI: 10.1109/ICASSP40776.2020.9052974.

- [8] FUJITA Y, KANDA N, HORIGUCHI S, et al. End-to-end neural speaker diarization with permutation-free objectives [C/OL]//Proceedings of Interspeech. 2019: 4300-4304. <https://arxiv.org/abs/1909.05952>. DOI: 10.21437/Interspeech.2

附录 A 实验复现过程和结果截图.

核心复现实验均在项目根目录下运行, 先设置 PYTHON PATH=src. 主要步骤为: (1) 运行 prepare_manifest.py 和 prepare_segments.py 生成 manifest 与 oracle segments; (2) 运行 train_asr_ctc.py 训练 BiLSTM-CTC 与 Conformer-CTC, 并用 infer_asr_ctc.py 评估 greedy、prefix beam 和 LM 融合; (3) 运行 train_vad.py、prepare_auto_vad_segments.py 和 evaluate_vad_segments.py 评估自动 VAD; (4) 运行 train_speaker_embedding.py、run_diarization.py 和 evaluate_diarization.py 评估说话人日志; (5) 运行 postprocess_transcript.py、infer_meeting.py 和 evaluate_system.py 生成最终转写与端到端指标. 全部关键产物保存在 outputs/metrics/、outputs/predictions/、outputs/diarization/、outputs/transcripts/ 和 outputs/figures/ 中. 最终系统评估日志显示 Reference meetings 为 20、Hypothesis meetings 为 20、Hypothesis segments 为 2676、SI-CER 为 0.4975、SD-CER 为 1.0056、DER 为 0.4541. 图 4 为本地演示界面与转写结果截图.

019-2899.

- [9] PARK T J, KANDA N, DIMITRIADIS D, et al. A review of speaker diarization: Recent advances with deep learning [J/OL]. Computer Speech & Language, 2022, 72: 101317. <https://arxiv.org/abs/2101.09624>. DOI: 10.1016/j.csl.2021.101317.

scripts/ 和 outputs/figures/ 中. 最终系统评估日志显示 Reference meetings 为 20、Hypothesis meetings 为 20、Hypothesis segments 为 2676、SI-CER 为 0.4975、SD-CER 为 1.0056、DER 为 0.4541. 图 4 为本地演示界面与转写结果截图.



图 4 M9 本地拖拽演示界面与会议转写结果截图